

Oppgavesett 1

Kapittel 1 og 2: Statistisk læring, prediksjon og bias-varians

SOK-1305 Statistisk læring for økonomer

Handelshøgskolen ved UiT
Høsten 2026

Hvordan jobbe med dette settet. Oppgavene følger James, Witten, Hastie, Tibshirani & Taylor, *An Introduction to Statistical Learning with Applications in Python* (ISLP). Kapittel 1 har ingen oppgaver i boka, så del A er egne oppgaver til lesestoffet. Del B og C er oppgavene i avsnitt 2.4. Jobb gjerne to og to, og bruk Python aktivt fra første uke – det er kortere vei fra kode til forståelse enn du tror.

Anbefalt utvalg:

- **Obligatorisk kjerne:** A1, A3, B1, B2, B3, B7, C9
- **Anbefalt:** A2, B5, B6, C8
- **Ekstra / for de som vil grave dypere:** A4, B4, C10

Innhold

1 Del A – Kapittel 1: Hva er statistisk læring?	1
A1. De tre eksempeldatasettene	2
A2. Prediksjon eller inferens?	2
A3. Kom i gang med Python og ISLP	3
A4. Statistisk læring og økonometri (diskusjon)	3
2 Del B – Kapittel 2, konseptuelle oppgaver (2.4)	4
B1. (ISLP 2.4, oppgave 1) Fleksibel eller lite fleksibel metode?	4
B2. (ISLP 2.4, oppgave 2) Klassifikasjon eller regresjon? Inferens eller prediksjon?	4
B3. (ISLP 2.4, oppgave 3) Bias-varians-dekomposisjonen	5
B4. (ISLP 2.4, oppgave 4) Anvendelser i praksis	6
B5. (ISLP 2.4, oppgave 5) Fordeler og ulemper ved høy fleksibilitet	7
B6. (ISLP 2.4, oppgave 6) Parametrisk mot ikke-parametrisk	7
B7. (ISLP 2.4, oppgave 7) K -nærmeste naboer for hånd	7
3 Del C – Kapittel 2, anvendte oppgaver (2.4)	8
C8. (ISLP 2.4, oppgave 8) College-datasettet	8
C9. (ISLP 2.4, oppgave 9) Auto-datasettet	9
C10. (ISLP 2.4, oppgave 10) Boston-datasettet	11

1 Del A – Kapittel 1: Hva er statistisk læring?

Kapittel 1 i ISLP inneholder ingen oppgaver. Oppgavene under er laget til lesestoffet og til de tre datasettene som presenteres i kapitlet (*Wage*, *Smarket* og *NCI60*).

A1. De tre eksempeldatasettene

Kapittel 1 introduserer tre datasett. For hvert av dem: avgjør om problemet er *veiledet* (supervised) eller *ikke-veiledet* (unsupervised) læring, om det er et regresjons- eller klassifikasjonsproblem, og identifiser responsvariabel og prediktorer.

- (a) **Wage**: lønnsdata for menn i Midt-Atlanteren i USA.
- (b) **Smarket**: daglige prosentvise endringer i S&P 500 over fem år.
- (c) **NCI60**: genuttrykksmålinger for 64 kreftcellelinjer.

Løsningsforslag

- (a) **Wage** – veiledet læring, regresjon. Responsen er lønn (kontinuerlig), prediktorene er blant annet alder, utdanningsnivå og kalenderår. Formålet i kapitlet er dels beskrivende (hvordan varierer lønn med alder?), dels prediktivt.
- (b) **Smarket** – veiledet læring, klassifikasjon. Responsen er en binær variabel: gikk markedet opp eller ned den aktuelle dagen. Prediktorene er de prosentvise endringene på de foregående fem dagene (og handelsvolum). Merk at treffsikkerheten er nær 50 % – et nyttig realitetssjekk-eksempel for økonomer.
- (c) **NCI60** – ikke-veiledet læring. Det finnes ingen responsvariabel; vi har 6830 genuttrykksmålinger på 64 cellelinjer og ønsker å finne grupper (klynger) av cellelinjer som ligner på hverandre. Kreftformen brukes bare i etterkant for å vurdere om klyngene gir mening – den inngår ikke i estimeringen.

A2. Prediksjon eller inferens?

Skillet mellom prediksjon og inferens er sentralt i faget. Gi tre eksempler fra økonomi eller samfunnsliv der *prediksjon* er hovedmålet, og tre der *inferens* er hovedmålet. Forklar kort hvorfor, og hva slags data du ville trenge.

Løsningsforslag

Eksempler på **prediksjon** (vi bryr oss om at $\hat{y}$ treffer, ikke om formen på $\hat{f}$):

- Kredittvurdering: vil denne låntakeren misligholde lånet?
- Etterspørselsprognose i en butikkjede for neste uke.
- Prisanslag på bolig ut fra areal, beliggenhet, byggeår.

Eksempler på **inferens** (vi vil forstå sammenhengen):

- Hvor mye øker lønna av ett ekstra år utdanning?
- Hvilken effekt har en avgiftsendring på forbruket av en vare?
- Hvilke faktorer forklarer forskjeller i produktivitet mellom bedrifter?

Poenget: til prediksjon kan vi gjerne bruke en svart boks med høy fleksibilitet, mens inferens krever modeller vi kan tolke – og ofte en identifikasjonsstrategi som gir kausal og ikke bare korrelasjonell tolkning. Mange praktiske problemer er blandinger: vi vil både treffe godt *og* kunne forklare hvorfor.

A3. Kom i gang med Python og ISLP

Installer Python-pakken ISLP, last inn Wage-datasettet, og lag et spredningsplott av lønn mot alder. Legg inn en glattet kurve eller en enkel gruppevis gjennomsnittslinje. Kommenter formen: hva skjer med lønn når alderen øker?

Løsningsforslag

```
# I terminalen (en gang): pip install ISLP
import numpy as np, pandas as pd
import matplotlib.pyplot as plt
from ISLP import load_data

Wage = load_data('Wage')
Wage.head()
Wage.describe()

fig, ax = plt.subplots(figsize=(7,5))
ax.scatter(Wage['age'], Wage['wage'], alpha=0.25, s=12, color='grey')

# Gruppevis gjennomsnitt per alder som enkel "glatting"
means = Wage.groupby('age')['wage'].mean()
ax.plot(means.index, means.values, color='#007396', linewidth=2.5)

ax.set_xlabel('Alder')
ax.set_ylabel('Lønn (1000 USD)')
ax.set_title('Lønn mot alder, Wage-datasettet')
plt.show()
```

Kommentar: Lønna stiger bratt fra tjueårene, flater ut rundt 40–50 år og faller svakt etter det. Sammenhengen er tydelig *ikke* lineær – en rett linje ville bomme systematisk i begge ender. Legg også merke til den lille gruppen med svært høy lønn (over 250), som skiller seg fra hovedmassen. Begge observasjonene motiverer metodene senere i kurset.

A4. Statistisk læring og økonometri (diskusjon)

Du har tidligere hatt kurs i økonometri. Skriv en halv side om hva du tror er de viktigste forskjellene i *formål* og *arbeidsmåte* mellom en klassisk økonometrisk analyse og en statistisk læringsanalyse. Hvor overlapper de?

Løsningsforslag

Momenter som bør komme fram (det finnes ikke ett fasitsvar):

- **Formål:** Økonometri retter seg tradisjonelt mot parameterestimering og kausal tolkning ($\hat{\beta}$ er interessant i seg selv). Statistisk læring retter seg ofte mot ut-av-utvalg-prediksjon ($\hat{f}$ er et middel, ikke et mål).
- **Evalueringskriterium:** Signifikans, R^2 og forventningsretthet mot testfeil målt på data modellen ikke har sett.
- **Modellvalg:** Teoridrevet spesifikasjon mot datadrevet valg ved kryssvalidering og regulering.
- **Skjevhet:** Økonometri er villig til å ofre presisjon for forventningsretthet; statistisk læring aksepterer gjerne litt skjevhet dersom det gir betydelig lavere varians (bias–varians-avveiningen).
- **Overlapp:** Begge bygger på samme statistiske grunnmur, begge bruker lineær regresjon

som arbeidshest, og feltene nærmer seg hverandre – «kausal maskinlæring» er et aktivt forskningsfelt.

2 Del B – Kapittel 2, konseptuelle oppgaver (2.4)

B1. (ISLP 2.4, oppgave 1) Fleksibel eller lite fleksibel metode?

For hvert av tilfellene under: vil vi vanligvis forvente at en *fleksibel* metode gjør det bedre eller dårligere enn en *lite fleksibel* metode? Begrunn.

- (a) Utvalgsstørrelsen n er svært stor, antall prediktorer p er lite.
- (b) p er svært stor, n er liten.
- (c) Sammenhengen mellom prediktorene og responsen er sterkt ikke-lineær.
- (d) Variansen til feilledet, $\sigma^2 = \text{Var}(\epsilon)$, er svært høy.

Løsningsforslag

- (a) **Bedre.** Med mange observasjoner og få prediktorer kan en fleksibel metode estimere en komplisert f uten at variansen eksploderer. Vi har «råd til» fleksibilitet.
- (b) **Dårligere.** Med få observasjoner og mange prediktorer vil en fleksibel metode tilpasse seg støyen i treningsdataene – klassisk overtilpasning, høy varians.
- (c) **Bedre.** En lite fleksibel metode (for eksempel lineær regresjon) kan ikke fange opp en sterkt ikke-lineær f og vil få stor skjevhet uansett hvor mye data vi har.
- (d) **Dårligere.** Når mye av variasjonen i y er ren støy, vil en fleksibel metode «lære» støyen. Merk at σ^2 er den irreducible feilen – den kan ikke reduseres av noen metode, men fleksibilitet gjør vondt verre ved å legge varians på toppen.

B2. (ISLP 2.4, oppgave 2) Klassifikasjon eller regresjon? Inferens eller prediksjon?

For hvert scenario: er dette et klassifikasjons- eller regresjonsproblem, er vi mest interessert i inferens eller prediksjon, og hva er n og p ?

- (a) Vi samler data om de 500 største bedriftene i USA. For hver bedrift registreres overskudd, antall ansatte, bransje og direktørlønn. Vi ønsker å forstå hvilke faktorer som påvirker direktørlønna.
- (b) Vi vurderer å lansere et nytt produkt og vil vite om det blir en suksess eller fiasko. Vi samler data om 20 tilsvarende produkter som er lansert tidligere. For hvert produkt vet vi om det ble suksess eller fiasko, pris, markedsføringsbudsjett, konkurrentpris og ti andre variabler.
- (c) Vi vil predikere den prosentvise endringen i USD/euro-kursen ut fra ukentlige endringer i verdens aksjemarkeder. Vi samler ukedata for hele 2012: prosentvis endring i USD/euro, i det amerikanske, det britiske og det tyske markedet.

Løsningsforslag

- (a) **Regresjon** (direktørlønn er kontinuerlig), **inferens** (vi vil forstå hvilke faktorer som spiller inn, ikke gjette lønna til bedrift nr. 501). $n = 500$, $p = 3$ (overskudd, antall ansatte, bransje).
- (b) **Klassifikasjon** (suksess/fiasco), **prediksjon** (vi bryr oss om utfallet for *vårt* produkt). $n = 20$, $p = 13$ (pris, markedsføringsbudsjett, konkurrentpris og ti andre).
- (c) **Regresjon** (prosentvis endring er kontinuerlig), **prediksjon**. $n = 52$ uker, $p = 3$ (endring i det amerikanske, britiske og tyske markedet).


Merk: Legg spesielt merke til (b): $n = 20$ og $p = 13$ er en svært vanskelig situasjon. Sammenlign med B1(b).

B3. (ISLP 2.4, oppgave 3) Bias–varians-dekomposisjonen

- (a) Skisser typiske kurver for kvadrert skjevhet (bias), varians, treningsfeil, testfeil og Bayesfeil (irreduibel feil) i én og samme figur, når vi går fra lite fleksible til mer fleksible metoder. x -aksen er fleksibilitet, y -aksen er verdien til hver kurve. Det skal være fem kurver – merk dem.
- (b) Forklar hvorfor hver av de fem kurvene har den formen du har tegnet.

Løsningsforslag

- (a) Figuren under viser den typiske formen.



- (b) Utgangspunktet er dekomposisjonen av forventet testfeil i et punkt x_0 :

$$\mathbb{E}(y_0 - \hat{f}(x_0))^2 = \text{Var}(\hat{f}(x_0)) + [\text{Bias}(\hat{f}(x_0))]^2 + \text{Var}(\epsilon).$$

- **Kvadrert skjevhet** faller monotont. Mer fleksible metoder kan tilnærme den sanne f bedre, så den systematiske feilen som følger av å bruke en for enkel modell krymper.
- **Varians** stiger monotont. Jo mer fleksibel metoden er, jo mer vil $\hat{f}$ endre seg dersom vi bytter ut treningssettet med et annet trekk fra samme populasjon.

- **Treningsfeilen** faller monotont, og går mot null for svært fleksible metoder – disse kan i ytterste konsekvens interpolere treningsdataene. Derfor er treningsfeil et *ubrukelig* kriterium for modellvalg.
- **Testfeilen** er summen av de tre leddene over og får dermed en karakteristisk U-form: først dominerer fallet i skjevhet, deretter dominerer veksten i varians. Minimumspunktet er den fleksibiliteten vi ønsker oss.
- **Irreduksibel feil** er en vannrett linje. Den kommer fra ϵ – støy og utelatte variabler som ingen modell kan fange opp. Den er et gulv: testfeilkurven kan aldri ligge under den.

B4. (ISLP 2.4, oppgave 4) Anvendelser i praksis

- Beskriv tre virkelige anvendelser der klassifikasjon er nyttig. Hva er responsen, hva er prediktorene, og er målet inferens eller prediksjon?
- Samme spørsmål for tre anvendelser av regresjon.
- Beskriv tre anvendelser der klyngeanalyse er nyttig.

Løsningsforslag

Åpen oppgave – her er noen forslag med økonomisk vinkling.

(a) Klassifikasjon

- *Konkursprediksjon*: respons = konkurs innen tre år (ja/nei); prediktorer = regnskapstall som gjeldsgrad, likviditet, driftsmargin, bransje. Mål: prediksjon.
- *Kundefrafall (churn)*: respons = sa opp abonnementet (ja/nei); prediktorer = bruksmønster, kundalder, antall kundeservicehenvendelser. Mål: prediksjon, men bedriften vil ofte også vite *hvorfor* – altså litt inferens.
- *Deltakelse i arbeidsstyrken*: respons = i arbeid (ja/nei); prediktorer = utdanning, alder, barn, region. Mål: typisk inferens.

(b) Regresjon

- *Boligpriser*: respons = kvadratmeterpris; prediktorer = beliggenhet, størrelse, byggeår, standard. Mål: prediksjon (takst) eller inferens (verdien av utsikt).
- *Lønnsdannelse*: respons = timelønn; prediktorer = utdanning, erfaring, yrke, kjønn. Mål: inferens.
- *Strømforbruk*: respons = forbruk neste døgn; prediktorer = temperatur, ukedag, historisk forbruk. Mål: prediksjon.

(c) Klyngeanalyse

- Kundesegmentering ut fra kjøpsmønster.
- Gruppering av kommuner eller regioner etter næringsstruktur.
- Gruppering av land etter makroøkonomiske nøkkeltall for å velge sammenlignbare «kontrollgrupper».

B5. (ISLP 2.4, oppgave 5) Fordeler og ulemper ved høy fleksibilitet

Hva er fordelene og ulempene med en svært fleksibel tilnærming (sammenlignet med en mindre fleksibel) til regresjon eller klassifikasjon? Når kan en mer fleksibel metode være å foretrekke, og når er en mindre fleksibel bedre?

Løsningsforslag

Fordeler ved høy fleksibilitet: kan tilnærme et bredt spekter av former for f , og dermed lav skjevhet; gjør få antakelser som kan slå feil; ofte høyere treffsikkerhet i prediksjon når det finnes nok data.

Ulemper: høy varians og risiko for overtilpasning; krever langt flere observasjoner; er tung å tolke – vi kan sjelden si «effekten av X_j er β_j »; ofte dyrere å estimere; vanskeligere å gjøre klassisk statistisk inferens (standardfeil, hypotesetester) på.

Foretrekkes når: målet er ren prediksjon, n er stor i forhold til p , den sanne sammenhengen antas komplisert og ikke-lineær, og støynivået er moderat.

Mindre fleksibelt foretrekkes når: målet er inferens og tolkbarhet, n er liten, p er stor, støyen er høy, eller når vi har god teoretisk grunn til å tro at en enkel form er omtrent riktig. I mange økonomiske anvendelser er tolkbarhet et krav fra oppdragsgiver eller regelverk – det alene kan avgjøre valget.

B6. (ISLP 2.4, oppgave 6) Parametrisk mot ikke-parametrisk

Beskriv forskjellen mellom en parametrisk og en ikke-parametrisk tilnærming til statistisk læring. Hva er fordelene med en parametrisk tilnærming, og hva er ulempene?

Løsningsforslag

En **parametrisk** metode gjør problemet om til å estimere et endelig antall parametere: vi antar først en funksjonsform, for eksempel $f(X) = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p$, og estimerer deretter de $p+1$ koeffisientene. En **ikke-parametrisk** metode antar ingen bestemt form for f , men prøver å komme så nær datapunktene som mulig uten å bli for ruglete – for eksempel K -nærmeste naboer eller glattingssplines.

Fordeler ved parametrisk: enklere problem (estimer noen få tall framfor en hel funksjon); krever mye mindre data; resultatene er tolkbare; velutviklet apparat for standardfeil og hypotesetester; rask å beregne.

Ulemper: den valgte formen stemmer nesten aldri helt med den sanne f . Er avviket stort, får vi systematisk skjevhet som ikke forsvinner uansett hvor mye data vi samler. Motmiddelet – mer fleksible parametriske modeller med flere ledd – fører oss tilbake mot overtilpasning.

Ikke-parametrisk unngår formantakelsen, men trenger til gjengjeld svært mange observasjoner for å gi presise estimater, og gir lite tolkbare svar.

B7. (ISLP 2.4, oppgave 7) K -nærmeste naboer for hånd

Tabellen viser et treningssett med seks observasjoner, tre prediktorer og en kvalitativ respons.

Obs.	X_1	X_2	X_3	Y
1	0	3	0	Rød
2	2	0	0	Rød
3	0	1	3	Rød
4	0	1	2	Grønn
5	-1	0	1	Grønn
6	1	1	1	Rød

Vi ønsker å predikere Y i testpunktet $X_1 = X_2 = X_3 = 0$ ved hjelp av K -nærmeste naboer.

- (a) Beregn den euklidske avstanden fra hver observasjon til testpunktet.
- (b) Hva blir prediksjonen med $K = 1$? Hvorfor?
- (c) Hva blir prediksjonen med $K = 3$? Hvorfor?
- (d) Dersom Bayes-beslutningsgrensa i dette problemet er sterkt ikke-lineær, vil vi da forvente at den beste verdien av K er stor eller liten? Hvorfor?

Løsningsforslag

(a) Avstanden er $d_i = \sqrt{X_{i1}^2 + X_{i2}^2 + X_{i3}^2}$:

Obs.	Regnestykke	d_i	Y
1	$\sqrt{0 + 9 + 0}$	3,00	Rød
2	$\sqrt{4 + 0 + 0}$	2,00	Rød
3	$\sqrt{0 + 1 + 9}$	3,16	Rød
4	$\sqrt{0 + 1 + 4}$	2,24	Grønn
5	$\sqrt{1 + 0 + 1}$	1,41	Grønn
6	$\sqrt{1 + 1 + 1}$	1,73	Rød

(b) $K = 1$: nærmeste nabo er observasjon 5 med $d = 1,41$. Prediksjonen er **Grønn**.

(c) $K = 3$: de tre nærmeste er observasjon 5 (Grønn), 6 (Rød) og 2 (Rød). Estimerte sannsynligheter blir $\hat{P}(\text{Rød}) = 2/3$ og $\hat{P}(\text{Grønn}) = 1/3$, så prediksjonen er **Rød**.

(d) **Liten K** . Lav K gir en fleksibel, lokal beslutningsgrense som kan bøye seg etter en komplisert Bayes-grense. Stor K glatter over mange naboer og gir en tilnærmet lineær grense – lav varians, men stor skjevhet når den sanne grensa er krokete. (Se figur 2.16 i boka: $K = 1$ mot $K = 100$.)

Sjekk med Python:

```
import numpy as np
from sklearn.neighbors import KNeighborsClassifier

X = np.array([[0,3,0],[2,0,0],[0,1,3],[0,1,2],[-1,0,1],[1,1,1]])
y = np.array(['Rød','Rød','Rød','Grønn','Grønn','Rød'])
x0 = np.array([0,0,0])

print(np.sqrt((X**2).sum(axis=1)).round(2))
for K in [1,3]:
    knn = KNeighborsClassifier(n_neighbors=K).fit(X,y)
    print(K, knn.predict(x0))
```

3 Del C – Kapittel 2, anvendte oppgaver (2.4)

Datasettene ligger i ISLP-pakken og kan lastes med `load_data()`. Alternativt finnes CSV-filene på bokas nettsted, www.statlearning.com.

C8. (ISLP 2.4, oppgave 8) College-datasettet

Datasettet College inneholder 18 variabler for 777 amerikanske universiteter og høyskoler. Les inn dataene, sett institusjonsnavnet som indeks, og utforsk: numerisk sammendrag, spredningsplottmatrise for Top10perc, Apps og Enroll, boksplott av Outstate mot Private, en ny kva-

litativ variabel `Elite` basert på om mer enn 50 % av studentene kommer fra beste tidel i videregående, histogrammer med ulikt antall søyler, og til slutt en kort oppsummering av det du finner.

Løsningsforslag

```
import pandas as pd, numpy as np
import matplotlib.pyplot as plt

college = pd.read_csv('College.csv', index_col=0) # (a)-(b)
college.describe() # (c)

# (d) spredningsplottmatrise
pd.plotting.scatter_matrix(college[['Top10perc', 'Apps', 'Enroll']],
                           figsize=(8,8));

# (e) boksplott
college.boxplot('Outstate', by='Private', figsize=(6,5));

# (f) Elite-variabel
college['Elite'] = pd.cut(college['Top10perc'], [0,50,100],
                          labels=['No', 'Yes'])
print(college['Elite'].value_counts())
college.boxplot('Outstate', by='Elite', figsize=(6,5));

# (g) histogrammer
fig, axes = plt.subplots(2, 2, figsize=(10,8))
college.hist('Apps', ax=axes[0,0], bins=15)
college.hist('Enroll', ax=axes[0,1], bins=30)
college.hist('Outstate', ax=axes[1,0], bins=15)
college.hist('Expend', ax=axes[1,1], bins=30)
plt.tight_layout()
```

Merk om (f): Boka viser kodelinjen med intervallgrensene $[0, 0.5, 1]$, som passer dersom `Top10perc` var en andel. I datasettet er variabelen målt i prosent (0–100), så bruk $[0, 50, 100]$. Dette er en fin liten felle – den lærer studentene å sjekke skalaen på variablene sine før de stoler på koden.

Typiske funn (h): Omtrent 78 institusjoner er «elite». Private institusjoner har klart høyere `Outstate`-avgift enn offentlige, og elite-institusjonene ligger enda høyere. Fordelingene av `Apps`, `Enroll` og `Expend` er sterkt høyreskjeve med noen få svært store institusjoner – et argument for å vurdere logaritmisk transformasjon senere i kurset. `Apps` og `Enroll` henger tett sammen, som forventet.

C9. (ISLP 2.4, oppgave 9) Auto-datasettet

Bruk Auto-datasettet fra laben, og pass på at manglende verdier er fjernet.

- Hvilke prediktorer er kvantitative, og hvilke er kvalitative?
- Hva er variasjonsbredden til hver kvantitative prediktor?
- Hva er gjennomsnitt og standardavvik for hver kvantitative prediktor?
- Fjern observasjon 10 til og med 85. Hva blir variasjonsbredde, gjennomsnitt og standardavvik i det som er igjen?
- Utforsk prediktorene grafisk på hele datasettet. Lag noen plott som framhever sammenhenger, og kommenter.

- (f) Anta at vi ønsker å predikere mpg ut fra de andre variablene. Tyder plottene dine på at noen av dem er nyttige? Begrunn.

Løsningsforslag

```
import pandas as pd, numpy as np
import matplotlib.pyplot as plt
from ISLP import load_data

Auto = load_data('Auto').dropna()
Auto.shape # (392, 9)
Auto.dtypes

kvant = ['mpg', 'displacement', 'horsepower', 'weight', 'acceleration']
# 'cylinders', 'year' og 'origin' er tallkodet, men diskrete/kvalitative

# (b) variasjonsbredde
print(Auto[kvant].agg(['min', 'max']).T)

# (c) gjennomsnitt og standardavvik
print(Auto[kvant].agg(['mean', 'std']).round(2).T)

# (d) fjern observasjon 10-85 (indeks 9 til og med 84)
Auto_sub = Auto.drop(Auto.index[9:85])
print(Auto_sub[kvant].agg(['min', 'max', 'mean', 'std']).round(2).T)

# (e) grafisk utforskning
pd.plotting.scatter_matrix(Auto[kvant + ['year']], figsize=(11,11));

fig, ax = plt.subplots(figsize=(7,5))
ax.scatter(Auto['weight'], Auto['mpg'], alpha=0.6, color='#007396')
ax.set_xlabel('Vekt (lbs)'); ax.set_ylabel('mpg')

Auto.boxplot('mpg', by='cylinders', figsize=(7,5));
print(Auto[kvant].corr().round(2))
```

(a) Kvantitative: mpg, displacement, horsepower, weight, acceleration. Kvalitative: name (bilmodell) og origin (1 = USA, 2 = Europa, 3 = Japan – tallkoden har ingen naturlig rangering). cylinders og year er tallverdier med få distinkte nivåer og kan behandles begge veier; boka gjør cylinders kategorisk i laben.

(b)–(c) Med 392 observasjoner får du blant annet $\text{mpg} \in [9; 46,6]$ med gjennomsnitt omtrent 23,4 og standardavvik omtrent 7,8, og $\text{weight} \in [1613; 5140]$. Rapporter tabellen fra koden over.

(d) Når rad 10–85 fjernes står 316 observasjoner igjen. Gjennomsnittene flytter seg litt oppover for mpg og acceleration og nedover for weight og horsepower – de fjernede radene er tidlige, tunge biler. Variasjonsbreddene snevres inn. Poenget med deloppgaven er å se hvor følsomme enkle sammendragsmål er for hvilke observasjoner som er med.

(e)–(f) mpg har en tydelig *negativ* og klart *ikke-lineær* sammenheng med weight, horsepower og displacement (korrelasjoner rundt $-0,8$). Kurven er konveks: forbedringen i drivstofføkonomi avtar for de aller letteste bilene. year har positiv sammenheng med mpg – nyere biler er mer drivstoffgjerrige. Biler med færre sylindre kjører lenger per gallon. acceleration har svakest sammenheng.

Konklusjonen er at flere variabler er nyttige, men at de er sterkt innbyrdes korrelerte (vekt, hestekrefter og slagvolum måler mye av det samme). Det peker fram mot multikollinearitet og variabelseleksjon i kapittel 3 og 6, og mot ikke-lineære modeller i kapittel 7.

C10. (ISLP 2.4, oppgave 10) Boston-datasettet

Last inn `Boston`-datasettet fra ISLP-pakken. Hvor mange rader og kolonner er det, og hva representerer de? Lag parvise spredningsplott og kommenter sammenhengene. Er noen prediktorer knyttet til kriminalitetsraten per innbygger? Finnes det bydeler med spesielt høy kriminalitet, skattenivå eller elev-lærer-forhold? Hvor mange bydeler grenser til Charles River? Hva er medianen for elev-lærer-forholdet? Hvilken bydel har lavest median boligverdi, og hvordan ser den ut sammenlignet med resten? Hvor mange bydeler har i gjennomsnitt mer enn 7 rom per bolig, og hvor mange har mer enn 8?

Løsningsforslag

```
import pandas as pd, numpy as np
import matplotlib.pyplot as plt
from ISLP import load_data

Boston = load_data('Boston')
print(Boston.shape) # (506, 13)
print(Boston.columns.tolist())

print(Boston.corr()['crim'].sort_values()) # hva henger sammen med crim?
pd.plotting.scatter_matrix(Boston[['crim', 'age', 'dis', 'tax', 'medv']],
                           figsize=(10,10));

print((Boston['chas'] == 1).sum()) # antall langs Charles River
print(Boston['ptratio'].median()) # median elev-laerer-forhold

i = Boston['medv'].idxmin() # lavest median boligverdi
print(Boston.loc[i])
print(Boston.describe().loc[['min', '25%', '50%', '75%', 'max']].T)

print((Boston['rm'] > 7).sum(), (Boston['rm'] > 8).sum())
```

Svar: Datasettet har 506 rader og 13 kolonner. Hver rad er en bydel («census tract») i Boston-området, og kolonnene er kjennetegn ved bydelen – blant annet kriminalitetsrate (`crim`), andel gammel bebyggelse (`age`), skattenivå (`tax`), elev-lærer-forhold (`ptratio`), gjennomsnittlig antall rom (`rm`) og median boligverdi (`medv`).

- Kriminalitet henger positivt sammen med tilgjengelighet til motorvei (`rad`) og skattenivå (`tax`), og negativt med avstand til sysselsettingsentra (`dis`) og median boligverdi. Sammenhengene er tydelig ikke-lineære: de aller fleste bydelene har svært lav kriminalitet, mens noen få har ekstremt høye verdier.
- 35 bydeler grenser til Charles River (`chas` = 1).
- Medianen for `ptratio` er 19,05.
- Bydelen med lavest `medv` ligger på nedre grense (5,0) og kjennetegnes av høy kriminalitet, høy `lstat` og gammel bebyggelse – verdier langt ute i fordelingen sammenlignet med kvartilene for resten av datasettet.
- 64 bydeler har i gjennomsnitt mer enn 7 rom per bolig; 13 har mer enn 8. De siste har gjennomgående lav kriminalitet og lav `lstat`.

Merk: `medv` er sensurert ved 50 – flere bydeler ligger nøyaktig på 50,0. Det er verdt å legge merke til før man modellerer, og er et godt eksempel på at man bør se på dataene før man setter i gang.

Oppgavetekstene er gjengitt i forkortet og bearbeidet form.
Se ISLP avsnitt 2.4 for de fullstendige formuleringene.