

Oppgavesett 1

Kapittel 1 og 2: Statistisk læring, prediksjon og bias-varians

SOK-1305 Statistisk læring for økonomer

Handelshøgskolen ved UiT
Høsten 2026

Hvordan jobbe med dette settet. Oppgavene følger James, Witten, Hastie, Tibshirani & Taylor, *An Introduction to Statistical Learning with Applications in Python* (ISLP). Kapittel 1 har ingen oppgaver i boka, så del A er egne oppgaver til lesestoffet. Del B og C er oppgavene i avsnitt 2.4. Jobb gjerne to og to, og bruk Python aktivt fra første uke – det er kortere vei fra kode til forståelse enn du tror.

Forkunnskaper. Du trenger ikke ha hatt økonometri for å løse dette settet. Alt du trenger er grunnleggende statistikk: gjennomsnitt, standardavvik, varians og korrelasjon. Faguttrykk som dukker opp underveis blir forklart.

Noen ord vi bruker hele semesteret

Respons (Y) Det vi ønsker å si noe om – lønn, boligpris, om et lån misligholdes.

Prediktor (X) Variablene vi bruker som grunnlag – alder, areal, inntekt. Kalles også forklaringsvariabel eller egenskap (*feature*).

Modell ($\hat{f}$) Regelen som oversetter fra X til et anslag på Y .

Treningsdata Dataene modellen er bygget på.

Testdata Data modellen *ikke* har sett, og som vi bruker til å måle hvor god den er.

Fleksibilitet Hvor mange ulike former modellen kan anta. En rett linje er lite fleksibel; en kurve som kan bukte seg fritt er svært fleksibel.

Anbefalt utvalg:

- **Obligatorisk kjerne:** A1, A3, A4, B1, B2, B3, B7, C9
- **Anbefalt:** A2, B5, B6, C8
- **Ekstra / for de som vil grave dypere:** B4, C10

Innhold

1 Del A – Kapittel 1: Hva er statistisk læring?	2
A1. De tre eksempeldatasettene	2
A2. Prediksjon eller inferens?	2
A3. Kom i gang med Python og ISLP	2
A4. Hvorfor holder det ikke å måle treffsikkerhet på egne data?	2
2 Del B – Kapittel 2, konseptuelle oppgaver (2.4)	3
B1. (ISLP 2.4, oppgave 1) Fleksibel eller lite fleksibel metode?	3
B2. (ISLP 2.4, oppgave 2) Klassifikasjon eller regresjon? Inferens eller prediksjon?	3
B3. (ISLP 2.4, oppgave 3) Bias-varians-dekomposisjonen	3
B4. (ISLP 2.4, oppgave 4) Anvendelser i praksis	3
B5. (ISLP 2.4, oppgave 5) Fordeler og ulemper ved høy fleksibilitet	3

B6. (ISLP 2.4, oppgave 6) Parametrisk mot ikke-parametrisk	4
B7. (ISLP 2.4, oppgave 7) K -nærmeste naboer for hånd	4
3 Del C – Kapittel 2, anvendte oppgaver (2.4)	4
C8. (ISLP 2.4, oppgave 8) College-datasettet	4
C9. (ISLP 2.4, oppgave 9) Auto-datasettet	4
C10. (ISLP 2.4, oppgave 10) Boston-datasettet	5

1 Del A – Kapittel 1: Hva er statistisk læring?

Kapittel 1 i ISLP inneholder ingen oppgaver. Oppgavene under er laget til lesestoffet og til de tre datasettene som presenteres i kapitlet (Wage, Smarket og NCI60).

A1. De tre eksempeldatasettene

Kapittel 1 introduserer tre datasett. For hvert av dem: avgjør om problemet er *veiledet* (supervised) eller *ikke-veiledet* (unsupervised) læring, om det er et regresjons- eller klassifikasjonsproblem, og identifiser responsvariabel og prediktorer.

- (a) **Wage**: lønnsdata for menn i Midt-Atlanteren i USA.
- (b) **Smarket**: daglige prosentvise endringer i S&P 500 over fem år.
- (c) **NCI60**: genuttrykksmålinger for 64 kreftcellelinjer.

A2. Prediksjon eller inferens?

Skillet mellom prediksjon og inferens er sentralt i faget. Gi tre eksempler fra økonomi eller samfunnsliv der *prediksjon* er hovedmålet, og tre der *inferens* er hovedmålet. Forklar kort hvorfor, og hva slags data du ville trenge.

A3. Kom i gang med Python og ISLP

Installer Python-pakken ISLP, last inn **Wage**-datasettet, og lag et spredningsplott av lønn mot alder. Legg inn en glattet kurve eller en enkel gruppevis gjennomsnittslinje. Kommenter formen: hva skjer med lønn når alderen øker?

A4. Hvorfor holder det ikke å måle treffsikkerhet på egne data?

En student pucker femten gamle eksamensoppgaver med fasit, til hun klarer alle femten feilfritt. En annen bruker samme antall timer på å forstå prinsippene bak oppgavene, og gjør fortsatt noen småfeil på de femten oppgavene.

- (a) Hvem av dem tror du gjør det best på eksamen? Hvorfor?
- (b) Anta at en analytiker bygger en modell som predikerer boligpriser, og at modellen treffer nesten perfekt på de 200 boligsalgene den er bygget på. Hva er den store innvendingen mot å bruke dette som argument for at modellen er god?
- (c) Hva burde analytikeren gjort i stedet? Beskriv framgangsmåten med dine egne ord – du trenger ingen formler.
- (d) Nevn ett tilfelle der modellen faktisk *ville* vært god selv om den treffer perfekt på egne data, og ett der den helt sikkert ikke er det.

2 Del B – Kapittel 2, konseptuelle oppgaver (2.4)

B1. (ISLP 2.4, oppgave 1) Fleksibel eller lite fleksibel metode?

For hvert av tilfellene under: vil vi vanligvis forvente at en *fleksibel* metode gjør det bedre eller dårligere enn en *lite fleksibel* metode? Begrunn.

- (a) Utvalgsstørrelsen n er svært stor, antall prediktorer p er lite.
- (b) p er svært stor, n er liten.
- (c) Sammenhengen mellom prediktorene og responsen er sterkt ikke-lineær.
- (d) Variansen til feilledet, $\sigma^2 = \text{Var}(\epsilon)$, er svært høy.

B2. (ISLP 2.4, oppgave 2) Klassifikasjon eller regresjon? Inferens eller prediksjon?

For hvert scenario: er dette et klassifikasjons- eller regresjonsproblem, er vi mest interessert i inferens eller prediksjon, og hva er n og p ?

- (a) Vi samler data om de 500 største bedriftene i USA. For hver bedrift registreres overskudd, antall ansatte, bransje og direktørlønn. Vi ønsker å forstå hvilke faktorer som påvirker direktørlønna.
- (b) Vi vurderer å lansere et nytt produkt og vil vite om det blir en suksess eller fiasko. Vi samler data om 20 tilsvarende produkter som er lansert tidligere. For hvert produkt vet vi om det ble suksess eller fiasko, pris, markedsføringsbudsjett, konkurrentpris og ti andre variabler.
- (c) Vi vil predikere den prosentvise endringen i USD/euro-kursen ut fra ukentlige endringer i verdens aksjemarkeder. Vi samler ukedata for hele 2012: prosentvis endring i USD/euro, i det amerikanske, det britiske og det tyske markedet.

B3. (ISLP 2.4, oppgave 3) Bias–varians-dekomposisjonen

- (a) Skisser typiske kurver for kvadrert skjevhet (bias), varians, treningsfeil, testfeil og Bayes-feil (irreduksibel feil) i én og samme figur, når vi går fra lite fleksible til mer fleksible metoder. x -aksen er fleksibilitet, y -aksen er verdien til hver kurve. Det skal være fem kurver – merk dem.
- (b) Forklar hvorfor hver av de fem kurvene har den formen du har tegnet.

B4. (ISLP 2.4, oppgave 4) Anvendelser i praksis

- (a) Beskriv tre virkelige anvendelser der klassifikasjon er nyttig. Hva er responsen, hva er prediktorene, og er målet inferens eller prediksjon?
- (b) Samme spørsmål for tre anvendelser av regresjon.
- (c) Beskriv tre anvendelser der klyngeanalyse er nyttig.

B5. (ISLP 2.4, oppgave 5) Fordeler og ulemper ved høy fleksibilitet

Hva er fordelene og ulempene med en svært fleksibel tilnærming (sammenlignet med en mindre fleksibel) til regresjon eller klassifikasjon? Når kan en mer fleksibel metode være å foretrekke, og når er en mindre fleksibel bedre?

B6. (ISLP 2.4, oppgave 6) Parametrisk mot ikke-parametrisk

Beskriv forskjellen mellom en parametrisk og en ikke-parametrisk tilnærming til statistisk læring. Hva er fordelene med en parametrisk tilnærming, og hva er ulempene?

B7. (ISLP 2.4, oppgave 7) K -nærmeste naboer for hånd

Tabellen viser et treningssett med seks observasjoner, tre prediktorer og en kvalitativ respons.

Obs.	X_1	X_2	X_3	Y
1	0	3	0	Rød
2	2	0	0	Rød
3	0	1	3	Rød
4	0	1	2	Grønn
5	-1	0	1	Grønn
6	1	1	1	Rød

Vi ønsker å predikere Y i testpunktet $X_1 = X_2 = X_3 = 0$ ved hjelp av K -nærmeste naboer.

- (a) Beregn den euklidske avstanden fra hver observasjon til testpunktet.
- (b) Hva blir prediksjonen med $K = 1$? Hvorfor?
- (c) Hva blir prediksjonen med $K = 3$? Hvorfor?
- (d) Dersom Bayes-beslutningsgrensa i dette problemet er sterkt ikke-lineær, vil vi da forvente at den beste verdien av K er stor eller liten? Hvorfor?

3 Del C – Kapittel 2, anvendte oppgaver (2.4)

Datasettene ligger i ISLP-pakken og kan lastes med `load_data()`. Alternativt finnes CSV-filene på bokas nettsted, www.statlearning.com.

C8. (ISLP 2.4, oppgave 8) College-datasettet

Datasettet `College` inneholder 18 variabler for 777 amerikanske universiteter og høyskoler. Les inn dataene, sett institusjonsnavnet som indeks, og utforsk: numerisk sammendrag, spredningsplottmatrise for `Top10perc`, `Apps` og `Enroll`, boksplott av `Outstate` mot `Private`, en ny kvalitativ variabel `Elite` basert på om mer enn 50 % av studentene kommer fra beste tidel i videregående, histogrammer med ulikt antall søyler, og til slutt en kort oppsummering av det du finner.

C9. (ISLP 2.4, oppgave 9) Auto-datasettet

Bruk `Auto`-datasettet fra laben, og pass på at manglende verdier er fjernet.

- (a) Hvilke prediktorer er kvantitative, og hvilke er kvalitative?
- (b) Hva er variasjonsbredden til hver kvantitative prediktor?
- (c) Hva er gjennomsnitt og standardavvik for hver kvantitative prediktor?
- (d) Fjern observasjon 10 til og med 85. Hva blir variasjonsbredde, gjennomsnitt og standardavvik i det som er igjen?

- (e) Utforsk prediktorene grafisk på hele datasettet. Lag noen plott som framhever sammenhenger, og kommenter.
- (f) Anta at vi ønsker å predikere `mpg` ut fra de andre variablene. Tyder plottene dine på at noen av dem er nyttige? Begrunn.

C10. (ISLP 2.4, oppgave 10) Boston-datasettet

Last inn **Boston**-datasettet fra ISLP-pakken. Hvor mange rader og kolonner er det, og hva representerer de? Lag parvise spredningsplott og kommenter sammenhengene. Er noen prediktorer knyttet til kriminalitetsraten per innbygger? Finnes det bydeler med spesielt høy kriminalitet, skattenivå eller elev–lærer-forhold? Hvor mange bydeler grenser til Charles River? Hva er medianen for elev–lærer-forholdet? Hvilken bydel har lavest median boligverdi, og hvordan ser den ut sammenlignet med resten? Hvor mange bydeler har i gjennomsnitt mer enn 7 rom per bolig, og hvor mange har mer enn 8?

Oppgavetekstene er gjengitt i forkortet og bearbeidet form.
Se ISLP avsnitt 2.4 for de fullstendige formuleringene.