

Oppgavesett 2

Kapittel 3 og 4: Lineær regresjon og klassifikasjon

SOK-1305 Statistisk læring for økonomer

Handelshøgskolen ved UiT
Høsten 2026

Hvordan jobbe med dette settet. Oppgavene dekker kapittel 3 og de første avsnittene i kapittel 4 i ISLP, og forutsetter at du har med deg begrepene fra kapittel 1 og 2. Noen av oppgavene er hentet fra boka (avsnitt 3.7 og 4.8), resten er laget til kurset. Det meste her skal regnes for hånd. Det er et poeng: formlene sitter først når du har brukt dem. Ta fram kalkulator og penn før du tar fram Python. Bruk deretter gjerne Python til å kontrollere svarene – flere av oppgavene har korte kodesnutter i løsningsforslaget.

Ordliste – symboler du trenger

RSS	Residualkvadratsum, $\sum_i (y_i - \hat{y}_i)^2$. Det modellen <i>ikke</i> klarer å forklare.
TSS	Total kvadratsum, $\sum_i (y_i - \bar{y})^2$. All variasjon i y før vi modellerer.
R^2	$1 - \text{RSS}/\text{TSS}$. Andelen av variasjonen i y modellen forklarer.
RSE	Residualstandardfeil, $\sqrt{\text{RSS}/(n - p - 1)}$. Anslag på σ , altså på typisk avvik fra regresjonslinja.
$\text{SE}(\hat{\beta}_j)$	Standardfeil: hvor mye $\hat{\beta}_j$ ville variert om vi trakk et nytt utvalg.
t -observator	$\hat{\beta}_j/\text{SE}(\hat{\beta}_j)$. Hvor mange standardfeil estimatet ligger fra null.
Dummyvariabel	0/1-variabel som koder en kvalitativ egenskap.
Interaksjonsledd	Produktet $X_1 X_2$ tatt inn som egen prediktor.
Odds	$p/(1 - p)$. Sannsynlighet omregnet til «forhold».
Logit	$\log(p/(1 - p))$, altså log-odds.
Feilrate	Andel observasjoner klassifisert feil.

Anbefalt utvalg:

- **Obligatorisk kjerne:** A1, A2, A4, B1, B2, B4, C1, C2, C3, D2, D3, E1, E3, E4
- **Anbefalt:** A3, A5, B3, B5, C4, D1, D4, E2, E5
- **Ekstra:** B6, C5, D5, E6

Del E bygger på avsnitt 4.3.1–4.3.2. Har vi bare så vidt rukket den logistiske modellen, kan du vente med E5 og E6 til etter neste forelesning.

Innhold

1 Del A – Enkel lineær regresjon (3.1)	1
A1. Minste kvadraters metode for hånd	1
A2. Normallikningene, og hvorfor linja går gjennom $(\bar{x}, \bar{y})$	3
A3. Vis at R^2 er kvadrert korrelasjon	4
A4. Advertising: les og gjenskap tabellen	4
A5. Konfidensintervall eller prediksjonsintervall?	5

2	Del B – Multippel regresjon (3.2–3.3)	6
	B1. Hva tester p -verdiene?	6
	B2. Interaksjon og fortegn	7
	B3. Dummyvariabler med tre nivåer	7
	B4. R^2 , justert R^2 og F	8
	B5. Synergi i Advertising	9
	B6. Kollinearitet i praksis	10
3	Del C – Trening, test og bias–varians	11
	C1. Lineær eller kubisk modell?	11
	C2. Overtilpasning du kan regne på	12
	C3. Utled bias–varians-dekomposisjonen	12
	C4. Bias–varians med tall	13
	C5. Når testsettet lyver	14
4	Del D – Klassifikasjon (4.1–4.2)	15
	D1. Feilrate og den late klassifikatoren	15
	D2. Hvorfor ikke lineær regresjon?	15
	D3. Den lineære sannsynlighetsmodellen på Default	16
	D4. KNN og dimensjonens forbannelse	17
	D5. Bayes-klassifikatoren og feilgulvet	18
5	Del E – Den logistiske modellen (4.3.1–4.3.2)	18
	E1. Odds, sannsynlighet og log-odds	18
	E2. Fra sannsynlighet til odds til logit	19
	E3. Sannsynligheten for A	20
	E4. Default: koeffisienten er <i>ikke</i> en endring i sannsynlighet	20
	E5. Studenter, saldo og et fortegn som snur	21
	E6. Rimelighet (likelihood) med tre kunder	22

1 Del A – Enkel lineær regresjon (3.1)

A1. Minste kvadraters metode for hånd

Vi har fem observasjoner:

x_i	1	2	3	4	5
y_i	2	4	5	4	5

- Regn ut $\bar{x}$, $\bar{y}$, $S_{xy} = \sum_i (x_i - \bar{x})(y_i - \bar{y})$ og $S_{xx} = \sum_i (x_i - \bar{x})^2$, og finn $\hat{\beta}_1$ og $\hat{\beta}_0$.
- Regn ut de fem tilpassede verdiene $\hat{y}_i$ og de fem residualene $e_i = y_i - \hat{y}_i$. Kontroller at $\sum_i e_i = 0$ og at $\sum_i x_i e_i = 0$.
- Regn ut RSS, TSS, R^2 og RSE.
- Regn ut $\text{SE}(\hat{\beta}_1) = \text{RSE}/\sqrt{S_{xx}}$ og t -observatoren for $H_0 : \beta_1 = 0$. Med $n - 2 = 3$ frihetsgrader er den kritiske t -verdien på 5 %-nivå 3,18. Hva konkluderer du?
- Regn ut korrelasjonen mellom x og y , og kontroller at $\text{Cor}(x, y)^2 = R^2$.

Løsningsforslag

(a) $\bar{x} = 3$, $\bar{y} = 4$. Sett opp avvikene:

x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$
1	2	-2	-2	4	4
2	4	-1	0	0	1
3	5	0	1	0	0
4	4	1	0	0	1
5	5	2	1	2	4
				$S_{xy} = 6$	$S_{xx} = 10$

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{6}{10} = 0,6, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 4 - 0,6 \cdot 3 = 2,2.$$

Linja er $\hat{y} = 2,2 + 0,6x$.

(b) $\hat{y} = (2,8; 3,4; 4,0; 4,6; 5,2)$ og $e = (-0,8; 0,6; 1,0; -0,6; -0,2)$.

Sjekk: $\sum e_i = -0,8 + 0,6 + 1,0 - 0,6 - 0,2 = 0$. ✓

$\sum x_i e_i = -0,8 + 1,2 + 3,0 - 2,4 - 1,0 = 0$. ✓

Dette er ikke tilfeldigheter – det er nettopp de to normallikningene som definerer minste kvadraters løsning. Se oppgave A2.

(c)

$$\text{RSS} = 0,64 + 0,36 + 1,00 + 0,36 + 0,04 = 2,40, \quad \text{TSS} = 4 + 0 + 1 + 0 + 1 = 6,00.$$

$$R^2 = 1 - \frac{2,40}{6,00} = 0,60, \quad \text{RSE} = \sqrt{\frac{2,40}{5-2}} = \sqrt{0,80} = 0,894.$$

Tolkning: modellen forklarer 60 % av variasjonen i y , og typiske avvik fra linja er omtrent 0,89 enheter.

(d)

$$\text{SE}(\hat{\beta}_1) = \frac{0,894}{\sqrt{10}} = 0,283, \quad t = \frac{0,6}{0,283} = 2,12.$$

Siden $2,12 < 3,18$ forkaster vi ikke H_0 . Med bare fem observasjoner er usikkerheten så stor at vi ikke kan utelukke at den sanne hellingen er null – selv om $R^2 = 0,60$ ser høyt ut. Et 95 %-konfidensintervall blir $0,6 \pm 3,18 \cdot 0,283 = [-0,30; 1,50]$, altså et intervall som inneholder null. **Poeng:** høy R^2 og «signifikant sammenheng» er to forskjellige ting.

(e) $S_{yy} = \text{TSS} = 6$, så

$$\text{Cor}(x, y) = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}} = \frac{6}{\sqrt{10 \cdot 6}} = \frac{6}{7,746} = 0,7746, \quad 0,7746^2 = 0,600 = R^2. \checkmark$$

```
import numpy as np, statsmodels.api as sm
x = np.array([1,2,3,4,5.]); y = np.array([2,4,5,4,5.])
m = sm.OLS(y, sm.add_constant(x)).fit()
print(m.params, m.bse, m.tvalues, m.rsquared, np.sqrt(m.mse_resid))
```

A2. Normallikningene, og hvorfor linja går gjennom $(\bar{x}, \bar{y})$

Utvidet versjon av ISLP 3.7, oppgave 6.

Utgangspunktet er

$$\text{RSS}(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2.$$

- (a) Deriver RSS med hensyn på β_0 og sett den deriverte lik null. Vis at betingelsen kan skrives $\sum_i e_i = 0$, der $e_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$.
- (b) Deriver RSS med hensyn på β_1 og sett den deriverte lik null. Vis at betingelsen kan skrives $\sum_i x_i e_i = 0$.
- (c) Bruk (a) til å vise at minste kvadraters linje alltid går gjennom punktet $(\bar{x}, \bar{y})$.
- (d) Sett $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ inn i (b) og vis at $\hat{\beta}_1 = S_{xy}/S_{xx}$.

Løsningsforslag

(a)

$$\frac{\partial \text{RSS}}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0 \iff \sum_{i=1}^n e_i = 0.$$

Residualene summerer seg altså alltid til null når modellen har konstantledd.

(b)

$$\frac{\partial \text{RSS}}{\partial \beta_1} = -2 \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i) = 0 \iff \sum_{i=1}^n x_i e_i = 0.$$

Residualene er «ortogonale» på prediktoren: det er ingen lineær sammenheng igjen mellom x og det modellen bommer på.

(c) Fra (a):

$$\sum_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \iff \sum_i y_i = n\hat{\beta}_0 + \hat{\beta}_1 \sum_i x_i.$$

Del på n :

$$\bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}.$$

Dette sier nøyaktig at punktet $(\bar{x}, \bar{y})$ ligger på linja $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$. Sjekk gjerne mot A1: $2,2 + 0,6 \cdot 3 = 4 = \bar{y}$. ✓

(d) Sett inn $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ i (b):

$$\sum_i x_i (y_i - \bar{y} + \hat{\beta}_1 \bar{x} - \hat{\beta}_1 x_i) = 0 \iff \sum_i x_i (y_i - \bar{y}) = \hat{\beta}_1 \sum_i x_i (x_i - \bar{x}).$$

Nå bruker vi at $\sum_i \bar{x}(y_i - \bar{y}) = 0$ og $\sum_i \bar{x}(x_i - \bar{x}) = 0$, slik at vi kan bytte ut x_i med $(x_i - \bar{x})$ på begge sider:

$$\sum_i (x_i - \bar{x})(y_i - \bar{y}) = \hat{\beta}_1 \sum_i (x_i - \bar{x})^2 \iff \hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}.$$

Dette er formel (3.4) i boka.

A3. Vis at R^2 er kvadrert korrelasjon

ISLP 3.7, oppgave 7.

I enkel lineær regresjon av Y på X er R^2 lik kvadratet av korrelasjonen mellom X og Y . Vis dette. Du kan for enkelhets skyld anta at $\bar{x} = \bar{y} = 0$.

Hint: Med sentrerte variabler er $\hat{\beta}_0 = 0$ og $\hat{\beta}_1 = \sum_i x_i y_i / \sum_i x_i^2$. Skriv ut RSS og forenkler.

Løsningsforslag

Med $\bar{x} = \bar{y} = 0$ gir A2(c) at $\hat{\beta}_0 = 0$, og $\hat{\beta}_1 = \sum_i x_i y_i / \sum_i x_i^2$. Skriv $TSS = \sum_i y_i^2$. Da er

$$\begin{aligned} RSS &= \sum_i (y_i - \hat{\beta}_1 x_i)^2 = \sum_i y_i^2 - 2\hat{\beta}_1 \sum_i x_i y_i + \hat{\beta}_1^2 \sum_i x_i^2 \\ &= \sum_i y_i^2 - 2 \frac{\sum_i x_i y_i}{\sum_i x_i^2} \sum_i x_i y_i + \left(\frac{\sum_i x_i y_i}{\sum_i x_i^2} \right)^2 \sum_i x_i^2 \\ &= \sum_i y_i^2 - \frac{(\sum_i x_i y_i)^2}{\sum_i x_i^2}. \end{aligned}$$

Legg merke til at de to siste leddene i midten er like store, med motsatt fortegn på det ene – derfor står bare ett igjen. Da får vi

$$R^2 = \frac{TSS - RSS}{TSS} = \frac{(\sum_i x_i y_i)^2 / \sum_i x_i^2}{\sum_i y_i^2} = \frac{(\sum_i x_i y_i)^2}{\sum_i x_i^2 \sum_i y_i^2} = (\text{Cor}(X, Y))^2,$$

siden korrelasjonen med sentrerte variabler er $\text{Cor}(X, Y) = \sum_i x_i y_i / \sqrt{\sum_i x_i^2 \sum_i y_i^2}$.

Merk: Resultatet gjelder *bare* i enkel regresjon. I multippel regresjon er R^2 lik kvadratet av korrelasjonen mellom y og $\hat{y}$ – ikke mellom y og en enkelt prediktor.

A4. Advertising: les og gjenskap tabellen

Tabell 3.1 og 3.2 i ISLP viser resultatet av å regressere **sales** (i tusen enheter) på TV (annonsebudsjett i tusen dollar), med $n = 200$ markeder:

	Koeffisient	Std.feil	t	RSE	3,26
Konstantledd	7,0325	0,4578	?	R^2	0,612
TV	0,0475	0,0027	?	F	312,1

- Regn ut de to t -observatorene.
- Regn ut tilnærmede 95 %-konfidensintervaller ($\hat{\beta} \pm 2 \text{SE}$) for begge koeffisientene. Hva betyr intervallet for TV-koeffisienten i klartekst, med enheter?
- Bruk RSE og n til å regne ut RSS. Bruk deretter R^2 til å regne ut TSS.
- Regn ut $F = \frac{(TSS - RSS)/1}{RSS/(n - 2)}$ og sammenlign med tabellverdien.
- Gjennomsnittlig salg er omtrent 14 (tusen enheter). Hvor stor er den typiske prediksjonsfeilen i prosent av gjennomsnittet?

Løsningsforslag

(a) $t_0 = 7,0325/0,4578 = 15,36$ og $t_1 = 0,0475/0,0027 = 17,59$. Boka oppgir 17,67; forskjellen skyldes bare at standardfeilen er avrundet til fire desimaler i tabellen. Begge er så store at p -verdiene er tilnærmet null.

(b)

$$\beta_0 : 7,0325 \pm 2 \cdot 0,4578 = [6,12; 7,95], \quad \beta_1 : 0,0475 \pm 2 \cdot 0,0027 = [0,042; 0,053].$$

Klartekst: øker vi TV-budsjettet med \$1000, øker salget i gjennomsnitt med mellom 42 og

53 enheter. (Husk enhetene: x er i tusen dollar og y i tusen enheter, så 0,0475 tusen enheter = 47,5 enheter.)

(c) Fra $RSE = \sqrt{RSS/(n-2)}$:

$$RSS = RSE^2 (n-2) = 3,26^2 \cdot 198 = 10,628 \cdot 198 = 2104,3.$$

Fra $R^2 = 1 - RSS/TSS$:

$$TSS = \frac{RSS}{1 - R^2} = \frac{2104,3}{0,388} = 5423,4.$$

(d)

$$F = \frac{(5423,4 - 2104,3)/1}{2104,3/198} = \frac{3319,1}{10,628} = 312,3,$$

mot 312,1 i tabellen – avviket skyldes avrundingen i (c). Legg også merke til at $\sqrt{312,3} = 17,67 = t_1$. I enkel regresjon er F nøyaktig kvadratet av t -observatoren for hellingen, så de to testene er samme test.

(e) $3,26/14,0 = 23,3\%$. Det er en ganske stor typisk bom, og et nyttig korrektiv til $R^2 = 0,61$, som isolert sett ser bra ut. RSE og R^2 svarer på to ulike spørsmål: hvor mye bommer vi i enheter, og hvor stor andel av variasjonen forklarer vi.

A5. Konfidensintervall eller prediksjonsintervall?

Vi regressere `mpg` på `horsepower` i `Auto`-datasettet ($n = 392$) og får $\hat{y} = 39,936 - 0,1578x$ med $RSE = 4,906$. For $x = 98$ hestekrefter blir $\hat{y} = 24,47$, og programmet rapporterer

95 % konfidensintervall	[23,97; 24,96]
95 % prediksjonsintervall	[14,81; 34,12]

- Forklar med ord hva hvert av de to intervallene sier noe om.
- Halvbredden i konfidensintervallet er 0,494. Med $t_{0,975} \approx 1,966$ gir dette $SE(\hat{y}) = 0,251$. Kontroller at prediksjonsintervallets halvbredde er omtrent $t \cdot \sqrt{SE(\hat{y})^2 + RSE^2}$.
- Hvilket av de to leddene under rottegnet dominerer? Hva forteller det deg om hva som skjer med de to intervallene når n blir veldig stor?

Løsningsforslag

(a) Konfidensintervallet gjelder *gjennomsnittet* $f(98)$: hvor ligger gjennomsnittlig `mpg` for alle biler med 98 hestekrefter? Prediksjonsintervallet gjelder *én bestemt bil* med 98 hestekrefter, og må i tillegg ta høyde for det individuelle feilleddet ϵ .

(b)

$$1,966 \cdot \sqrt{0,251^2 + 4,906^2} = 1,966 \cdot \sqrt{0,063 + 24,07} = 1,966 \cdot 4,912 = 9,66,$$

og $24,47 \pm 9,66 = [14,81; 34,13]$. ✓

(c) $RSE^2 = 24,07$ dominerer fullstendig over $SE(\hat{y})^2 = 0,063$. Når n vokser, går $SE(\hat{y})$ mot null – vi blir sikrere og sikrere på hvor gjennomsnittslinja ligger – så konfidensintervallet krymper mot et punkt. Prediksjonsintervallet krymper derimot *ikke* mot null: det konvergerer mot $\pm 1,96\sigma$. Dette er den irreducible feilen fra kapittel 2 i praksis. Uansett hvor mye data vi samler, kan vi ikke forutsi enkeltbiler bedre enn støyen tillater.

2 Del B – Multippel regresjon (3.2–3.3)

B1. Hva tester p -verdiene?

ISLP 3.7, oppgave 1.

Tabell 3.4 i boka viser multippel regresjon av **sales** på TV, radio og newspaper:

	Koeffisient	Std.feil	t	p -verdi
Konstantledd	2,939	0,3119	9,42	$< 0,0001$
TV	0,046	0,0014	32,81	$< 0,0001$
radio	0,189	0,0086	21,89	$< 0,0001$
newspaper	-0,001	0,0059	-0,18	0,8599

- (a) Skriv ned nullhypotesen som hver av de fire p -verdiene hører til.
- (b) Hvilke konklusjoner kan du trekke? Svar i form av salg, TV, radio og aviser – ikke i form av β -er.
- (c) I *enkel* regresjon av **sales** på bare **newspaper** er koeffisienten positiv og klart signifikant. Korrelasjonen mellom **radio** og **newspaper** er 0,354. Forklar hvordan disse to tingene henger sammen.

Løsningsforslag

(a) For hver rad j er nullhypotesen $H_0 : \beta_j = 0$ gitt at de andre to prediktorene er med i modellen. For eksempel: «når vi holder TV- og radiobudsjettet fast, har avisbudsjettet ingen sammenheng med salget.» Det siste leddet er avgjørende – det er en annen hypotese enn den vi tester i enkel regresjon.

(b) TV og radio har en klar sammenheng med salg. For avisannonsering finner vi ingen sammenheng når vi allerede har tatt hensyn til TV- og radiobudsjettet: hvis to markeder bruker like mye på TV og radio, ser det ikke ut til å bety noe for salget at det ene bruker mer på aviser.

(c) Markeder som annonserer mye i aviser, annonserer også mye på radio (korrelasjon 0,354). Radio virker på salget. I en enkel regresjon der aviser er eneste prediktor, får aviser derfor «æren» for radioeffekten – avisbudsjettet fungerer som en stedfortreder for radiobudsjettet. Når radio kommer inn i modellen, forsvinner avisenes tilsynelatende effekt.

Boka bruker et poengtert bilde: en regresjon av antall haiangrep på iskremsalg gir positiv sammenheng, men det er temperaturen som driver begge. **Lærdom:** en koeffisient i multippel regresjon betyr noe annet enn den samme koeffisienten i enkel regresjon, og hvilken av dem du vil ha avhenger av hva du spør om.

B2. Interaksjon og fortegn

ISLP 3.7, oppgave 3.

Vi har fem prediktorer: X_1 = karaktersnitt (GPA, skala 0–4), X_2 = IQ, X_3 = nivå (1 for fullført bachelor, 0 for bare videregående), $X_4 = X_1X_2$ og $X_5 = X_1X_3$. Responsen er startlønn (i tusen dollar). Minste kvadraters metode gir

$$\hat{\beta}_0 = 50, \quad \hat{\beta}_1 = 20, \quad \hat{\beta}_2 = 0,07, \quad \hat{\beta}_3 = 35, \quad \hat{\beta}_4 = 0,01, \quad \hat{\beta}_5 = -10.$$

- (a) Hvilket utsagn er riktig, og hvorfor?
 - (i) For gitt IQ og GPA tjener de med bare videregående mer i gjennomsnitt.

- (ii) For gitt IQ og GPA tjener de med bachelor mer i gjennomsnitt.
 - (iii) For gitt IQ og GPA tjener de med bare videregående mer i gjennomsnitt, forutsatt at GPA er høy nok.
 - (iv) For gitt IQ og GPA tjener de med bachelor mer i gjennomsnitt, forutsatt at GPA er høy nok.
- (b) Predikér lønna til en person med bachelor, IQ 110 og GPA 4,0.
- (c) Riktig eller galt: «Siden koeffisienten på $\text{GPA} \times \text{IQ}$ er svært liten (0,01), er det lite som tyder på en interaksjonseffekt.» Begrunn.

Løsningsforslag

- (a) Skriv opp modellen og samle leddene som inneholder X_3 :

$$\hat{y} = 50 + 20 X_1 + 0,07 X_2 + 0,01 X_1 X_2 + \underbrace{(35 - 10 X_1)}_{\text{effekten av bachelor}} X_3.$$

Differansen mellom bachelor og videregående, for gitt GPA og IQ, er altså $35 - 10 \cdot \text{GPA}$. Denne er

$$35 - 10 \text{ GPA} < 0 \iff \text{GPA} > 3,5.$$

Så: for GPA over 3,5 tjener de med bare videregående mest. Riktig svar er (iii).

- (b) Sett inn $X_1 = 4,0$, $X_2 = 110$, $X_3 = 1$:

$$\begin{aligned} \hat{y} &= 50 + 20 \cdot 4,0 + 0,07 \cdot 110 + 35 \cdot 1 + 0,01 \cdot 4,0 \cdot 110 - 10 \cdot 4,0 \cdot 1 \\ &= 50 + 80 + 7,7 + 35 + 4,4 - 40 = 137,1, \end{aligned}$$

altså omtrent \$137 100.

(c) **Galt.** Størrelsen på en koeffisient sier ingenting alene – den avhenger av skalaen til variabelen. IQ ligger rundt 100 og GPA rundt 3, så produktet $X_1 X_2$ ligger rundt 300. Bidraget fra interaksjonsleddet er da $0,01 \cdot 300 = 3$ tusen dollar, som ikke er ubetydelig. For å avgjøre om det er «bevis for» en interaksjonseffekt må vi se på t -observatoren $\hat{\beta}_4 / \text{SE}(\hat{\beta}_4)$ eller p -verdien, ikke på $\hat{\beta}_4$ i seg selv.

B3. Dummyvariabler med tre nivåer

En bedrift har avdelinger i tre landsdeler. Vi regresserer månedslønn (i tusen kroner) på ansiennitet (år) og landsdel, med *sør* som referansekategori:

$$\hat{y} = 380 + 12 \cdot \text{ansiennitet} - 25 \cdot D_{\text{midt}} - 40 \cdot D_{\text{nord}}.$$

- (a) Regn ut predikert lønn for en ansatt med 10 års ansiennitet i hver av de tre landsdelene.
- (b) Hva er den estimerte lønnsforskjellen mellom nord og midt, for gitt ansiennitet?
- (c) Anta at vi i stedet velger *nord* som referansekategori. Skriv opp den nye likningen med koeffisienter, og kontroller at de predikerte lønningene i (a) er uendret.
- (d) Hvorfor lager vi to dummyvariabler og ikke tre, når det er tre landsdeler?

Løsningsforslag

- (a) Med ansiennitet = 10 er $380 + 120 = 500$ grunnlaget:

$$\text{sør} = 500, \quad \text{midt} = 500 - 25 = 475, \quad \text{nord} = 500 - 40 = 460.$$

(b) $-40 - (-25) = -15$. Nord ligger 15 tusen under midt. Legg merke til at dette er en *differanse mellom to koeffisienter*, ikke en koeffisient i seg selv.

(c) Med nord som referanse blir konstantleddet lønna i nord:

$$\hat{y} = 340 + 12 \cdot \text{ansiennitet} + 40 \cdot D_{\text{sør}} + 15 \cdot D_{\text{midt}}.$$

Kontroll med 10 år: nord = $340 + 120 = 460$ ✓, sør = $460 + 40 = 500$ ✓, midt = $460 + 15 = 475$ ✓.

Poenget: valget av referansekategori endrer hvordan koeffisientene skal *tolkes*, men ikke modellens prediksjoner, ikke RSS og ikke R^2 . Det er samme modell skrevet på to måter.

(d) Tre dummyvariabler pluss konstantledd ville vært lineært avhengige: de tre dummyene summerer seg til 1 i hver rad, akkurat som konstantleddet. Da finnes det uendelig mange koeffisientsett som gir nøyaktig samme prediksjoner, og minste kvadraters løsning er ikke entydig. Med K nivåer bruker vi derfor $K - 1$ dummyer.

B4. R^2 , justert R^2 og F

Vi har $n = 100$ observasjoner og $\text{TSS} = 1000$. Tre nestede modeller gir:

Modell	Antall prediktorer p	RSS
$M_1: X_1$	1	500
$M_2: X_1, X_2$	2	460
$M_3: X_1, X_2, X_3$	3	458

(a) Regn ut R^2 for alle tre modellene.

(b) Regn ut justert $R^2 = 1 - \frac{\text{RSS}/(n-p-1)}{\text{TSS}/(n-1)}$ for alle tre. Hvilken modell foretrekker dette kriteriet?

(c) Forklar hvorfor RSS aldri kan *øke* når vi legger til en prediktor, og dermed hvorfor R^2 aldri kan synke.

(d) Test om X_3 bidrar, med $F = \frac{(\text{RSS}_2 - \text{RSS}_3)/1}{\text{RSS}_3/(n-4)}$. Kritisk verdi på 5 %-nivå er omtrent 3,94. Hva konkluderer du?

(e) Gjør det samme for X_2 (bruk RSS_1 , RSS_2 og $n - 3$).

Løsningsforslag

(a) $R_1^2 = 1 - 500/1000 = 0,500$, $R_2^2 = 0,540$, $R_3^2 = 0,542$. Den stiger, som den alltid gjør.

(b) $\text{TSS}/(n-1) = 1000/99 = 10,101$.

$$M_1: 1 - \frac{500/98}{10,101} = 1 - \frac{5,102}{10,101} = 0,495$$

$$M_2: 1 - \frac{460/97}{10,101} = 1 - \frac{4,742}{10,101} = 0,531$$

$$M_3: 1 - \frac{458/96}{10,101} = 1 - \frac{4,771}{10,101} = 0,528$$

Justert R^2 er høyest for M_2 . Kriteriet «straffer» den tredje prediktoren fordi den knapt reduserer RSS, mens frihetsgradene går ned.

(c) M_2 inneholder M_1 som spesialtilfelle: sett $\beta_2 = 0$, så er de identiske. Minste kvadraters metode i M_2 minimerer RSS over et *større* sett av mulige koeffisienter, og minimum over en større mengde kan aldri bli høyere. I verste fall velger metoden $\hat{\beta}_2 = 0$ og gir samme RSS. Siden TSS er den samme uansett modell, kan $R^2 = 1 - \text{RSS}/\text{TSS}$ da aldri synke. Derfor er R^2 ubrukelig til å velge mellom modeller med ulikt antall prediktorer.

(d)

$$F = \frac{(460 - 458)/1}{458/96} = \frac{2}{4,771} = 0,42.$$

Langt under 3,94: vi forkaster ikke $H_0 : \beta_3 = 0$. Samme konklusjon som justert R^2 . (Merk at $t = \sqrt{F} = 0,65$ – det er t -observatoren X_3 ville fått i utskriften fra M_3 .)

(e)

$$F = \frac{(500 - 460)/1}{460/97} = \frac{40}{4,742} = 8,44,$$

godt over kritisk verdi ($\approx 3,94$), $p \approx 0,005$. X_2 bidrar.

B5. Synergi i Advertising

Tabell 3.9 i boka viser modellen med interaksjon mellom TV og radio:

$$\widehat{\text{sales}} = 6,7502 + 0,0191 \text{ TV} + 0,0289 \text{ radio} + 0,0011 (\text{TV} \times \text{radio}).$$

- Skriv om modellen slik at TV står utenfor en parentes, og les av den «effektive hellingen» for TV.
- Regn ut denne hellingen når **radio** er 0, 20 og 50. Tolk tallene i antall solgte enheter per \$1000 økt TV-budsjett.
- Modellen uten interaksjon har $R^2 = 0,897$; med interaksjon er $R^2 = 0,968$. Regn ut hvor stor andel av den *gjenstående* variasjonen interaksjonsleddet forklarer.
- Anta at p -verdien for interaksjonsleddet hadde vært liten, men at p -verdien for **radio** alene hadde vært stor. Ville du fjernet **radio** fra modellen?

Løsningsforslag

(a)

$$\widehat{\text{sales}} = 6,7502 + (0,0191 + 0,0011 \text{ radio})\text{TV} + 0,0289 \text{ radio}.$$

Hellingen for TV er $0,0191 + 0,0011 \text{ radio}$ – den avhenger av radiobudsjettet.

(b)

$$\text{radio} = 0 : 0,0191; \quad \text{radio} = 20 : 0,0411; \quad \text{radio} = 50 : 0,0741.$$

I enheter: \$1000 ekstra på TV gir omtrent 19 flere solgte enheter hvis vi ikke bruker noe på radio, men omtrent 74 flere hvis radiobudsjettet er \$50 000. Å bruke penger på begge medier gir mer enn summen av delene – det er synergien.

(c) Uforklart andel før interaksjonen: $1 - 0,897 = 0,103$. Etter: $1 - 0,968 = 0,032$. Andelen av det gjenstående som forklares:

$$\frac{0,968 - 0,897}{1 - 0,897} = \frac{0,071}{0,103} = 0,69,$$

altså 69 %. Et hopp fra 0,897 til 0,968 høres lite ut, men er det ikke.

(d) Nei. Hierarkiprinsippet: er interaksjonsleddet med i modellen, skal hovedeffektene være med, uansett p -verdi. Grunnen er at modellen ellers blir avhengig av hvor nullpunktet

på skalaen tilfeldigvis ligger – flytter du målestokken for TV, endrer du hva «radio alene» betyr.

B6. Kollinearitet i praksis

Tabell 3.11 i boka viser to regresjoner på **Credit**-datasettet, begge med **balance** som respons:

	Variabel	Koeffisient	Std.feil	t
Modell 1	age	-2,292	0,672	?
	limit	0,173	0,005	?
Modell 2	rating	2,202	0,952	?
	limit	0,025	0,064	?

- (a) Regn ut de fire t -observatorene.
- (b) Standardfeilen til **limit** er 12–13 ganger større i modell 2. Hva er årsaken, og hva gjør det med konklusjonen om **limit**?
- (c) Betyr modell 2 at kredittgrensa ikke har noe med saldoen å gjøre?
- (d) For hver av situasjonene under: hvilket av problemene i avsnitt 3.3.3 er det, og hva ville du gjort?
 - (i) Residualplottet mot $\hat{y}$ viser en tydelig U-form.
 - (ii) Residualene vifter ut som en trakt: små for lave $\hat{y}$, store for høye.
 - (iii) Én observasjon har en x -verdi langt utenfor de andre, og linja endrer seg mye om vi fjerner den.
 - (iv) Dataene er månedlige tall for samme bedrift over ti år, og residualene ligner seg selv fra måned til måned.

Løsningsforslag

(a) Modell 1: $t_{\text{age}} = -2,292/0,672 = -3,41$ og $t_{\text{limit}} = 0,173/0,005 = 34,6$. Modell 2: $t_{\text{rating}} = 2,202/0,952 = 2,31$ og $t_{\text{limit}} = 0,025/0,064 = 0,39$.

(b) **rating** og **limit** måler nesten det samme (korrelasjon nær 1). Da finnes det mange kombinasjoner av de to koeffisientene som gir omtrent samme RSS, og minste kvadraters metode klarer ikke å skille dem. Standardfeilen blåses opp, t -observatoren faller, og **limit** går fra å være klart signifikant til å se irrelevant ut.

(c) Nei. Kollinearitet ødelegger vår evne til å tildele effekten til den *ene eller den andre* av to nesten identiske variabler. Modellens prediksjoner er fortsatt gode. Løsningen er enten å fjerne den ene variabelen, eller å slå dem sammen til ett mål.

(d)

- (i) **Ikke-linearitet**. Forsøk transformasjoner ($\log x$, $\sqrt{x}$) eller polynomledd (x^2).
- (ii) **Heteroskedastisitet** (ikke-konstant varians). Ofte hjelper det å modellere $\log y$ eller $\sqrt{y}$ i stedet for y .
- (iii) **Høy giring (leverage)**. Sjekk om observasjonen er en registreringsfeil. Er den ekte, rapporter resultatene både med og uten den.
- (iv) **Korrelerte feilledd**. Standardfeilene blir for små og konfidensintervallene for smale – vi tror vi har mer uavhengig informasjon enn vi har. Bruk metoder for tidsserier.

3 Del C – Trening, test og bias–varians

C1. Lineær eller kubisk modell?

ISLP 3.7, oppgave 4.

Vi har $n = 100$ observasjoner med én prediktor. Vi tilpasser både en lineær modell $Y = \beta_0 + \beta_1 X + \epsilon$ og en kubisk modell $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \epsilon$.

- (a) Anta at den sanne sammenhengen er lineær. Hvilken modell har lavest *trenings*-RSS – eller er det ikke nok informasjon til å si?
- (b) Samme spørsmål for *test*-RSS.
- (c) Anta nå at den sanne sammenhengen ikke er lineær, men at vi ikke vet hvor langt fra lineær den er. Hvilken modell har lavest *trenings*-RSS?
- (d) Samme spørsmål for *test*-RSS.

Løsningsforslag

(a) Den kubiske, eller like lav. Den lineære modellen er et spesialtilfelle av den kubiske ($\beta_2 = \beta_3 = 0$), så den kubiske minimerer over en større mengde – samme argument som i B4(c). I praksis blir *trenings*-RSS strengt lavere, fordi den kubiske modellen fanger opp litt tilfeldig støy.

(b) Den lineære, forventningsmessig. Når den sanne f er lineær, har begge modellene skjevhet null, men den kubiske har høyere varians – den bruker to frihetsgrader på å estimere koeffisienter som egentlig er null. Bias–varians-regnskapet gir da høyere forventet testfeil for den kubiske.

(c) Den kubiske, av nøyaktig samme grunn som i (a). Nestede modeller gir alltid lavere eller lik *trenings*-RSS, uavhengig av hva som er sant. Dette er hele grunnen til at *trenings*-RSS ikke kan brukes til modellvalg.

(d) Ikke nok informasjon. Er den sanne sammenhengen nesten lineær, vinner den lineære modellen fordi variansgevinsten er større enn skjevhetstapet. Er den tydelig krum, vinner den kubiske. Uten å vite hvor langt fra lineær f er, kan vi ikke avgjøre det – vi må estimere testfeilen, for eksempel med et testsett eller kryssvalidering.

C2. Overtilpasning du kan regne på

Vi bruker de samme fem observasjonene som i A1: $x = (1, 2, 3, 4, 5)$, $y = (2, 4, 5, 4, 5)$.

I stedet for en rett linje tilpasser vi et fjerdegradspolynom $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2 + \hat{\beta}_3 x^3 + \hat{\beta}_4 x^4$. Minste kvadraters metode gir

$$\hat{y} = 5 - \frac{35}{4}x + \frac{187}{24}x^2 - \frac{9}{4}x^3 + \frac{5}{24}x^4.$$

- (a) Sett inn $x = 1$ og $x = 2$ og kontroller at polynomet treffer y nøyaktig. (Det gjør det for alle fem punktene.)
- (b) Hva blir RSS og R^2 for denne modellen?
- (c) Hva skjer om du prøver å regne ut $\text{RSE} = \sqrt{\text{RSS}/(n - p - 1)}$ her?
- (d) Bruk begge modellene til å predikere ved $x = 6$ og ved $x = 0$. Den lineære modellen fra A1 var $\hat{y} = 2,2 + 0,6x$. Kommentér.
- (e) Hvilken modell ville du valgt, og hvorfor? Knytt svaret til bias og varians.

Løsningsforslag

(a) Ved $x = 1$:

$$5 - \frac{35}{4} + \frac{187}{24} - \frac{9}{4} + \frac{5}{24} = \frac{120 - 210 + 187 - 54 + 5}{24} = \frac{48}{24} = 2. \checkmark$$

Ved $x = 2$: $5 - 17,5 + 31,167 - 18 + 3,333 = 4,0. \checkmark$

(b) $RSS = 0$ og $R^2 = 1 - 0/6 = 1$. Modellen forklarer «all» variasjon.

(c) $n - p - 1 = 5 - 4 - 1 = 0$: vi deler på null. Det er ikke en teknisk kuriositet, men et signal. Med like mange parametere som observasjoner er det ingen frihetsgrader igjen til å anslå støyen σ . Modellen har brukt opp all informasjonen i dataene på å treffe punktene.

(d)

	Lineær	Fjerdegrad
$\hat{y}(6)$	5,8	17,0
$\hat{y}(0)$	2,2	5,0

Kontroll for fjerdegradspolynomet ved $x = 6$: $5 - 52,5 + 280,5 - 486 + 270 = 17,0$. Prediksjonen er dobbelt så høy som den største observerte y -verdien, og alle observasjonene ligger mellom 2 og 5.

(e) Den lineære. Fjerdegradspolynomet har skjevhet null på treningsdataene (det treffer perfekt), men enorm varians: flytter du én av de fem y -verdiene litt, kaster hele kurven seg rundt. $R^2 = 1$ og $RSS = 0$ måler bare hvor godt modellen husker dataene den har sett – det er samme feilslutning som å pugge fasiten til øvingsoppgavene og tro at man da kan faget.

C3. Utled bias–varians-dekomposisjonen

La $Y = f(X) + \epsilon$ med $E(\epsilon) = 0$, $\text{Var}(\epsilon) = \sigma^2$, og la ϵ være uavhengig av treningsdataene. Vi har estimert $\hat{f}$ på et treningssett og skal predikere i et fast punkt x_0 , med utfall $y_0 = f(x_0) + \epsilon$.

Vis at

$$E(y_0 - \hat{f}(x_0))^2 = \text{Var}(\hat{f}(x_0)) + [\text{Bias}(\hat{f}(x_0))]^2 + \sigma^2, \quad \text{Bias}(\hat{f}(x_0)) = E[\hat{f}(x_0)] - f(x_0).$$

Hint 1: Sett inn $y_0 = f(x_0) + \epsilon$ og gang ut. *Hint 2:* Legg til og trekk fra $E[\hat{f}(x_0)]$.

Løsningsforslag

Skriv $f = f(x_0)$ og $\hat{f} = \hat{f}(x_0)$ for å spare plass. Forventningen tas over både ϵ og trekningen av treningssettet.

Steg 1. Sett inn og gang ut:

$$E(y_0 - \hat{f})^2 = E(f + \epsilon - \hat{f})^2 = E(f - \hat{f})^2 + 2E[\epsilon(f - \hat{f})] + E(\epsilon^2).$$

Steg 2. Midtleddet forsvinner. ϵ er uavhengig av treningsdataene, og $f - \hat{f}$ avhenger bare av treningsdataene, så

$$E[\epsilon(f - \hat{f})] = E(\epsilon) \cdot E(f - \hat{f}) = 0.$$

Og $E(\epsilon^2) = \text{Var}(\epsilon) = \sigma^2$ siden $E(\epsilon) = 0$.

Steg 3. Ta det første leddet. Legg til og trekk fra $E[\hat{f}]$:

$$\begin{aligned} E(f - \hat{f})^2 &= E\left(\underbrace{f - E[\hat{f}]}_{\text{fast tall}} + \underbrace{E[\hat{f}] - \hat{f}}_{\text{tilfeldig, forventning 0}}\right)^2 \\ &= (f - E[\hat{f}])^2 + 2(f - E[\hat{f}]) E[E[\hat{f}] - \hat{f}] + E(E[\hat{f}] - \hat{f})^2 \\ &= [\text{Bias}(\hat{f})]^2 + 0 + \text{Var}(\hat{f}). \end{aligned}$$

Her brukte vi at $E[E[\hat{f}] - \hat{f}] = 0$ per definisjon.

Steg 4. Sett sammen:

$$E(y_0 - \hat{f})^2 = \text{Var}(\hat{f}) + [\text{Bias}(\hat{f})]^2 + \sigma^2.$$

Hva utledningen faktisk sier. Alle tre leddene er ikke-negative, og σ^2 avhenger ikke av modellen. Dermed er σ^2 et gulv: ingen metode, uansett hvor smart, kan komme under den forventede testfeilen σ^2 . Det eneste vi kan gjøre er å balansere de to første leddene mot hverandre – og fleksibilitet flytter dem i hver sin retning.

C4. Bias–varians med tall

En simulering gir følgende for fem metoder med økende fleksibilitet, i et gitt punkt x_0 . Den irreducible feilen er $\sigma^2 = 1,0$.

Fleksibilitet	1	2	3	4	5
Kvadrert skjevhet	4,0	1,6	0,6	0,3	0,2
Varians	0,2	0,5	1,0	2,2	4,0


- Regn ut forventet test-MSE for hver av de fem.
- Hvilken fleksibilitet er best? Skisser hvordan de tre komponentene og summen ser ut som funksjon av fleksibilitet.
- Trenings-MSE synker monotont: 4,5; 2,4; 1,5; 0,9; 0,4. Hvilken modell ville du valgt om du bare hadde sett trenings-MSE?
- Kan forventet test-MSE noen gang bli mindre enn 1,0 her? Begrunn.

Løsningsforslag

(a) Test-MSE = skjevhet² + varians + 1,0:

Fleksibilitet	1	2	3	4	5
Test-MSE	5,2	3,1	2,6	3,5	5,2

(b) Fleksibilitet 3, med test-MSE 2,6. Merk at hverken skjevhet eller varians er minst der – det er summen som teller. Kurven har den karakteristiske U-formen:



(c) Fleksibilitet 5 – den med lavest trenings-MSE, men som deler førsteplassen for *dårligst* testfeil. Trenings-MSE synker uansett hva som er sant, akkurat som i C1(c) og C2.

(d) Nei. Både skjevhet² og varians er ikke-negative, så test-MSE $\geq \sigma^2 = 1,0$. Kom du under, ville du enten regnet feil, eller målt feilen på data modellen allerede har sett.

C5. Når testsettet lyver

En analytiker har $n = 200$ observasjoner og $p = 500$ prediktorer, som alle er ren støy og uten sammenheng med y . Hun gjør følgende:

1. kjører 500 enkle regresjoner på *hele* datasettet og plukker ut de fem prediktorene med lavest p -verdi,
 2. deler så dataene i et treningssett og et testsett,
 3. tilpasser en modell med de fem utvalgte prediktorene på treningssettet, og rapporterer feilen på testsettet.
- (a) Hvis alle 500 prediktorene er ren støy, hvor mange av dem vil vi likevel forvente å finne «signifikante» på 5 %-nivå?
- (b) Forklar hvorfor testfeilen hennes blir for optimistisk.
- (c) Hva er den riktige rekkefølgen på stegene?

Løsningsforslag

(a) $500 \cdot 0,05 = 25$. Et signifikansnivå på 5 % betyr per definisjon at vi forkaster en sann nullhypotese i 5 % av tilfellene. Tester du nok, finner du alltid noe.

(b) Testsettet er ikke lenger «data modellen ikke har sett». Utvalget av de fem prediktorene brukte hele datasettet, altså også de radene som senere havnet i testsettet. Modellen har fått et forsprang: den er valgt fordi den tilfeldigvis passer på disse punktene. Testfeilen måler dermed delvis hvor godt modellen husker, ikke hvor godt den generaliserer.

(c) Del først, deretter velg. Alt som innebærer å se på responsen – valg av variabler, transformasjoner, valg av modellklasse, valg av K i KNN – må skje utelukkende på treningssettet. Testsettet røres én gang, helt til slutt.

4 Del D – Klassifikasjon (4.1–4.2)

D1. Feilrate og den late klassifikatoren

I `Default`-datasettet er det 10 000 kunder, og 333 av dem misligholder kredittkortgjelda. En modell gir følgende forvekslingstabell på treningsdataene:

Predikert	Faktisk		Sum
	Nei	Ja	
Nei	9644	252	9896
Ja	23	81	104
Sum	9667	333	10 000

- (a) Regn ut den totale feilraten.
- (b) Regn ut feilraten til en «lat» klassifikator som alltid sier «nei».
- (c) Hvor stor andel av dem som faktisk misligholder, fanger modellen opp?
- (d) Er modellen god? Diskuter kort hva slags feil som er dyrest for en bank.

Løsningsforslag

(a) $(252 + 23)/10\,000 = 275/10\,000 = 2,75\%$.
(b) Den late klassifikatoren tar feil på alle de 333 som misligholder: $333/10\,000 = 3,33\%$.
(c) $81/333 = 24,3\%$. Modellen overser altså tre av fire mislighold.
(d) Målt på total feilrate er modellen bare litt bedre enn å ikke gjøre noe i det hele tatt (2,75 mot 3,33 %). Det er fordi klassene er svært skjevfordelte: når bare 3,3 % misligholder, kommer man langt med å alltid gjette «nei». For banken er de to feiltypene ikke like dyre. Å gi kreditt til noen som misligholder koster hele beløpet; å nekte kreditt til noen som ville betalt, koster tapt rente. Da bør vi ikke bruke 0,5 som terskel, men noe lavere – for eksempel klassifisere som «misligholder» når $\hat{p} > 0,1$. Vi fanger flere mislighold, men får flere falske alarmer, og den totale feilraten stiger. **Poeng:** feilraten alene er sjelden det riktige målet.

D2. Hvorfor ikke lineær regresjon?

ISLP 4.2.

En pasient kommer inn på akuttmottaket, og vi vil predikere diagnosen ut fra symptomer. Det er tre mulige diagnoser: hjerneslag, overdose og epileptisk anfall.

- (a) En student foreslår å kode responsen som $Y = 1, 2, 3$ og kjøre vanlig lineær regresjon. Skriv opp en annen rekkefølge på kodingen. Vil de to modellene gi samme prediksjoner? Hva sier det oss?
- (b) Hvilke to antakelser om diagnosene ligger implisitt i kodingen $Y = 1, 2, 3$?
- (c) Anta nå at det bare er to klasser, kodet $Y = 0$ og $Y = 1$. Vis at hvis vi i stedet koder dem $Y = 1$ og $Y = 2$, blir de tilpassede verdiene fra minste kvadraters metode bare forskjøvet med 1, slik at klassifiseringen ved en passende terskel blir identisk. *Hint:* hva skjer med $\hat{\beta}_0$ og $\hat{\beta}_1$ når y erstattes av $y + 1$?
- (d) Hvilket problem gjenstår likevel med lineær regresjon i to-klassetilfellet?

Løsningsforslag

(a) For eksempel: overdose = 1, hjerneslag = 2, epileptisk anfall = 3. De to modellene gir helt forskjellige prediksjoner, fordi regresjonen tar tallene på alvor som tall: den prøver å modellere avstanden mellom kategoriene. Siden svaret avhenger av et vilkårlig valg vi selv gjorde, er metoden feil.

(b) Kodingen 1, 2, 3 antar (i) en *rekkefølge* – at overdose ligger «mellom» hjerneslag og epileptisk anfall – og (ii) at *avstandene* er like store, altså at gapet fra hjerneslag til overdose er like stort som gapet fra overdose til epileptisk anfall. Ingen av delene gir mening for tre diagnoser uten naturlig rangering.

(c) La $z_i = y_i + 1$. Da er $\bar{z} = \bar{y} + 1$, og

$$\hat{\beta}_1^{(z)} = \frac{\sum_i (x_i - \bar{x})(z_i - \bar{z})}{\sum_i (x_i - \bar{x})^2} = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2} = \hat{\beta}_1^{(y)},$$

siden $z_i - \bar{z} = y_i - \bar{y}$. Videre er $\hat{\beta}_0^{(z)} = \bar{z} - \hat{\beta}_1 \bar{x} = \hat{\beta}_0^{(y)} + 1$. Altså er $\hat{z}_i = \hat{y}_i + 1$ for alle i . Terskelen $\hat{y} > 0,5$ svarer nøyaktig til $\hat{z} > 1,5$, så vi klassifiserer likt. Med to klasser er kodingen altså *ikke* et problem – problemet i (a) oppstår først med tre eller flere.

(d) Prediksjonene er ikke gyldige sannsynligheter. En rett linje er ubegrenset, så $\hat{p}$ vil før eller siden bli negativ eller større enn 1. Se D3.

D3. Den lineære sannsynlighetsmodellen på Default

Vi koder `default` som 0/1 og kjører vanlig minste kvadraters regresjon på `balance`. Resultatet er

$$\hat{p}(\text{balance}) = -0,0752 + 0,00012987 \cdot \text{balance}.$$

- (a) Regn ut $\hat{p}$ for saldoene 250, 1000 og 2500 dollar.
- (b) For hvilke saldoer er $\hat{p} < 0$? (Løs $-0,0752 + 0,00012987x = 0$.)
- (c) I datasettet har 3123 av 10000 kunder saldo under denne grensen. Hvor stor andel av kundene får altså en negativ estimert sannsynlighet?
- (d) Ved hvilken saldo ville $\hat{p}$ passert 1? Høyeste observerte saldo er 2654. Forklar hvorfor problemet med $\hat{p} > 1$ ikke dukker opp i akkurat dette datasettet, men likevel er et prinsipielt problem.
- (e) Hva er det den logistiske funksjonen gjør annerledes?

Løsningsforslag

(a)

$$\begin{aligned}\text{balance} = 250 : & -0,0752 + 0,0325 = -0,043 \\ \text{balance} = 1000 : & -0,0752 + 0,1299 = 0,055 \\ \text{balance} = 2500 : & -0,0752 + 0,3247 = 0,249\end{aligned}$$


Den første er negativ – en «sannsynlighet» på $-4,3\%$.

(b) $x = 0,0752/0,00012987 = 579$. For alle saldoer under omtrent \$579 er $\hat{p} < 0$.

(c) $3123/10000 = 31,2\%$. Nesten en tredjedel av kundene får et meningsløst svar. Dette er ikke et randfenomen.

(d) $\hat{p} = 1$ når $x = (1 + 0,0752)/0,00012987 = 8279$. Ingen i datasettet har så høy saldo, så vi ser det ikke – men modellen sier likevel at en kunde med saldo \$9000 har sannsynlighet over 1 for mislighold. En modell som produserer umulige svar utenfor dataområdet, er en modell vi ikke kan bruke til å ekstrapolere, og vi kan ikke tolke $\hat{p}$ som en sannsynlighet.

(e) Den logistiske funksjonen $p(X) = e^{\beta_0 + \beta_1 X} / (1 + e^{\beta_0 + \beta_1 X})$ er en S-kurve som alltid ligger strengt mellom 0 og 1, uansett hvor stor eller liten X er. Vi modellerer den lineære formen på *log-odds*-skalaen i stedet for på sannsynlighetsskalaen. Figuren viser de to modellene på Default:



D4. KNN og dimensjonens forbannelse

ISLP 4.8, oppgave 4.

Vi vil predikere responsen til en testobservasjon ved hjelp av de nærmeste naboene. Alle prediktorene er jevnt fordelt på $[0, 1]$.

- Med $p = 1$ bruker vi de observasjonene som ligger innenfor 10 % av X -området rundt testpunktet. Hvor stor andel av observasjonene bruker vi i gjennomsnitt?
- Med $p = 2$ bruker vi observasjoner som ligger innenfor 10 % av området for *begge* variablene. Hvor stor andel nå?
- Samme spørsmål med $p = 100$.
- Bruk (a)–(c) til å forklare hvorfor KNN fungerer dårlig når p er stor.
- Anta at vi i stedet vil ha en terning i p dimensjoner som i gjennomsnitt inneholder 10 % av observasjonene. Hvor lang må hver side være når $p = 1, 2$ og 100? Kommenter.

Løsningsforslag

- 10 %.
- Kravet må oppfylles i begge dimensjoner samtidig, og siden variablene er uavhengige multipliserer vi: $0,1 \cdot 0,1 = 0,01$, altså 1 %.
- $0,1^{100} = 10^{-100}$. Praktisk talt null.
- Andelen naboer «i nærheten» faller eksponentielt med p . Med mange prediktorer er selv den nærmeste naboen svært langt unna testpunktet, og da er den ikke representativ for f i testpunktet. KNN hviler på at «nær i X » betyr «likt i Y », og den antakelsen brytes ned når p vokser. Det er en av grunnene til at en parametrisert modell som lineær regresjon ofte slår KNN når p er stor.
- Vi trenger $s^p = 0,1$, altså $s = 0,1^{1/p}$:

$$p = 1 : s = 0,10; \quad p = 2 : s = 0,316; \quad p = 100 : s = 0,1^{0,01} = 0,977.$$

Med 100 prediktorer må «nabolaget» dekke 97,7 % av området til hver variabel for å fange opp 10 % av observasjonene. Det er ikke et nabolag lenger – det er nesten hele datasettet.

Ordet «nærmeste» har mistet meningen sin.

D5. Bayes-klassifikatoren og feilgulvet

Anta at vi kjenner de sanne sannsynlighetene $\Pr(Y = 1 \mid X = x)$ i fem testpunkter:

Testpunkt	1	2	3	4	5
$\Pr(Y = 1 \mid X = x)$	0,05	0,30	0,55	0,80	0,95

- (a) Hva predikerer Bayes-klassifikatoren i hvert punkt?
- (b) Feilsannsynligheten i punkt x er $1 - \max\{p, 1 - p\} = \min\{p, 1 - p\}$. Regn den ut i hvert punkt.
- (c) Hva er den gjennomsnittlige Bayes-feilraten over de fem punktene?
- (d) Kan en bedre metode komme under dette tallet? Hva svarer Bayes-feilraten til i regresjonssammenheng?

Løsningsforslag

- (a) Bayes-klassifikatoren velger klassen med høyest sannsynlighet, altså 1 hvis $p > 0,5$: prediksjonene blir 0, 0, 1, 1, 1.
- (b) $\min\{p, 1 - p\}$: 0,05; 0,30; 0,45; 0,20; 0,05.
- (c) $(0,05 + 0,30 + 0,45 + 0,20 + 0,05)/5 = 1,05/5 = 0,21$, altså 21 %.
- (d) Nei. Bayes-klassifikatoren bruker de *sanne* sannsynlighetene og er optimal per konstruksjon – ingen metode kan i gjennomsnitt gjøre det bedre. Bayes-feilraten er klassifikasjonens motstykke til den irreducible feilen σ^2 i regresjon: et gulv som følger av at X ikke bestemmer Y fullstendig. Legg merke til at punkt 3 bidrar mest (0,45): når p ligger nær 0,5, er utfallet nesten et myntkast, og selv en perfekt modell tar feil nesten halve tiden.

5 Del E – Den logistiske modellen (4.3.1–4.3.2)

E1. Odds, sannsynlighet og log-odds

Deloppgave (a) og (b) er ISLP 4.8, oppgave 9.

- (a) I gjennomsnitt: hvor stor andel av dem som har odds 0,37 for å misligholde kredittkortgjelda, kommer faktisk til å misligholde?
- (b) En kunde har 16 % sannsynlighet for å misligholde. Hva er oddsen?
- (c) Fyll ut tabellen:

p	0,10	0,25	0,50	0,75	0,90
$\text{odds} = p/(1 - p)$					
$\text{logit} = \log(p/(1 - p))$					

- (d) Hvilke verdier kan odds ta? Hvilke verdier kan logit ta? Hvorfor er det siste praktisk når vi skal sette en lineær modell på høyresiden?

Løsningsforslag

(a) Løs $p/(1-p) = 0,37$ for p :

$$p = \frac{0,37}{1 + 0,37} = \frac{0,37}{1,37} = 0,27.$$

Omtrent 27 %.

(b) $\frac{0,16}{1 - 0,16} = \frac{0,16}{0,84} = 0,19.$

(c)

p	0,10	0,25	0,50	0,75	0,90
odds	0,111	0,333	1	3	9
logit	-2,20	-1,10	0	1,10	2,20

Legg merke til symmetrien: p og $1-p$ gir logit med samme tallverdi og motsatt fortegn.

(d) Odds ligger i $(0, \infty)$; logit ligger i $(-\infty, \infty)$. En lineær funksjon $\beta_0 + \beta_1 X$ kan også ta alle verdier på tallinja. Ved å modellere *logit* lineært får vi altså to størrelser som lever på samme skala – og når vi regner tilbake til p , havner vi automatisk i $(0, 1)$. Det er hele trikset bak logistisk regresjon.

E2. Fra sannsynlighet til odds til logit

ISLP 4.8, oppgave 1.

Vis at den logistiske modellen

$$p(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}} \quad (4.2)$$

er ekvivalent med

$$\frac{p(X)}{1 - p(X)} = e^{\beta_0 + \beta_1 X} \quad (4.3)$$

og dermed med $\log(p(X)/(1 - p(X))) = \beta_0 + \beta_1 X$ (4.4).

Løsningsforslag

Skriv $z = \beta_0 + \beta_1 X$. Fra (4.2):

$$1 - p(X) = 1 - \frac{e^z}{1 + e^z} = \frac{1 + e^z - e^z}{1 + e^z} = \frac{1}{1 + e^z}.$$

Da blir

$$\frac{p(X)}{1 - p(X)} = \frac{e^z/(1 + e^z)}{1/(1 + e^z)} = e^z = e^{\beta_0 + \beta_1 X},$$

som er (4.3). Ta logaritmen på begge sider, og du får (4.4).

Andre veien: start med $p/(1-p) = e^z$. Da er $p = e^z(1-p)$, altså $p(1 + e^z) = e^z$ og $p = e^z/(1 + e^z)$.

Konsekvensen for tolkning. Øker X med én enhet, øker log-odds med β_1 – uansett hvor vi starter. Ekvivalent: oddsen *multipliseres* med e^{β_1} . Sannsynligheten endres derimot ikke med et fast beløp; se E4.

E3. Sannsynligheten for A

For en gruppe studenter er X_1 = antall timer lest, X_2 = karaktersnitt fra bachelor, og $Y = 1$ hvis studenten får A. Logistisk regresjon gir $\hat{\beta}_0 = -6$, $\hat{\beta}_1 = 0,05$, $\hat{\beta}_2 = 1$.

- Estimer sannsynligheten for at en student som leser 40 timer og har snitt 3,5 får A.
- Hvor mange timer må denne studenten lese for å ha 50 % sjanse for A?
- Hvor mange timer må en student med snitt 2,5 lese for å ha 50 % sjanse? Kommenter forskjellen.

Løsningsforslag

(a) Regn først ut den lineære delen:

$$\hat{z} = -6 + 0,05 \cdot 40 + 1 \cdot 3,5 = -6 + 2 + 3,5 = -0,5.$$

Deretter

$$\hat{p} = \frac{e^{-0,5}}{1 + e^{-0,5}} = \frac{0,6065}{1,6065} = 0,378.$$

Omtrent 38 %.

(b) $\hat{p} = 0,5$ svarer til odds = 1, altså logit = 0:

$$-6 + 0,05X_1 + 3,5 = 0 \implies 0,05X_1 = 2,5 \implies X_1 = 50.$$

Studenten må lese 50 timer.

(c) $-6 + 0,05X_1 + 2,5 = 0 \implies X_1 = 3,5/0,05 = 70$ timer.

Ett karakterpoeng lavere snitt må altså kompenseres med 20 timers ekstra lesing. Det følger direkte av forholdet mellom koeffisientene: $\hat{\beta}_2/\hat{\beta}_1 = 1/0,05 = 20$. Slike «bytteforhold» er ofte lettere å tolke enn koeffisientene hver for seg – de er uavhengige av at logit-skalaen i seg selv er lite intuitiv.

E4. Default: koeffisienten er *ikke* en endring i sannsynlighet

Tabell 4.1 i boka gir følgende for logistisk regresjon av **default** på **balance**:

$$\hat{\beta}_0 = -10,6513, \quad \hat{\beta}_1 = 0,0055, \quad SE(\hat{\beta}_1) = 0,0002.$$

- Regn ut $\hat{p}$ for saldo \$1000 og \$2000.
- Ved hvilken saldo er $\hat{p} = 0,5$?
- Regn ut $\hat{p}$ for saldo 1100 og for 2000, og finn hvor mye sannsynligheten øker ved 100 dollar mer i saldo, når man starter på henholdsvis 1000 og 1900. Hvorfor er de to tallene så forskjellige?
- Hva blir oddsen multiplisert med når saldoen øker med 100 dollar?
- Regn ut z -observatoren for $H_0 : \beta_1 = 0$.

Løsningsforslag

(a) Saldo 1000:

$$\hat{z} = -10,6513 + 0,0055 \cdot 1000 = -5,151, \quad \hat{p} = \frac{e^{-5,151}}{1 + e^{-5,151}} = 0,0058.$$

Saldo 2000:

$$\hat{z} = -10,6513 + 11 = 0,349, \quad \hat{p} = \frac{e^{0,349}}{1 + e^{0,349}} = \frac{1,417}{2,417} = 0,586.$$

Under 1 % mot nesten 59 %.

(b) $\hat{p} = 0,5$ krever $\hat{z} = 0$:

$$X = \frac{10,6513}{0,0055} = 1937.$$

(c)

Saldo	$\hat{p}$	$\hat{p}$ ved +100	Endring
1000	0,0058	0,0099	+0,0042
1900	0,4498	0,5863	+0,1365

Den samme økningen på 100 dollar gir under et halvt prosentpoeng det ene stedet og nesten 14 prosentpoeng det andre. Grunnen er at S-kurven er nesten flat i halene og bratt i midten: β_1 er en fast endring i *log-odds*, ikke i sannsynlighet. Sannsynlighetsendringen avhenger av hvor på kurven vi står.

Dette er den vanligste eksamensfeilen i kapittel 4. «En krone mer i saldo øker sannsynligheten for mislighold med 0,0055» er galt. Riktig er: «øker log-odds med 0,0055», eller «multipliserer oddsen med $e^{0,0055} = 1,0055$ ».

(d) $e^{0,0055 \cdot 100} = e^{0,55} = 1,73$. Oddsen blir altså 73 % høyere per 100 dollar økt saldo – uansett startpunkt. Det er nettopp fordi denne faktoren er konstant at logit-skalaen er den naturlige å tolke på.

(e) $z = 0,0055/0,0002 = 27,5$ (boka oppgir 24,9 med færre avrundinger). Uansett: enormt, og p -verdien er praktisk talt null. z -observatoren spiller nøyaktig samme rolle her som t -observatoren i kapittel 3.

```
import numpy as np
p = lambda z: np.exp(z)/(1+np.exp(z))
for b in [1000, 1100, 1900, 2000]:
    print(b, round(p(-10.6513 + 0.0055*b), 4))
```

E5. Studenter, saldo og et fortegn som snur

To modeller på Default-dataene:

Tabell 4.2: bare studentstatus		Tabell 4.3: saldo, inntekt og studentstatus	
Konstantledd	−3,5041	Konstantledd	−10,8690
student[Yes]	0,4049	balance	0,00574
		income (i tusen \$)	0,00300
		student[Yes]	−0,6468

- Bruk tabell 4.2 til å regne ut $\hat{p}$ for en student og for en ikke-student.
- Bruk tabell 4.3 til å regne ut $\hat{p}$ for en student og en ikke-student som begge har saldo \$1500 og inntekt \$40 000.
- Koeffisienten på **student** er positiv i den første modellen og negativ i den andre. Er én av dem feil? Forklar hva som skjer.
- Formulér i én setning hva hver av de to modellene faktisk svarer på.

Løsningsforslag

(a) Student: $\hat{z} = -3,5041 + 0,4049 = -3,0992$, så $\hat{p} = e^{-3,0992}/(1 + e^{-3,0992}) = 0,0431$.
Ikke-student: $\hat{z} = -3,5041$, $\hat{p} = 0,0292$.

Studenter misligholder altså oftere: 4,3 % mot 2,9 %.

(b) Student:

$$\hat{z} = -10,869 + 0,00574 \cdot 1500 + 0,003 \cdot 40 - 0,6468 = -2,786, \quad \hat{p} = 0,058.$$

Ikke-student: $\hat{z} = -2,139$, $\hat{p} = 0,105$.

Nå er det motsatt: studenten har 5,8 % mot ikke-studentens 10,5 %.

(c) Ingen av dem er feil – de svarer på ulike spørsmål. Studenter har i gjennomsnitt *høyere saldo* enn ikke-studenter, og høy saldo driver mislighold. Når vi ikke kontrollerer for saldo, får studentstatus «æren» for saldoeffekten. Kontrollerer vi for saldo, ser vi at en student med *samme* saldo som en ikke-student faktisk er den tryggeste av de to. Dette kalles konfundering, og er nøyaktig samme mekanisme som med *newspaper* og *radio* i B1(c) – bare på log-odds-skalaen.

(d)

- Tabell 4.2: «Hvis alt jeg vet om deg er at du er student, hvor risikabel er du?» Svar: mer risikabel enn gjennomsnittet.
- Tabell 4.3: «Hvis jeg allerede kjenner saldoen og inntekten din, hva betyr det i tillegg at du er student?» Svar: du er mindre risikabel.

Hvilken en bank bør bruke, avhenger av hva den vet om søkeren på beslutningstidspunktet.

E6. Rimelighet (likelihood) med tre kunder

Logistisk regresjon estimeres ikke med minste kvadraters metode, men med *sannsynlighetsmaksimering*: vi velger de β -ene som gjør de observerte utfallene mest sannsynlige. Rimelighetsfunksjonen er

$$\ell(\beta_0, \beta_1) = \prod_{i: y_i=1} p(x_i) \prod_{i': y_{i'}=0} (1 - p(x_{i'})).$$

Vi har tre kunder:

Kunde	Saldo x_i	Misligholdt? y_i
1	1000	0
2	2000	1
3	1500	0

Vurder to kandidater: $A = (\beta_0, \beta_1) = (-10,65; 0,0055)$ og $B = (-5,00; 0,0025)$.

- Regn ut $p(x_i)$ for alle tre kundene under hver av de to kandidatene.
- Regn ut ℓ for hver kandidat. Hvilken foretrekker metoden?
- Hvorfor bruker vi i praksis $\log \ell$ i stedet for ℓ ?
- Hva er analogien til kapittel 3? Hva minimerte vi der, og hva maksimerer vi her?

Løsningsforslag

(a) Regn først $z_i = \beta_0 + \beta_1 x_i$, deretter $p = e^z / (1 + e^z)$:

	x_i	y_i	p_i under A	p_i under B
1	1000	0	0,0058	0,0759
2	2000	1	0,5866	0,5000
3	1500	0	0,0832	0,2227

(For B og kunde 2: $z = -5 + 0,0025 \cdot 2000 = 0$, som gir $p = 0,5$.)

(b) Bidraget er p_i for de som misligholdt og $1 - p_i$ for de andre:

$$\ell(A) = (1 - 0,0058) \cdot 0,5866 \cdot (1 - 0,0832) = 0,9942 \cdot 0,5866 \cdot 0,9168 = 0,535$$

$$\ell(B) = (1 - 0,0759) \cdot 0,5000 \cdot (1 - 0,2227) = 0,9241 \cdot 0,5000 \cdot 0,7773 = 0,359$$

Kandidat A gir høyest rimelighet og foretrekkes. Estimaten $\hat{\beta}_0, \hat{\beta}_1$ er de som gjør ℓ så stor som mulig – A er nettopp anslagene fra tabell 4.1.

(c) Produktet av mange tall mellom 0 og 1 blir fort så lite at maskinen runder det til null. Logaritmen gjør produktet om til en sum, $\log \ell = \sum_i [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$, som er numerisk stabil og lettere å derivere. Siden log er strengt voksende, gir det samme maksimum. Her: $\log \ell(A) = -0,626$ mot $\log \ell(B) = -1,024$.

(d) I kapittel 3 valgte vi koeffisientene som *minimerte* RSS – avstanden mellom observerte og tilpassede y -verdier. Her velger vi koeffisientene som *maksimerer* rimeligheten – hvor godt modellen forklarer de observerte 0/1-utfallene. I begge tilfeller: sett opp et kriterium, deriver, sett lik null. Forskjellen er at førsteordensbetingelsene i logistisk regresjon ikke har en lukket løsning, så de må løses numerisk. Det er derfor Python bruker en iterativ algoritme i stedet for én formel.

Oppgavetekster fra boka er gjengitt i forkortet og bearbeidet form.

Se ISLP avsnitt 3.7 og 4.8 for de fullstendige formuleringene.