

Oppgavesett 2

Kapittel 3 og 4: Lineær regresjon og klassifikasjon

SOK-1305 Statistisk læring for økonomer

Handelshøgskolen ved UiT
Høsten 2026

Hvordan jobbe med dette settet. Oppgavene dekker kapittel 3 og de første avsnittene i kapittel 4 i ISLP, og forutsetter at du har med deg begrepene fra kapittel 1 og 2. Noen av oppgavene er hentet fra boka (avsnitt 3.7 og 4.8), resten er laget til kurset. Det meste her skal regnes for hånd. Det er et poeng: formlene sitter først når du har brukt dem. Ta fram kalkulator og penn før du tar fram Python. Bruk deretter gjerne Python til å kontrollere svarene – flere av oppgavene har korte kodesnutter i løsningsforslaget.

Ordliste – symboler du trenger

RSS	Residualkvadratsum, $\sum_i (y_i - \hat{y}_i)^2$. Det modellen <i>ikke</i> klarer å forklare.
TSS	Total kvadratsum, $\sum_i (y_i - \bar{y})^2$. All variasjon i y før vi modellerer.
R^2	$1 - \text{RSS}/\text{TSS}$. Andelen av variasjonen i y modellen forklarer.
RSE	Residualstandardfeil, $\sqrt{\text{RSS}/(n - p - 1)}$. Anslag på σ , altså på typisk avvik fra regresjonslinja.
$\text{SE}(\hat{\beta}_j)$	Standardfeil: hvor mye $\hat{\beta}_j$ ville variert om vi trakk et nytt utvalg.
t -observator	$\hat{\beta}_j/\text{SE}(\hat{\beta}_j)$. Hvor mange standardfeil estimatet ligger fra null.
Dummyvariabel	0/1-variabel som koder en kvalitativ egenskap.
Interaksjonsledd	Produktet $X_1 X_2$ tatt inn som egen prediktor.
Odds	$p/(1 - p)$. Sannsynlighet omregnet til «forhold».
Logit	$\log(p/(1 - p))$, altså log-odds.
Feilrate	Andel observasjoner klassifisert feil.

Anbefalt utvalg:

- **Obligatorisk kjerne:** A1, A2, A4, B1, B2, B4, C1, C2, C3, D2, D3, E1, E3, E4
- **Anbefalt:** A3, A5, B3, B5, C4, D1, D4, E2, E5
- **Ekstra:** B6, C5, D5, E6

Del E bygger på avsnitt 4.3.1–4.3.2. Har vi bare så vidt rukket den logistiske modellen, kan du vente med E5 og E6 til etter neste forelesning.

Innhold

1 Del A – Enkel lineær regresjon (3.1)	1
A1. Minste kvadraters metode for hånd	1
A2. Normallikningene, og hvorfor linja går gjennom $(\bar{x}, \bar{y})$	2
A3. Vis at R^2 er kvadrert korrelasjon	2
A4. Advertising: les og gjenskap tabellen	2
A5. Konfidensintervall eller prediksjonsintervall?	3

2	Del B – Multippel regresjon (3.2–3.3)	3
	B1. Hva tester p -verdiene?	3
	B2. Interaksjon og fortegn	3
	B3. Dummyvariabler med tre nivåer	4
	B4. R^2 , justert R^2 og F	4
	B5. Synergi i Advertising	4
	B6. Kollinearitet i praksis	5
3	Del C – Trening, test og bias–varians	5
	C1. Lineær eller kubisk modell?	5
	C2. Overtilpasning du kan regne på	6
	C3. Utled bias–varians-dekomposisjonen	6
	C4. Bias–varians med tall	6
	C5. Når testsettet lyver	6
4	Del D – Klassifikasjon (4.1–4.2)	7
	D1. Feilrate og den late klassifikatoren	7
	D2. Hvorfor ikke lineær regresjon?	7
	D3. Den lineære sannsynlighetsmodellen på Default	8
	D4. KNN og dimensjonens forbannelse	8
	D5. Bayes-klassifikatoren og feilgulvet	8
5	Del E – Den logistiske modellen (4.3.1–4.3.2)	9
	E1. Odds, sannsynlighet og log-odds	9
	E2. Fra sannsynlighet til odds til logit	9
	E3. Sannsynligheten for A	9
	E4. Default: koeffisienten er <i>ikke</i> en endring i sannsynlighet	9
	E5. Studenter, saldo og et fortegn som snur	10
	E6. Rimelighet (likelihood) med tre kunder	10

1 Del A – Enkel lineær regresjon (3.1)

A1. Minste kvadraters metode for hånd

Vi har fem observasjoner:

x_i	1	2	3	4	5
y_i	2	4	5	4	5

- Regn ut $\bar{x}$, $\bar{y}$, $S_{xy} = \sum_i (x_i - \bar{x})(y_i - \bar{y})$ og $S_{xx} = \sum_i (x_i - \bar{x})^2$, og finn $\hat{\beta}_1$ og $\hat{\beta}_0$.
- Regn ut de fem tilpassede verdiene $\hat{y}_i$ og de fem residualene $e_i = y_i - \hat{y}_i$. Kontroller at $\sum_i e_i = 0$ og at $\sum_i x_i e_i = 0$.
- Regn ut RSS, TSS, R^2 og RSE.
- Regn ut $\text{SE}(\hat{\beta}_1) = \text{RSE}/\sqrt{S_{xx}}$ og t -observatoren for $H_0 : \beta_1 = 0$. Med $n - 2 = 3$ frihetsgrader er den kritiske t -verdien på 5 %-nivå 3,18. Hva konkluderer du?
- Regn ut korrelasjonen mellom x og y , og kontroller at $\text{Cor}(x, y)^2 = R^2$.

A2. Normallikningene, og hvorfor linja går gjennom $(\bar{x}, \bar{y})$

Utvidet versjon av ISLP 3.7, oppgave 6.

Utgangspunktet er

$$\text{RSS}(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2.$$

- (a) Deriver RSS med hensyn på β_0 og sett den deriverte lik null. Vis at betingelsen kan skrives $\sum_i e_i = 0$, der $e_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$.
- (b) Deriver RSS med hensyn på β_1 og sett den deriverte lik null. Vis at betingelsen kan skrives $\sum_i x_i e_i = 0$.
- (c) Bruk (a) til å vise at minste kvadraters linje alltid går gjennom punktet $(\bar{x}, \bar{y})$.
- (d) Sett $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ inn i (b) og vis at $\hat{\beta}_1 = S_{xy}/S_{xx}$.

A3. Vis at R^2 er kvadrert korrelasjon

ISLP 3.7, oppgave 7.

I enkel lineær regresjon av Y på X er R^2 lik kvadratet av korrelasjonen mellom X og Y . Vis dette. Du kan for enkelhets skyld anta at $\bar{x} = \bar{y} = 0$.

Hint: Med sentrerte variabler er $\hat{\beta}_0 = 0$ og $\hat{\beta}_1 = \sum_i x_i y_i / \sum_i x_i^2$. Skriv ut RSS og forenkle.

A4. Advertising: les og gjenskap tabellen

Tabell 3.1 og 3.2 i ISLP viser resultatet av å regressere **sales** (i tusen enheter) på TV (annonsebudsjett i tusen dollar), med $n = 200$ markeder:

	Koeffisient	Std.feil	t	RSE	3,26
Konstantledd	7,0325	0,4578	?	R^2	0,612
TV	0,0475	0,0027	?	F	312,1

- (a) Regn ut de to t -observatorene.
- (b) Regn ut tilnærmede 95 %-konfidensintervaller ($\hat{\beta} \pm 2 \text{SE}$) for begge koeffisientene. Hva betyr intervallet for TV-koeffisienten i klartekst, med enheter?
- (c) Bruk RSE og n til å regne ut RSS. Bruk deretter R^2 til å regne ut TSS.
- (d) Regn ut $F = \frac{(\text{TSS} - \text{RSS})/1}{\text{RSS}/(n-2)}$ og sammenlign med tabellverdien.
- (e) Gjennomsnittlig salg er omtrent 14 (tusen enheter). Hvor stor er den typiske prediksjonsfeilen i prosent av gjennomsnittet?

A5. Konfidensintervall eller prediksjonsintervall?

Vi regressere **mpg** på **horsepower** i Auto-datasettet ($n = 392$) og får $\hat{y} = 39,936 - 0,1578x$ med $\text{RSE} = 4,906$. For $x = 98$ hestekrefter blir $\hat{y} = 24,47$, og programmet rapporterer

95 % konfidensintervall	[23,97; 24,96]
95 % prediksjonsintervall	[14,81; 34,12]

- (a) Forklar med ord hva hvert av de to intervallene sier noe om.

- (b) Halvbredde i konfidensintervallet er 0,494. Med $t_{0,975} \approx 1,966$ gir dette $SE(\hat{y}) = 0,251$. Kontroller at prediksjonsintervallets halvbredde er omtrent $t \cdot \sqrt{SE(\hat{y})^2 + RSE^2}$.
- (c) Hvilket av de to leddene under rottegnet dominerer? Hva forteller det deg om hva som skjer med de to intervallene når n blir veldig stor?

2 Del B – Multipl regressjon (3.2–3.3)

B1. Hva tester p -verdiene?

ISLP 3.7, oppgave 1.

Tabell 3.4 i boka viser multipl regressjon av **sales** på **TV**, **radio** og **newspaper**:

	Koeffisient	Std.feil	t	p -verdi
Konstantledd	2,939	0,3119	9,42	< 0,0001
TV	0,046	0,0014	32,81	< 0,0001
radio	0,189	0,0086	21,89	< 0,0001
newspaper	−0,001	0,0059	−0,18	0,8599

- (a) Skriv ned nullhypotesen som hver av de fire p -verdiene hører til.
- (b) Hvilke konklusjoner kan du trekke? Svar i form av salg, TV, radio og aviser – ikke i form av β -er.
- (c) I *enkel* regressjon av **sales** på bare **newspaper** er koeffisienten positiv og klart signifikant. Korrelasjonen mellom **radio** og **newspaper** er 0,354. Forklar hvordan disse to tingene henger sammen.

B2. Interaksjon og fortegn

ISLP 3.7, oppgave 3.

Vi har fem prediktorer: X_1 = karaktersnitt (GPA, skala 0–4), X_2 = IQ, X_3 = nivå (1 for fullført bachelor, 0 for bare videregående), $X_4 = X_1X_2$ og $X_5 = X_1X_3$. Responsen er startlønn (i tusen dollar). Minste kvadraters metode gir

$$\hat{\beta}_0 = 50, \quad \hat{\beta}_1 = 20, \quad \hat{\beta}_2 = 0,07, \quad \hat{\beta}_3 = 35, \quad \hat{\beta}_4 = 0,01, \quad \hat{\beta}_5 = -10.$$

- (a) Hvilket utsagn er riktig, og hvorfor?
- For gitt IQ og GPA tjener de med bare videregående mer i gjennomsnitt.
 - For gitt IQ og GPA tjener de med bachelor mer i gjennomsnitt.
 - For gitt IQ og GPA tjener de med bare videregående mer i gjennomsnitt, forutsatt at GPA er høy nok.
 - For gitt IQ og GPA tjener de med bachelor mer i gjennomsnitt, forutsatt at GPA er høy nok.
- (b) Predikér lønna til en person med bachelor, IQ 110 og GPA 4,0.
- (c) Riktig eller galt: «Siden koeffisienten på $GPA \times IQ$ er svært liten (0,01), er det lite som tyder på en interaksjonseffekt.» Begrunn.

B3. Dummyvariabler med tre nivåer

En bedrift har avdelinger i tre landsdeler. Vi regresserer månedslønn (i tusen kroner) på ansiennitet (år) og landsdel, med *sør* som referansekategori:

$$\hat{y} = 380 + 12 \cdot \text{ansiennitet} - 25 \cdot D_{\text{midt}} - 40 \cdot D_{\text{nord}}.$$

- (a) Regn ut predikert lønn for en ansatt med 10 års ansiennitet i hver av de tre landsdelene.
- (b) Hva er den estimerte lønnsforskjellen mellom nord og midt, for gitt ansiennitet?
- (c) Anta at vi i stedet velger *nord* som referansekategori. Skriv opp den nye likningen med koeffisienter, og kontroller at de predikerte lønningene i (a) er uendret.
- (d) Hvorfor lager vi to dummyvariabler og ikke tre, når det er tre landsdeler?

B4. R^2 , justert R^2 og F

Vi har $n = 100$ observasjoner og $\text{TSS} = 1000$. Tre nestede modeller gir:

Modell	Antall prediktorer p	RSS
$M_1: X_1$	1	500
$M_2: X_1, X_2$	2	460
$M_3: X_1, X_2, X_3$	3	458

- (a) Regn ut R^2 for alle tre modellene.
- (b) Regn ut justert $R^2 = 1 - \frac{\text{RSS}/(n-p-1)}{\text{TSS}/(n-1)}$ for alle tre. Hvilken modell foretrekker dette kriteriet?
- (c) Forklar hvorfor RSS aldri kan øke når vi legger til en prediktor, og dermed hvorfor R^2 aldri kan synke.
- (d) Test om X_3 bidrar, med $F = \frac{(\text{RSS}_2 - \text{RSS}_3)/1}{\text{RSS}_3/(n-4)}$. Kritisk verdi på 5 %-nivå er omtrent 3,94. Hva konkluderer du?
- (e) Gjør det samme for X_2 (bruk RSS_1 , RSS_2 og $n-3$).

B5. Synergi i Advertising

Tabell 3.9 i boka viser modellen med interaksjon mellom TV og radio:

$$\widehat{\text{sales}} = 6,7502 + 0,0191 \text{TV} + 0,0289 \text{radio} + 0,0011 (\text{TV} \times \text{radio}).$$

- (a) Skriv om modellen slik at TV står utenfor en parentes, og les av den «effektive hellingen» for TV.
- (b) Regn ut denne hellingen når **radio** er 0, 20 og 50. Tolk tallene i antall solgte enheter per \$1000 økt TV-budsjett.
- (c) Modellen uten interaksjon har $R^2 = 0,897$; med interaksjon er $R^2 = 0,968$. Regn ut hvor stor andel av den *gjenstående* variasjonen interaksjonsleddet forklarer.
- (d) Anta at p -verdien for interaksjonsleddet hadde vært liten, men at p -verdien for **radio** alene hadde vært stor. Ville du fjernet **radio** fra modellen?

B6. Kollinearitet i praksis

Tabell 3.11 i boka viser to regresjoner på **Credit**-datasettet, begge med **balance** som respons:

	Variabel	Koeffisient	Std.feil	t
Modell 1	age	-2,292	0,672	?
	limit	0,173	0,005	?
Modell 2	rating	2,202	0,952	?
	limit	0,025	0,064	?

- (a) Regn ut de fire t -observatorene.
- (b) Standardfeilen til **limit** er 12–13 ganger større i modell 2. Hva er årsaken, og hva gjør det med konklusjonen om **limit**?
- (c) Betyr modell 2 at kredittgrensa ikke har noe med saldoen å gjøre?
- (d) For hver av situasjonene under: hvilket av problemene i avsnitt 3.3.3 er det, og hva ville du gjort?
 - (i) Residualplottet mot $\hat{y}$ viser en tydelig U-form.
 - (ii) Residualene vifter ut som en trakt: små for lave $\hat{y}$, store for høye.
 - (iii) Én observasjon har en x -verdi langt utenfor de andre, og linja endrer seg mye om vi fjerner den.
 - (iv) Dataene er månedlige tall for samme bedrift over ti år, og residualene ligner seg selv fra måned til måned.

3 Del C – Trening, test og bias–varians

C1. Lineær eller kubisk modell?

ISLP 3.7, oppgave 4.

Vi har $n = 100$ observasjoner med én prediktor. Vi tilpasser både en lineær modell $Y = \beta_0 + \beta_1 X + \epsilon$ og en kubisk modell $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \epsilon$.

- (a) Anta at den sanne sammenhengen er lineær. Hvilken modell har lavest *trenings*-RSS – eller er det ikke nok informasjon til å si?
- (b) Samme spørsmål for *test*-RSS.
- (c) Anta nå at den sanne sammenhengen ikke er lineær, men at vi ikke vet hvor langt fra lineær den er. Hvilken modell har lavest *trenings*-RSS?
- (d) Samme spørsmål for *test*-RSS.

C2. Overtilpasning du kan regne på

Vi bruker de samme fem observasjonene som i A1: $x = (1, 2, 3, 4, 5)$, $y = (2, 4, 5, 4, 5)$.

I stedet for en rett linje tilpasser vi et fjerdegradspolynom $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2 + \hat{\beta}_3 x^3 + \hat{\beta}_4 x^4$. Minste kvadraters metode gir

$$\hat{y} = 5 - \frac{35}{4}x + \frac{187}{24}x^2 - \frac{9}{4}x^3 + \frac{5}{24}x^4.$$

- (a) Sett inn $x = 1$ og $x = 2$ og kontroller at polynomet treffer y nøyaktig. (Det gjør det for alle fem punktene.)
- (b) Hva blir RSS og R^2 for denne modellen?
- (c) Hva skjer om du prøver å regne ut $\text{RSE} = \sqrt{\text{RSS}/(n - p - 1)}$ her?
- (d) Bruk begge modellene til å predikere ved $x = 6$ og ved $x = 0$. Den lineære modellen fra A1 var $\hat{y} = 2,2 + 0,6x$. Kommentér.
- (e) Hvilken modell ville du valgt, og hvorfor? Knytt svaret til bias og varians.

C3. Utled bias–variens-dekomposisjonen

La $Y = f(X) + \epsilon$ med $E(\epsilon) = 0$, $\text{Var}(\epsilon) = \sigma^2$, og la ϵ være uavhengig av treningsdataene. Vi har estimert $\hat{f}$ på et treningssett og skal predikere i et fast punkt x_0 , med utfall $y_0 = f(x_0) + \epsilon$.

Vis at

$$E(y_0 - \hat{f}(x_0))^2 = \text{Var}(\hat{f}(x_0)) + [\text{Bias}(\hat{f}(x_0))]^2 + \sigma^2, \quad \text{Bias}(\hat{f}(x_0)) = E[\hat{f}(x_0)] - f(x_0).$$

Hint 1: Sett inn $y_0 = f(x_0) + \epsilon$ og gang ut. *Hint 2:* Legg til og trekk fra $E[\hat{f}(x_0)]$.

C4. Bias–variens med tall

En simulering gir følgende for fem metoder med økende fleksibilitet, i et gitt punkt x_0 . Den irreducible feilen er $\sigma^2 = 1,0$.

Fleksibilitet	1	2	3	4	5
Kvadrert skjevhet	4,0	1,6	0,6	0,3	0,2
Varians	0,2	0,5	1,0	2,2	4,0

- (a) Regn ut forventet test-MSE for hver av de fem.
- (b) Hvilken fleksibilitet er best? Skisser hvordan de tre komponentene og summen ser ut som funksjon av fleksibilitet.
- (c) Trenings-MSE synker monotont: 4,5; 2,4; 1,5; 0,9; 0,4. Hvilken modell ville du valgt om du bare hadde sett trenings-MSE?
- (d) Kan forventet test-MSE noen gang bli mindre enn 1,0 her? Begrunn.

C5. Når testsettet lyver

En analytiker har $n = 200$ observasjoner og $p = 500$ prediktorer, som alle er ren støy og uten sammenheng med y . Hun gjør følgende:

1. kjører 500 enkle regresjoner på *hele* datasettet og plukker ut de fem prediktorene med lavest p -verdi,
 2. deler så dataene i et treningssett og et testsett,
 3. tilpasser en modell med de fem utvalgte prediktorene på treningssettet, og rapporterer feilen på testsettet.
- (a) Hvis alle 500 prediktorene er ren støy, hvor mange av dem vil vi likevel forvente å finne «signifikante» på 5 %-nivå?
 - (b) Forklar hvorfor testfeilen hennes blir for optimistisk.
 - (c) Hva er den riktige rekkefølgen på stegene?

4 Del D – Klassifikasjon (4.1–4.2)

D1. Feilrate og den late klassifikatoren

I `Default`-datasettet er det 10 000 kunder, og 333 av dem misligholder kredittkortgjelda. En modell gir følgende forvekslingstabell på treningsdataene:

Predikert	Faktisk		Sum
	Nei	Ja	
Nei	9644	252	9896
Ja	23	81	104
Sum	9667	333	10 000

- (a) Regn ut den totale feilraten.
- (b) Regn ut feilraten til en «lat» klassifikator som alltid sier «nei».
- (c) Hvor stor andel av dem som faktisk misligholder, fanger modellen opp?
- (d) Er modellen god? Diskuter kort hva slags feil som er dyrest for en bank.

D2. Hvorfor ikke lineær regresjon?

ISLP 4.2.

En pasient kommer inn på akuttmottaket, og vi vil predikere diagnosen ut fra symptomer. Det er tre mulige diagnoser: hjerneslag, overdose og epileptisk anfall.

- (a) En student foreslår å kode responsen som $Y = 1, 2, 3$ og kjøre vanlig lineær regresjon. Skriv opp en *annen* rekkefølge på kodingen. Vil de to modellene gi samme prediksjoner? Hva sier det oss?
- (b) Hvilke to antakelser om diagnosene ligger implisitt i kodingen $Y = 1, 2, 3$?
- (c) Anta nå at det bare er to klasser, kodet $Y = 0$ og $Y = 1$. Vis at hvis vi i stedet koder dem $Y = 1$ og $Y = 2$, blir de tilpassede verdiene fra minste kvadraters metode bare forskjøvet med 1, slik at klassifiseringen ved en passende terskel blir identisk. *Hint:* hva skjer med $\hat{\beta}_0$ og $\hat{\beta}_1$ når y erstattes av $y + 1$?
- (d) Hvilket problem gjenstår likevel med lineær regresjon i to-klasetilfellet?

D3. Den lineære sannsynlighetsmodellen på Default

Vi koder `default` som 0/1 og kjører vanlig minste kvadraters regresjon på `balance`. Resultatet er

$$\hat{p}(\text{balance}) = -0,0752 + 0,00012987 \cdot \text{balance}.$$

- (a) Regn ut $\hat{p}$ for saldoene 250, 1000 og 2500 dollar.
- (b) For hvilke saldoer er $\hat{p} < 0$? (Løs $-0,0752 + 0,00012987x = 0$.)
- (c) I datasettet har 3123 av 10 000 kunder saldo under denne grensen. Hvor stor andel av kundene får altså en negativ estimert sannsynlighet?
- (d) Ved hvilken saldo ville $\hat{p}$ passert 1? Høyeste observerte saldo er 2654. Forklar hvorfor problemet med $\hat{p} > 1$ ikke dukker opp i akkurat dette datasettet, men likevel er et prinsipielt problem.
- (e) Hva er det den logistiske funksjonen gjør annerledes?

D4. KNN og dimensjonens forbannelse

ISLP 4.8, oppgave 4.

Vi vil predikere responsen til en testobservasjon ved hjelp av de nærmeste naboene. Alle prediktorene er jevnt fordelt på $[0, 1]$.

- (a) Med $p = 1$ bruker vi de observasjonene som ligger innenfor 10 % av X -området rundt testpunktet. Hvor stor andel av observasjonene bruker vi i gjennomsnitt?
- (b) Med $p = 2$ bruker vi observasjoner som ligger innenfor 10 % av området for *begge* variablene. Hvor stor andel nå?
- (c) Samme spørsmål med $p = 100$.
- (d) Bruk (a)–(c) til å forklare hvorfor KNN fungerer dårlig når p er stor.
- (e) Anta at vi i stedet vil ha en terning i p dimensjoner som i gjennomsnitt inneholder 10 % av observasjonene. Hvor lang må hver side være når $p = 1, 2$ og 100 ? Kommenter.

D5. Bayes-klassifikatoren og feilgulvet

Anta at vi kjenner de sanne sannsynlighetene $\Pr(Y = 1 \mid X = x)$ i fem testpunkter:

Testpunkt	1	2	3	4	5
$\Pr(Y = 1 \mid X = x)$	0,05	0,30	0,55	0,80	0,95

- (a) Hva predikerer Bayes-klassifikatoren i hvert punkt?
- (b) Feilsannsynligheten i punkt x er $1 - \max\{p, 1 - p\} = \min\{p, 1 - p\}$. Regn den ut i hvert punkt.
- (c) Hva er den gjennomsnittlige Bayes-feilraten over de fem punktene?
- (d) Kan en bedre metode komme under dette tallet? Hva svarer Bayes-feilraten til i regresjonssammenheng?

5 Del E – Den logistiske modellen (4.3.1–4.3.2)

E1. Odds, sannsynlighet og log-odds

Deloppgave (a) og (b) er ISLP 4.8, oppgave 9.

- (a) I gjennomsnitt: hvor stor andel av dem som har odds 0,37 for å misligholde kredittkortgjelda, kommer faktisk til å misligholde?
- (b) En kunde har 16 % sannsynlighet for å misligholde. Hva er oddsen?
- (c) Fyll ut tabellen:

p	0,10	0,25	0,50	0,75	0,90
$\text{odds} = p/(1 - p)$					
$\text{logit} = \log(p/(1 - p))$					

- (d) Hvilke verdier kan odds ta? Hvilke verdier kan logit ta? Hvorfor er det siste praktisk når vi skal sette en lineær modell på høyresiden?

E2. Fra sannsynlighet til odds til logit

ISLP 4.8, oppgave 1.

Vis at den logistiske modellen

$$p(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}} \quad (4.2)$$

er ekvivalent med

$$\frac{p(X)}{1 - p(X)} = e^{\beta_0 + \beta_1 X} \quad (4.3)$$

og dermed med $\log(p(X)/(1 - p(X))) = \beta_0 + \beta_1 X$ (4.4).

E3. Sannsynligheten for A

ISLP 4.8, oppgave 6.

For en gruppe studenter er X_1 = antall timer lest, X_2 = karaktersnitt fra bachelor, og $Y = 1$ hvis studenten får A. Logistisk regresjon gir $\hat{\beta}_0 = -6$, $\hat{\beta}_1 = 0,05$, $\hat{\beta}_2 = 1$.

- (a) Estimer sannsynligheten for at en student som leser 40 timer og har snitt 3,5 får A.
- (b) Hvor mange timer må denne studenten lese for å ha 50 % sjanse for A?
- (c) Hvor mange timer må en student med snitt 2,5 lese for å ha 50 % sjanse? Kommenter forskjellen.

E4. Default: koeffisienten er *ikke* en endring i sannsynlighet

Tabell 4.1 i boka gir følgende for logistisk regresjon av **default** på **balance**:

$$\hat{\beta}_0 = -10,6513, \quad \hat{\beta}_1 = 0,0055, \quad \text{SE}(\hat{\beta}_1) = 0,0002.$$

- (a) Regn ut $\hat{p}$ for saldo \$1000 og \$2000.
- (b) Ved hvilken saldo er $\hat{p} = 0,5$?
- (c) Regn ut $\hat{p}$ for saldo 1100 og for 2000, og finn hvor mye sannsynligheten øker ved 100 dollar mer i saldo, når man starter på henholdsvis 1000 og 1900. Hvorfor er de to tallene så forskjellige?
- (d) Hva blir oddsen multiplisert med når saldoen øker med 100 dollar?
- (e) Regn ut z -observatoren for $H_0 : \beta_1 = 0$.

E5. Studenter, saldo og et fortegn som snur

To modeller på **Default**-dataene:

Tabell 4.2: bare studentstatus		Tabell 4.3: saldo, inntekt og studentstatus	
Konstantledd	-3,5041	Konstantledd	-10,8690
student[Yes]	0,4049	balance	0,00574
		income (i tusen \$)	0,00300
		student[Yes]	-0,6468

- (a) Bruk tabell 4.2 til å regne ut $\hat{p}$ for en student og for en ikke-student.

- (b) Bruk tabell 4.3 til å regne ut $\hat{p}$ for en student og en ikke-student som begge har saldo \$1500 og inntekt \$40 000.
- (c) Koeffisienten på **student** er positiv i den første modellen og negativ i den andre. Er én av dem feil? Forklar hva som skjer.
- (d) Formulér i én setning hva hver av de to modellene faktisk svarer på.

E6. Rimelighet (likelihood) med tre kunder

Logistisk regresjon estimeres ikke med minste kvadraters metode, men med *sannsynlighetsmaksimering*: vi velger de β -ene som gjør de observerte utfallene mest sannsynlige. Rimelighetsfunksjonen er

$$\ell(\beta_0, \beta_1) = \prod_{i: y_i=1} p(x_i) \prod_{i': y_{i'}=0} (1 - p(x_{i'})).$$

Vi har tre kunder:

Kunde	Saldo x_i	Misligholdt? y_i
1	1000	0
2	2000	1
3	1500	0

Vurder to kandidater: $A = (\beta_0, \beta_1) = (-10,65; 0,0055)$ og $B = (-5,00; 0,0025)$.

- (a) Regn ut $p(x_i)$ for alle tre kundene under hver av de to kandidatene.
- (b) Regn ut ℓ for hver kandidat. Hvilken foretrekker metoden?
- (c) Hvorfor bruker vi i praksis $\log \ell$ i stedet for ℓ ?
- (d) Hva er analogien til kapittel 3? Hva minimerte vi der, og hva maksimerer vi her?

Oppgavetekster fra boka er gjengitt i forkortet og bearbeidet form.
Se ISLP avsnitt 3.7 og 4.8 for de fullstendige formuleringene.