

Statistisk læring for økonomer

Kapittel 2: Det teoretiske rammeverket

Tema: Estimering, Prediksjon og The Bias-Variance Trade-off

Agenda

1. Hvorfor estimere f ? (Prediksjon vs. Inferens)
2. Hvordan estimere f ? (Parametrisk vs. Ikke-parametrisk)
3. Trade-off: Fleksibilitet vs. Tolkbarhet.
4. Evaluering av nøyaktighet (MSE).
5. Bias-Variance Trade-off.

Mål for dagen: Forstå hvorfor en mer kompleks modell ikke alltid er bedre.

Feilledets natur

Vi husker modellen: $Y = f(X) + \epsilon$.

Hvis vi bruker en modell $\hat{f}$ for å predikere Y , får vi $\hat{Y} = \hat{f}(X)$.

Notater:

Feilledets natur

Vi husker modellen: $Y = f(X) + \epsilon$.

Hvis vi bruker en modell $\hat{f}$ for å predikere Y , får vi $\hat{Y} = \hat{f}(X)$.

Forventet feil (kvadrert) kan splittes i to deler:

$$E[Y - \hat{Y}]^2 = \underbrace{[f(X) - \hat{f}(X)]^2}_{\text{Reducible error}} + \underbrace{\text{Var}(\epsilon)}_{\text{Irreducible error}}$$

- **Reducible:** Kan minskes ved å velge en bedre modell ($\hat{f}$).
- **Irreducible:** Støy i dataene vi aldri blir kvitt (målefeil, utelatte variabler).

Notater:

To hovedmål med analyse

Hvorfor gjør vi dette? Økonomer og Data Scientists har ofte ulike mål.

Viktig Info: 1. Prediksjon

- Fokus: $\hat{Y}$.
- Vi bryr oss lite om hvordan f ser ut, bare at den treffer blink.
- Eks: Børskurser, Spam-filter.
- Black box"metoder er OK.

Eksempel: 2. Inferens (Slutning)

- Fokus: Forstå forholdet mellom X og Y .
- Hvilke X påvirker Y ? Positivt eller negativt?
- Eks: Hvordan påvirker utdanning lønn?
- Krever enkle, tolkbare modeller.

I dette kurset skal vi gjøre begge deler, men mye fokus på prediksjon.

Hvordan estimere f ? Metode A: Parametrisk

To-steps prosess:


1. Vi *antar* en form på funksjonen (f.eks. lineær).

$$f(X) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots$$

2. Vi bruker dataene til å estimere parametrene (β).

Fordeler: Enkelt, krever færre data, lett å tolke.

Ulemper: Antakelsen er ofte feil! (Virkeligheten er sjelden en rett linje).




Metode B: Ikke-Parametrisk

Vi antar *ingen* bestemt form på f . Vi prøver å finne en kurve som går så nærme datapunktene som mulig, uten å være for "vinglete".


Fordeler: Veldig fleksibelt, kan tilpasse seg komplekse mønstre.

Ulemper: Krever *mye* data. Fare for "Overfitting".



Trade-off: Prediksjon vs. Tolkbarhet

Det er en fundamental motsetning mellom fleksibilitet og tolkbarhet.



Spørsmål: Hvorfor vil vi ikke alltid velge den mest fleksible metoden?

Hvordan vet vi om modellen er god?

I regresjon bruker vi oftest Mean Squared Error (MSE).

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{f}(x_i))^2$$


- **Training MSE:** Beregnet på dataene vi brukte til å lage modellen.
- **Test MSE:** Beregnet på *nye* data modellen ikke har sett før.

Viktig Info: Viktig regel

Vi bryr oss egentlig **kun** om Test MSE! Det hjelper ikke å huske pensum (Training) hvis du stryker på eksamen (Test).

Fleksibilitet vs. MSE

Hva skjer med feilen når modellens fleksibilitet øker?



- **Training MSE:** Går *alltid* ned når fleksibiliteten øker.
- **Test MSE:** Går ned først, men så opp igjen (U-form). Hvorfor?

The Bias-Variance Trade-off

Dette er den matematiske forklaringen på U-formen.

For et gitt punkt x_0 , kan forventet test-MSE dekomponeres slik:

$$E(y_0 - \hat{f}(x_0))^2 = \text{Var}(\hat{f}(x_0)) + [\text{Bias}(\hat{f}(x_0))]^2 + \text{Var}(\epsilon)$$

- **Bias:** Feilen som oppstår ved å bruke en for enkel modell (f.eks. å anta lineær når sannheten er buet). *Minker med økt fleksibilitet.*
- **Varians:** Hvor mye $\hat{f}$ ville endret seg hvis vi byttet datasett. *Øker med økt fleksibilitet.*

Vi søker punktet der summen av Bias og Varians er lavest!

Oppsummering Kapittel 2

- Statistisk læring handler om å estimere f .
- **Prediksjon** vs. **Inferens** styrer metodevalget.
- **Overfitting**: Når modellen følger støyen (Training error er lav, Test error er høy).
- **Bias-Variance Trade-off**: Nøkkelen til å velge riktig modellkompleksitet.

Neste gang: Kapittel 3 - Lineær Regresjon (Vår første parametriske metode).