

Statistisk læring for økonomer

Forelesning 1: Introduksjon & Motivasjon

Faglærer: Markus J. Aase
Tromsø

Dagens Plan

- **Del 1:** Praktisk informasjon om kurset (Eksamen, Prosjekt, Pensum).
- **Del 2:** Hva er *Data Science* og Statistisk Læring?
- **Del 3:** Motiverende eksempler (fra Kapittel 1 i boka).
 - Lønningsdata (Regresjon/Prediksjon)
 - Aksjemarkedet (Klassifisering)
 - Gen-data (Klynger/Unsupervised)

Notater:

Om emnet

Faglærer: Markus Aase (Spørsmål om fag/prosjekt)

Admin: hhcampus@hjelp.uit.no

Viktig Info: Vurdering og Karakter

- **Prosjektarbeid (40%):**
 - Grupper på 1-2 personer.
 - Bruk Python eller R.
- **Muntlig eksamen (60%):**
 - Tester forståelse av konsepter.
- **Arbeidskrav:** En presentasjon av prosjektbeskrivelse (Godkjent/Ikke godkjent).

Eksempel: Læringsressurser


- *An Introduction to Statistical Learning* (ISLP/ISLR).
 - Finnes gratis her: <https://www.statlearning.com/>
 - Både i R og Python
- Videoforelesninger (se forelesningsplan).
- Disse slidsene. Legges ut med mine notater, etter hver forelesning.
- Kodefiler (Python/R).

Hva er Statistisk Læring?

"A vast set of tools for understanding data."


Hvorfor trenger økonomer dette?

- Tradisjonell økonometri vs. *Data Science*
- Fokusering: Fra *kausalitet* og *inferens* (slutning) → *prediksjon* og *mønstergjenkjenning*.
- Håndtere store og komplekse datasett (**Big Data**)



Eksempel: 1: Wage Data (Lønn)

I boka, kapittel 1, motiveres statistisk læring gjennom **Wage Data** - som omhandler, alder, år og utdanning - sett opp mot lønn.




Figur 1.1 fra ISLP: Lønn som funksjon av alder, år og utdanning ((James et al., 2023))

Eksempel: 1: Wage Data (Lønn)

Mål: Forstå sammenhengen mellom alder, utdanning og lønn.

Type problem: **Regresjon** (kontinuerlig variabel).



Spørsmål: Er sammenhengen lineær?

Eksempel: Eksempel 2: Stock Market Data


Mål: Predikere om S&P 500 går **OPP** eller **NED** i morgen.

Type problem: **Klassifisering** (kategorisk variabel).

Indeksverdi

Opp/Ned?

Dag (t)




Figur 1.2 fra ISLP: Boxplots fra S&P 500 aksjen ((James et al., 2023))

Eksempel: Eksempel 3: Gene Expression Data (NCI60)

Mål: Finne grupper av kreftceller som ligner på hverandre.

Type problem: **Ikke-veiledet læring (Unsupervised/Clustering)**.

Vi vet ikke *fasiten* (Y) på forhånd.



Poeng: Vi ser etter struktur i dataene uten å vite fasiten.

Veiledet og ikke-veiledet læring

Boka og kurset vil diskutere **Veiledet læring** og **Ikke-veiledet læring**.

Datasett vi skal bruke

Boka og kurset benytter virkelige (eller realistiske) datasett for å illustrere metodene. Alle ligger tilgjengelig i Python-pakken ISLP.

Python Kode

```
from ISLP import load_data

# Laste inn et datasett
wage = load_data('Wage')
market = load_data('Smarket')
```

- **Wage:** Sammenheng mellom lønn, utdanning, alder og år (Mid-Atlantic US). (*Regresjon*)
- **Smarket:** Daglige investeringsavkastninger for S&P 500 (2001-2005). (*Klassifisering*)
- **Advertising:** Salg av et produkt vs. budsjett for TV, Radio og Avis. (*Lineær Regresjon*)
- **Default:** Kredittkort-data. Hvem misligholder gjelden sin? (*Veldig relevant for økonomer!*)
- **NCI60:** Gen-uttrykk fra 64 kreftceller. (*Klynger/Unsupervised*)

Vi skal bruke (blant annet) disse gjennom hele semesteret for å teste modellene våre. Alle datasettene står listet i boka.

Datasett i R

For de av dere som bruker R, finnes de samme datasettene i pakken ISLR.

R Kode

```
# Installer pakken først: install.packages("ISLR2")

library(ISLR2)

# Last inn datasettene
data('Wage')
data('Smarket')

# Nå er variablene 'Wage' og 'Smarket' tilgjengelige i minnet
```

- **Merk:** I R trenger man ofte ikke tilegne datasettet til en variabel (som `wage = ...`) slik som i Python. Når du kjører `data("Wage")`, dukker objektet `Wage` opp i miljøet ditt automatisk.
- Igjen, valg av programmeringsspråk er opp til dere!

Matematisk Notasjon (Kap 1)

For å kunne snakke presist om metodene, må vi definere språket vårt (Lineær Algebra).

Viktig Info: Grunnleggende størrelser

- n : Antall observasjoner (rader i datasettet).
- p : Antall variabler/predikatorer (kolonner).

Vektorer: Vi lar X betegne en input-vektor (en rad med data):

$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{pmatrix}$$

Notat: I dette kurset skriver vi ofte vektorer som kolonner.

Datamatriksen $\mathbf{X}$

Vi samler alle våre n observasjoner i en matrise $\mathbf{X}$.

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

Spørsmål:

- Hva representerer rad i ? (Svar: En enkelt person/bedrift/observasjon).
- Hva representerer kolonne j ? (Svar: En variabel, f.eks. "Alder").

Python Kode

```
from ISLP import load_data

# Laste inn et datasett
wage = load_data('Wage')
# Viser de første fem radene
wage.head()
```

Tabell 1: Utdrag fra Wage-datasettet (ISLP)

year	age	maritl	race	education	...	wage
2006	18	1. Never Married	1. White	1. < HS Grad	...	75.043154
2004	24	1. Never Married	1. White	4. College Grad	...	70.476020
2003	45	2. Married	1. White	3. Some College	...	130.982177
2003	43	2. Married	3. Asian	4. College Grad	...	154.685293
2005	50	4. Divorced	1. White	2. HS Grad	...	75.043154

Den Fundamentale Modellen

Målet med statistisk læring er å finne sammenhengen mellom X (input) og Y (output).

Vi antar at det finnes en sann, men ukjent sammenheng:


$$Y = f(X) + \epsilon$$

- $f(X)$: Den *systematiske* informasjonen som X gir om Y . Det er denne vi prøver å estimere ($\hat{f}$).
- ϵ (**epsilon**): Det tilfeldige feilleddet (*error term*).

Notater:

Visualisering av Y

Hvordan ser dette ut i 2D ($p = 1$)?



Viktig Info: Hvorfor kan vi ikke treffe perfekt?

Selv om vi visste den sanne f , ville vi fortsatt bomme på Y på grunn av ϵ . Dette kalles **Irreducible Error**.

Oppsummering

- Statistisk læring er verktøykassen vår for moderne dataanalyse.
- Vi skiller ofte mellom:
 1. **Veiledet (Supervised):** Vi har en fasit (Y) (f.eks. Lønn, Børsretning).
 2. **Ikke-veiledet (Unsupervised):** Vi leter etter mønstre (f.eks. Klynger).
- **Neste forelesning:** Kapittel 2 – Det teoretiske rammeverket ($Y = f(X) + \epsilon$).

Referanser

Gareth James, Daniela Witten, Trevor Hastie, Robert Tibshirani, and Jonathan Taylor. *An Introduction to Statistical Learning: with Applications in Python*. Springer Nature, New York, 2023.