

SOK-1305 Statistisk læring for økonomer

Kapittel 3.1: Enkel lineær regresjon



Tema: Estimering av koeffisienter, hypotesetesting og modellpresisjon

Agenda

modelleres som / tilnærmet

1. Den lineære modellen: $Y \approx \beta_0 + \beta_1 X$.
2. Estimering av parametre: Minste kvadraters metode (OLS).
3. Hvor gode er estimatene? (Standardfeil og Konfidensintervaller).
4. Hypotesetesting (t -test og p -verdi).
5. Hvor god er modellen? (R^2 og RSE).

β_0, β_1

$$Y = f(x) + \varepsilon$$
$$\hat{y} = \hat{f}(x)$$

↑
estimat på den
sanne funksjon $f(x)$

Mål for dagen: $\left[\begin{array}{c} X \\ Y \end{array} \right]$ Lære å kvantifisere forholdet mellom en prediktor og en respons.


Modellen

Vi antar at det er et lineært forhold mellom X og Y :


$$Y = \beta_0 + \beta_1 X + \epsilon$$

- β_0 (Intercept): Forventet verdi av Y når $X = 0$.
- β_1 (Stigningstall): Endring i Y per enhets endring i X .
- ϵ (Feilledd): Alt modellen ikke fanger opp (støy).

Notater (Populasjon vs. Utvalg):



• verden er aldri perfekt lineær.



Notater:

<u>Populasjon (observerbar)</u>		<u>Utvalg (regnes ut)</u>	
parameter	β_0, β_1	estimat:	$\hat{\beta}_0, \hat{\beta}_1$
sanne funksjon	f	estimer funksjon:	$\hat{f}$
feil/edd	ε_i	residual:	e_i
forventning:	μ	gj. snitt:	$\bar{y}$

Estimering: Ordinary Least Squares (OLS)


Vi har data $(x_1, y_1), \dots, (x_n, y_n)$. Vi ønsker å finne $\hat{\beta}_0$ og $\hat{\beta}_1$ slik at den estimerte linjen $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ ligger nærmest mulig datapunktene.

Vi minimerer **Residual Sum of Squares (RSS)**:

$$RSS = e_1^2 + e_2^2 + \dots + e_n^2$$

der $e_i = y_i - \hat{y}_i$ er residualet for observasjon i .

$$\hat{\beta}_0 + \hat{\beta}_1 x_1$$



linear
regression

$$RSS = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + \dots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

Estimatorene

Ved å bruke litt matematikk, kan vi vise at det som minimerer β_0 og β_1 er:


$$\bar{y} = \frac{\sum_{i=1}^n y_i}{n} \quad (\text{utvalgs-} \\ \text{gj.snitt})$$

$$\bar{x} = \frac{\sum x_i}{n}$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Notater: Hva betyr disse intuitivt?



Notater:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

Vi ønsker å finne $\hat{\beta}_0$ og $\hat{\beta}_1$ som

minimerer $RSS = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$

kjernerregel

$$f(x) = g(h(x))$$

$$f'(x) = g'(h) \cdot h'(x)$$

1) Deriverer mhp. β_0 :

$$\frac{\partial RSS}{\partial \beta_0} = \frac{\partial}{\partial \beta_0} \sum (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

$\hat{\beta}_1 =$ hjemme (else :)

bruk $\Rightarrow -2 \sum (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)$
kjernerregel

for å finne minimum, sett lik 0

$$-2 \sum (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$

$$\sum y_i - n \cdot \hat{\beta}_0 - \hat{\beta}_1 \sum x_i = 0 \Rightarrow$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Eksempel: Salg vs. TV-reklame

Fra boka (ISLP Tabell 3.1): Vi ser på effekten av TV-reklame på salg basert på 200 observasjoner. Her bruker vi Advertising datasettet. Her er salgsvariablene i tusen enheter, og TV variabelen er i tusen-dollar.

Variabel	Koeffisient ($\hat{\beta}$)	Std. error	t-statistikk	p-verdi
$\hat{\beta}_0$ Intercept	7.0325	0.4578	15.36	< 0.0001
$\hat{\beta}_1$ TV	0.0475	0.0027	17.67	< 0.0001

$H_0: \beta_1 = 0$
 $H_a: \beta_1 \neq 0$

Tolkning:

- Hvis vi bruker 0 kr på TV-reklame, forventer vi et salg på ca. 7033 enheter.
- For hver ekstra \$1000 brukt på TV-reklame, øker salget med ca. 47.5 enheter.

Viktig Info: Viktig

Er $\hat{\beta}_1$ bare et resultat av tilfeldigheter i utvalget, eller er det en reell sammenheng?

Hvor nøyaktig er $\hat{\beta}$?

$\hat{\beta}_0$ og $\hat{\beta}_1$ er estimater basert på et utvalg. Hvor mye ville de variert om vi tok et nytt utvalg?

Vi bruker **Standardfeil (SE)**:

$$SE(\hat{\beta}_1)^2 = \frac{\sigma^2}{\sum (x_i - \bar{x})^2}$$

- Jo mer data (n), jo lavere SE.
- Jo mer spredning i X , jo lavere SE (hvorfor?).
- **Konfidensintervall:** $\hat{\beta}_1 \pm 2 \cdot SE(\hat{\beta}_1)$ inneholder den sanne β_1 med ca. 95% sannsynlighet.

$$SE(\hat{\beta}_1) = \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{\sum (x_i - \bar{x})^2} \right]$$

3.1.2!
baker

Er det en sammenheng?

Vi tester nullhypotesen mot alternativhypotesen:

- $H_0 : \beta_1 = 0$ (Ingen sammenheng mellom X og Y)
- $H_a : \beta_1 \neq 0$ (Det er en sammenheng)

null hypotese
alt. hypotese

Vi beregner en t -statistikk:

$$t = \frac{\hat{\beta}_1 - 0}{SE(\hat{\beta}_1)}$$

P-verdi: Sannsynligheten for å observere en så stor t dersom H_0 er sann.

- Liten p-verdi (< 0.05) $\implies$ Vi forkaster H_0 . Det er en statistisk signifikant sammenheng.

Residual Standard Error (RSE)

RSE er et estimat på standardavviket til feilleddet ϵ . Det forteller oss hvor mye modellen bommer i gjennomsnitt.

$$\text{La } RSE = \beta_{ra} \text{ :)$$

- RSE måles i samme enhet som Y .
- Det er et mål på lack of fit".


$$RSE = \sqrt{\frac{1}{n-2} RSS}$$

$$RSS = \sum e_i^2 = \sum (y_i - \hat{y}_i)^2$$

Eksempel Advertising: RSE er ca. 3.26 (salget varierer med ca. 3260 enheter rundt regresjonslinjen).

Husk: $Y = \beta_0 + \beta_1 X + \epsilon$, at ved hver obs. er det også et feilledd ϵ .

→
Samme



Så det er grunnar til at den ekte reg. linja Y , selv hvis β_0, β_1 er kjent, ville ikke den predikert Y perfekt fra X .

R^2 - Coefficient of Determination

R^2 måler andelen av variasjonen i Y som forklares av modellen.

$$R^2 = \frac{TSS - RSS}{TSS} = 1 - \frac{RSS}{TSS}$$

der $TSS = \sum (y_i - \bar{y})^2$ er den totale variasjonen i Y .

- $R^2 \approx 1$: Modellen forklarer nesten all variasjon.
- $R^2 \approx 0$: Modellen forklarer nesten ingenting.
- I enkel lineær regresjon er $R^2 = r^2$ (korrelasjonen i annen).

$$TSS = \sum (y_i - \bar{y})^2$$

Total varias i
responser y

Hva har vi lært?

I kapittel 2 snakket vi om målene med analysen.

- Inferens: Vi ser på p-verdien og konfidensintervaller for β_1 for å forstå *om* og *hvordan* TV-reklame påvirker salg.
- Prediksjon: Vi bruker $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ for å gjette salget neste år hvis vi vet reklamebudsjettet.

Notater: Hvorfor er prediksjonsintervaller alltid bredere enn konfidensintervaller for gjennomsnittet?

Oppsummering Kapittel 3.1

- Enkel lineær regresjon antar $Y \approx \beta_0 + \beta_1 X$.
- Vi bruker OLS for å finne de besteestimatene.
- Standardfeil forteller oss om usikkerheten i estimatene.
- t -tester brukes for å sjekke om en variabel faktisk har betydning.
- R^2 og RSE brukes for å evaluere hvor godt linjen passer dataene.

Neste gang: Multippel Lineær Regresjon - hva skjer når vi har mer enn én prediktor?