

SOK-1305 Statistisk læring for økonomer

Kapittel 3.2 – 3.5: Multippel lineær regresjon

Tema: Mer enn én prediktor, interaksjoner og modellproblemer

Agenda

1. Multippel lineær regresjon: $Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p + \epsilon$.
2. Er i det hele tatt modellen nyttig? (F -test).
3. Variabelseleksjon: Hvilke X -er bør være med?
4. Kvalitative prediktorer (Dummy-variabler).
5. Utover linearitet: Interaksjonsledd og polynomiske ledd.
6. Potensielle utfordringer (Kollinearitet, Outliers).

Modellen

I virkeligheten påvirkes Y av mange faktorer samtidig.

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p + \epsilon$$

Tolkning: β_j er den gjennomsnittlige effekten på Y av en enhets økning i X_j , gitt at alle andre prediktorer holdes konstante (*ceteris paribus*).

Eksempel: Salg

$$\text{Salg} = \beta_0 + \beta_1(\text{TV}) + \beta_2(\text{Radio}) + \beta_3(\text{Avis}) + \epsilon$$

Hva skjer hvis vi bare ser på Avis alene vs. i en multippel modell?

Eksempel: Notater

Eksempel: Noen viktige spørsmål


Eksempel: Multippel regresjon: alle tre mediene

	Koeffisient	Std. feil	<i>t</i>	<i>p</i> -verdi
Intercept	2.939	0.3119	9.42	< 0.0001
TV	0.046	0.0014	32.81	< 0.0001
radio	0.189	0.0086	21.89	< 0.0001
newspaper	−0.001	0.0059	−0.18	0.8599

Eksempel: Multippel regresjon: alle tre mediene


Forlengs

start tomt, legg til
én om gangen




Baklengs

start fullt, fjern
én om gangen



Blandet

legg til som forlengs,
men angre ved behov



Hvorfor blandet finnes. Forlengs seleksjon er *grådig*: den tar det beste valget i hvert steg og ser seg aldri tilbake. En variabel som var nyttig tidlig kan bli overflødig når andre kommer inn — akkurat som **newspaper** i **Advertising**, som er klart signifikant alene, men faller til $p = 0.86$ når **radio** er med. Blandet seleksjon utfører forlengs- og baklengssteg om hverandre til alle variabler i modellen har lav p -verdi, og alle utenfor ville fått høy p -verdi om de ble lagt til.

Når $p > n$. Baklengs seleksjon kan ikke brukes, siden den fulle modellen ikke lar seg estimere med minste kvadraters metode. Forlengs kan alltid brukes.

R^2 kan aldri synke

Legger vi til en variabel til, går R^2 **alltid** opp — selv om variabelen er ren støy. R^2 kan derfor ikke brukes til å velge mellom modeller med ulikt antall variabler.

Hvorfor? Den gamle modellen er ikke borte — den ligger fortsatt inne i den nye, som tilfellet $\hat{\beta}_{\text{ny}} = 0$. Minste kvadraters metode leter i en *større* mengde, og et minimum over en større mengde kan aldri bli større:

$$\min_{\mathcal{M}_{p+1}} RSS \leq \min_{\mathcal{M}_p} RSS \implies R^2 = 1 - \frac{RSS}{TSS} \text{ kan bare stige.}$$

Eksempel: Advertising (ISLP s. 88)

Modell	R^2	Justert R^2
TV	0.61000	0.60803
TV + radio	0.89719	0.89615
TV + radio + newspaper	0.89720	0.89563

radio gir et reelt sprang på +0.287. newspaper gir +0.00001 — en forbedring i femte desimal, og p -verdien er 0.86.

Viktig Info: Justert R^2

Justert R^2 straffer antall variabler, og **synker** i siste steg (−0.00052). Den ser at newspaper ikke betalte for plassen sin. R^2 måler tilpasning til treningsdataene — ikke om modellen er god.

Notater: hva skjer med R^2 hvis vi legger til en kolonne med tilfeldige tall?

F-testen

Når vi har mange variabler, kan vi ikke bare se på hver enkelt t -test. Vi må sjekke om *noen* av variablene er nyttige.

Hypotese:

- $H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0$
- $H_a : \text{Minst én } \beta_j \neq 0$

$$F = \frac{(TSS - RSS)/p}{RSS/(n - p - 1)}$$

Viktig Info: Hvorfor ikke bare se på p-verdier?

Hvis vi har 100 variabler som egentlig ikke påvirker Y , vil ca. 5 av dem se signifikante"ut ved en tilfeldighet (5% nivå). F -testen korrigerer for dette!

R^2 vs Justert R^2

Hva skjer med R^2 når vi legger til flere variabler?

- R^2 : Vil *alltid* øke (eller være lik) når vi legger til variabler, selv om de er bare støy.
- **Justert R^2** : Straffer oss for å legge til unyttige variabler.

Notater om variabelseleksjon (Forward, Backward, Mixed):

Dummy-variabler

Hva om X ikke er et tall, men en kategori? (F.eks. Kjønn, Region, Student).

Vi lager en indikatorvariabel:

$$x_i = \begin{cases} 1 & \text{hvis person } i \text{ er student} \\ 0 & \text{hvis ikke} \end{cases}$$

Modellen blir da:

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i = \begin{cases} \beta_0 + \beta_1 + \epsilon_i & \text{hvis student} \\ \beta_0 + \epsilon_i & \text{hvis ikke} \end{cases}$$

Tolkning: β_1 er den gjennomsnittlige forskjellen mellom gruppene.

Utover det additive: Interaksjonsledd

Den standard lineære modellen antar at effekten av X_1 er uavhengig av X_2 . Men hva om de forsterker hverandre?

Eksempel: Kanskje TV-reklame virker bedre hvis vi også kjører Radio-reklame samtidig?

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \underbrace{\beta_3 (X_1 \cdot X_2)}_{\text{Interaksjon}} + \epsilon$$


Viktig Info: Hierarkisk prinsipp

Hvis vi inkluderer et interaksjonsledd $X_1 \cdot X_2$, må vi også inkludere hovedeffektene X_1 og X_2 i modellen, selv om p-verdiene deres er høye.

Polynomisk regresjon

Hvis forholdet ser ut som en bue, kan vi legge til kvadrerte ledd.

$$\text{Salg} = \beta_0 + \beta_1(\text{Pris}) + \beta_2(\text{Pris}^2) + \epsilon$$



Ikke-lineære sammenhenger kan ofte fanges opp lineært!

Diagnostikk: Hva kan gå galt?

Å kjøre en regresjon er lett, å stole på den er vanskelig.

1. **Ikke-lineær sammenheng:** Sjekk residual-plot.
2. **Korrelasjon i feilledd:** (Vanlig i tidsserier).
3. **Heteroskedastisitet:** Variansen til ϵ er ikke konstant (traktform i residualene).
4. **Outliers:** Enkeltpunkter som drar i linja.
5. **Multikollinearitet:** To eller flere X -variabler er sterkt korrelerte.

Når prediktorene krangler

Hvis X_1 og X_2 er nesten like (f.eks. formue og inntekt), får modellen problemer med å skille effektene deres.

Konsekvens:

- Standardfeilene (SE) til β -ene eksploderer.
- Vi får lave t -statistikker (variablene ser insignifikante ut), selv om F -testen er skyhøy.

Eksempel: VIF - Variance Inflation Factor

Vi måler multikollinearitet med VIF. En verdi over 5 eller 10 tyder på problemer.

Parametrisk vs. Ikke-parametrisk

Hvorfor bruke lineær regresjon når vi har KNN?

- **Lineær Regresjon:**

- (+) Lett å tolke, krever lite data, gir p-verdier.
- (-) Bommer hvis sannheten er veldig kompleks/ikke-lineær.

- **KNN (Regresjon):**

- (+) Fleksibel, ingen antakelser om form.
- (-) "Curse of Dimensionality" sliter når vi har mange prediktorer.

Oppsummering Kapittel 3

- Multippel regresjon lar oss isolere effekten av én variabel.
- Bruk **F-test** for å vurdere den totale modellen.
- **Dummy-variabler** brukes for kategoriske data.
- **Interaksjoner** fanger opp synergieffekter.
- Vær alltid på vakt mot **multikollinearitet** og **ikke-linearitet**.

Neste gang: Kapittel 4 - Klassifisering (Logistisk regresjon).