

Klassifikasjon

ISLP kapittel 4.1–4.3

Fra «*hvor mye?*» til «*hvilken?*»

Alle tall i forelesningen er regnet ut på `Default`-datasettet ($n = 10\,000$)

Plan for forelesningen

Det vi skal igjennom

- 4.1 Hva er et klassifikasjonsproblem?
- 4.2 Hvorfor kan vi ikke bare bruke lineær regresjon?
- 4.3.1 Den logistiske modellen
 - odds og log-odds
- 4.3.2 Hvordan estimeres β_0 og β_1 ?
- 4.3.3 Prediksjon og klassifikasjon
- 4.3.4 Flere prediktorer og konfundering
- 4.3.5 Mer enn to klasser (kort)

Etter forelesningen skal du kunne

1. Forklare hvorfor OLS er feil verktøy for en kvalitativ Y .
2. Utlede sammenhengen mellom *sannsynlighet*, *odds* og *log-odds*.
3. Forklare hva sannsynlighetsmaksimering (maximum likelihood) gjør.
4. Tolke $\hat{\beta}_1$ i en logistisk regresjon — og vite hva den *ikke* betyr.
5. Regne ut $\hat{p}(x)$ for hånd og gjøre en klassifikasjon.

Diskriminantanalyse (4.4), naive Bayes og sammenligning av metoder (4.5) kommer senere.

Der vi slapp: kapittel 3

Rammeverket vårt er fortsatt det samme:

$$Y = f(X) + \varepsilon$$

I kapittel 3 var Y **kvantitativ** — et tall. Vi

- antok $f(X) = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p$
- minimerte $\text{RSS} = \sum_i (y_i - \hat{y}_i)^2$
- fikk en *lukket formel* for $\hat{\beta}$

Hva endrer seg nå?

Y er **kvalitativ** — en merkelapp, ikke et tall.

Tre ting må erstattes:

1. **Modellen** for f (kan ikke gi hva som helst ut)
2. **Tapsfunksjonen** (RSS gir ikke mening)
3. **Feilmålet** (MSE gir ikke mening)

Alt annet — bias-varians, trenings- vs. testfeil, overtilpasning — gjelder **fortsatt**.

Spørsmål fra tidligere?

Spørsmål fra tidligere?

Spørsmål fra tidligere?

Spørsmål fra tidligere?

4.1

Klassifikasjonsproblemet

Hva er klassifikasjon?

Definisjon

Responsen Y tar verdier i et endelig, **uordnet** sett av klasser $\mathcal{C} = \{1, 2, \dots, K\}$. Vi skal bygge en **klassifikator** $\hat{C}(x)$ som tildeler en klasse til enhver x .

Eksempler fra økonomi og finans


- Misligholder kunden lånet? Ja/Nei
- Er transaksjonen svindel? Ja/Nei
- Går aksjen opp eller ned i morgen? Opp/Ned
- Slutter den ansatte i år? Ja/Nei
- Hvilket produkt velger forbrukeren? A/B/C

Merk: klassene er *uordnede*.

Det finnes ingen naturlig rekkefølge på {svindel, ikke svindel} slik det finnes på kroner eller prosent.


Dette er hele kilden til problemene i 4.2.

Regresjon vs. klassifikasjon — illustrert



Regresjon

Vi måler avstand *loddrett*: hvor langt bommer vi i kroner?



Klassifikasjon

Vi måler om vi havner på *riktig side*: rett eller galt.

Regresjon tilpasser en **kurve gjennom** punktene. Klassifikasjon trekker en **grense mellom** dem.

Hva vil vi ha ut — og hvordan måler vi feil?

Tre ting vi ønsker

1. En **klasse**: $\hat{C}(x) \in \mathcal{C}$
2. En **sannsynlighet**: $\Pr(Y = k \mid X = x)$
Ofte viktigere enn klassen! En bank vil vite *hvor* risikabel kunden er.
3. **Innsikt**: hvilke X -er skiller klassene?

Feilrate erstatter MSE


$$\text{Feilrate} = \frac{1}{n} \sum_{i=1}^n I(y_i \neq \hat{y}_i)$$

der $I(\cdot)$ er 1 hvis utsagnet er sant, 0 ellers. Dette er simpelthen *andelen* vi bommer på.

Som i kapittel 2 er det **testfeilraten** som teller — treningsfeilraten kan gjøres kunstig lav.

Bayes-klassifikatoren (2.2.3) er fasiten: velg klassen med høyest $\Pr(Y = k \mid X = x)$. Den gir lavest mulig feilrate — men krever at vi *kjenner* de sanne sannsynlighetene. Alt vi gjør i kapittel 4 er forsøk på å **estimere** dem.

Vårt gjennomgangseksempel: Default



$n = 10\,000$ kunder.

$Y = \text{default}$ (Ja/Nei)

$X = \text{balance, income, student}$

Bare **3,33 %** misligholder.

Legg merke til: de oransje ligger til *høyre* — *balance* skiller klassene. De ligger spredt *loddrett* — *income* gjør det ikke.

Figuren viser et tilfeldig utvalg av observasjonene for lesbarhetens skyld (ISLP figur 4.1).

4.2

Hvorfor ikke bare bruke lineær regresjon?

Forsøk 1: kod kategoriene som tall

En pasient kommer inn på akutten. Tre mulige diagnoser. Vi koder dem som tall og kjører OLS:

$$Y = \begin{cases} 1 & \text{hjerneslag} \\ 2 & \text{overdose} \\ 3 & \text{epileptisk anfall} \end{cases}$$

$$Y = \begin{cases} 1 & \text{epileptisk anfall} \\ 2 & \text{hjerneslag} \\ 3 & \text{overdose} \end{cases}$$

To ubegrunnede påstander sniker seg inn

1. **Rekkefølge:** kodingen sier at overdose ligger «mellom» hjerneslag og anfall.
2. **Avstand:** kodingen sier at avstanden slag $\rightarrow$ overdose er *like stor* som overdose $\rightarrow$ anfall.

De to kodingene over gir **forskjellige modeller** og **forskjellige prediksjoner** på de samme dataene. Det er en dødsdom.

Unntak: hvis klassene faktisk er ordnet med rimelig like avstander (mild, moderat, alvorlig) kan 1–2–3 forsvares.

Forsøk 2: bare to klasser — da går det bedre

Med to klasser kan vi bruke dummy-trikset fra 3.3.1:

$$Y = \begin{cases} 0 & \text{ikke mislighold} \\ 1 & \text{mislighold} \end{cases}$$

Nå er kodingen **ikke** vilkårlig på samme måte: snur vi 0 og 1, snur bare fortegnet på $\hat{\beta}_1$, og prediksjonene blir identiske.

Og det er faktisk noe fint her


For en 0/1-variabel er

$$E[Y \mid X] = 1 \cdot \Pr(Y = 1 \mid X) + 0 \cdot \Pr(Y = 0 \mid X) = p(X).$$

Så OLS *prøver* å estimere nettopp den sannsynligheten vi er ute etter.

Men modellen er


$$p(X) = \beta_0 + \beta_1 X \quad (4.1)$$



Venstresiden er **låst** til $[0, 1]$.

Høyresiden er en rett linje — den går mot $\pm\infty$.

Og slik ser det ut på ekte data



OLS av default (0/1) på balance:

$$\hat{p}(X) = -0,0752 + 0,00013 X$$

- Negativ for all `balance` < 579
- Det gjelder **45 %** av kundene
- Ved \$2500: $\hat{p} = 0,25$, mens den ekte andelen er nær 1

Streker nederst/øverst: faktiske observasjoner med $y = 0$ (blå) og $y = 1$ (oransje). ISLP figur 4.2, venstre panel.

Delkonklusjon 4.2

To grunner til ikke å klassifisere med regresjon

- (a) En regresjonsmetode **takler ikke mer enn to klasser**. Enhver tallkoding påfører dataene en rekkefølge og en avstandsskala som ikke finnes.
- (b) Selv med to klasser gir den **ikke meningsfulle sannsynligheter**. Estimaten faller utenfor $[0, 1]$.

Men vær rettferdig: for to klasser gir OLS en fornuftig *rangering* av kundene, og klassifikasjonene blir faktisk identiske med dem fra diskriminantanalyse (4.4). Det er sannsynlighetene som er ubrukelige — ikke rekkefølgen.

Vi trenger en modell som **ikke kan** gi *'shit out'*.

4.3.1

Den logistiske modellen

Kravspesifikasjon

Vi leter etter en funksjon σ som

1. tar imot *hva som helst* på tallinja: $\sigma : (-\infty, \infty) \rightarrow (0, 1)$
2. er *monoton* — større z skal alltid gi større sannsynlighet
3. er *glatt* og lett å derivere (vi skal maksimere noe senere)

Vi beholder den lineære delen $z = \beta_0 + \beta_1 X$ — den er tolkbar og lett å regne med — og **presser den gjennom σ** :

$$p(X) = \sigma(\beta_0 + \beta_1 X).$$

Den logistiske funksjonen


Modellen (4.2)

$$p(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}}$$

Ekvivalent, og ofte greiere:



$$p(X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X)}}$$

Hvorfor virker dette? Telleren e^z er alltid *positiv*, og nevneren $1 + e^z$ er alltid *større enn telleren*. Altså $0 < p < 1$ uansett hva z er.




$\sigma(z) \rightarrow 0$ når $z \rightarrow -\infty$, $\sigma(z) \rightarrow 1$ når $z \rightarrow \infty$

Lineær vs. logistisk på Default (ISLP figur 4.2)



Samme data, samme prediktor. Til venstre: negative sannsynligheter, og kurven klarer ikke å komme opp mot 1. Til høyre: alltid mellom 0 og 1 — og S-formen fanger opp at risikoen *eksploderer* et sted rundt \$1600–\$2000.

Er S-formen virkelig der? Sjekk mot data



Her har vi delt kundene i grupper på \$200 og regnet ut hvor stor *andel* i hver gruppe som faktisk misligholdt.

Punktene er rå data — ingen modell. Likevel danner de en S.

Den logistiske funksjonen er ikke et matematisk triks for å slippe unna $[0, 1]$ -problemet. Den beskriver formen dataene faktisk har.

Utleddning, steg 1: fra (4.2) til (4.3)

Skriv $z = \beta_0 + \beta_1 X$ for å spare plass. Da er $p = \frac{e^z}{1 + e^z}$.

Først: hva er $1 - p$?

$$\begin{aligned} 1 - p &= 1 - \frac{e^z}{1 + e^z} = \frac{1 + e^z}{1 + e^z} - \frac{e^z}{1 + e^z} \\ &= \frac{1 + e^z - e^z}{1 + e^z} = \boxed{\frac{1}{1 + e^z}} \end{aligned}$$

Så: del p på $1 - p$.

$$\frac{p}{1 - p} = \frac{e^z}{1 + e^z} \bigg/ \frac{1}{1 + e^z} = \frac{e^z}{1 + e^z} \cdot \frac{1 + e^z}{1} = e^z$$

Resultat (4.3)

$$\frac{p(X)}{1 - p(X)} = e^{\beta_0 + \beta_1 X}$$

Legg merke til hvor pent $1 + e^z$ forsvinner. Det er ikke tilfeldig — det er nettopp derfor *denne* funksjonen er valgt.

Hva er odds?

Definisjon

$$\text{odds} = \frac{p}{1-p} = \frac{\text{sjansen for at det skjer}}{\text{sjansen for at det ikke skjer}}$$

Les det høyt

$p = 0,2 \Rightarrow \text{odds} = \frac{0,2}{0,8} = \frac{1}{4}$:
«1 av 5 misligholder.»

$p = 0,9 \Rightarrow \text{odds} = \frac{0,9}{0,1} = 9$:
«9 av 10 misligholder.»

Dette er samme språk som brukes i veddemål på hest.

p	$\text{odds} = \frac{p}{1-p}$	$\log(\text{odds})$
0,01	0,0101	-4,60
0,10	0,111	-2,20
0,25	0,333	-1,10
0,50	1	0
0,75	3	+1,10
0,90	9	+2,20
0,99	99	+4,60

Poenget med tabellen

p lever i $(0, 1)$ — låst i begge ender

odds lever i $(0, \infty)$ — låst i *én* ende

$\log(\text{odds})$ lever i $(-\infty, \infty)$ — **fri**

Legg merke til symmetrien: $\log$ -odds for p og for $1-p$ er like store med motsatt fortegn.

Utleddning, steg 2: fra (4.3) til (4.4)

Vi har akkurat vist at

$$\frac{p(X)}{1 - p(X)} = e^{\beta_0 + \beta_1 X}.$$

Ta logaritmen på begge sider. Siden $\log(e^a) = a$:

$$\log\left(\frac{p(X)}{1 - p(X)}\right) = \log(e^{\beta_0 + \beta_1 X}) = \beta_0 + \beta_1 X$$

Resultat (4.4)

$$\log\left(\frac{p(X)}{1 - p(X)}\right) = \beta_0 + \beta_1 X$$

Venstresiden kalles **log-odds** eller **logit**.

Dette er hele ideen bak logistisk regresjon


Problemet i 4.2 var at venstresiden var *låst* mens høyresiden var *fri*.

Løsningen er ikke å gjøre høyresiden mindre fri — vi vil beholde den lineære modellen.

Løsningen er å transformere venstresiden til noe som også er fritt.

Logistisk regresjon er altså en **lineær modell** — bare ikke for p , men for log-odds.

Tre måter å skrive den samme modellen



Veien tilbake, steg for steg: $\log \frac{p}{1-p} = z \Rightarrow \frac{p}{1-p} = e^z \Rightarrow p = e^z - p e^z \Rightarrow p(1 + e^z) = e^z \Rightarrow p = \frac{e^z}{1+e^z}$

Hva betyr egentlig β_1 ?

Tre riktige formuleringer


På log-odds-skalaen	Én enhets økning i X gir $+\beta_1$ i log-odds. <i>Additivt.</i>
På odds-skalaen	Én enhets økning i X <i>ganger</i> odds med e^{β_1} . <i>Multiplikativt.</i>
På sannsynlighetsskalaen	Fortegnet gjelder alltid: $\beta_1 > 0 \Rightarrow p$ øker. Men hvor mye p endrer seg avhenger av hvor på kurven vi står.

Den vanligste feilen på eksamen

« $\hat{\beta}_1 = 0,0055$, altså øker sannsynligheten for mislighold med 0,55 prosentpoeng per dollar.»

Galt. 0,0055 er endringen i *log-odds*, ikke i sannsynlighet. I en lineær modell er β_1 hele historien. I en logistisk modell er den bare *halve* historien — resten avhenger av X .

Samme β_1 — helt forskjellig effekt



balance	$\hat{p}$	endring
500 → 600	0,0004 → 0,0006	+0,03 pp
1000 → 1100	0,0058 → 0,0099	+0,42 pp
1500 → 1600	0,083 → 0,136	+5,3 pp
1900 → 2000	0,450 → 0,586	+13,7 pp

Alle fire radene har *samme* $\hat{\beta}_1$ og samme økning på \$100. Effekten på sannsynligheten varierer med en faktor på over 400.

Matematisk: $\frac{\partial p}{\partial X} = \beta_1 p(1-p)$, som er størst når $p = 0,5$ og der lik $\beta_1/4$.

4.3.2

Hvordan finner vi $\hat{\beta}_0$ og $\hat{\beta}_1$?

Hvorfor ikke minste kvadraters metode?

I kapittel 3 minimerte vi

$$\text{RSS}(\beta) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

satte de deriverte lik null, og fikk en **lukket formel**:

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}.$$

Hvorfor det ikke fungerer her


- Modellen er **ikke lineær** i β lenger — $p(x_i)$ ligger inne i en eksponentialfunksjon. Ingen lukket formel finnes.
- Variansen er **ikke konstant**: for en 0/1-variabel er $\text{Var}(Y | X) = p(X)(1 - p(X))$, som endrer seg med X .
- Vi har en langt bedre idé tilgjengelig: velg de β -ene som gjør de **observerte dataene mest sannsynlige**.

Sannsynlighetsmaksimering (*maximum likelihood*) er den generelle metoden. Den brukes gjennom hele resten av boka. Og et lite lyspunkt: *OLS er selv et spesialtilfelle av sannsynlighetsmaksimering* — nemlig når feilledet antas normalfordelt. Vi har brukt metoden hele tiden uten å vite det.

Ideen bak sannsynlighetsmaksimering

Målet, i én setning

Finn de $\hat{\beta}_0$ og $\hat{\beta}_1$ som gir en **høy** $\hat{p}(x_i)$ for alle som faktisk misligholdt, og en **lav** $\hat{p}(x_i)$ for alle som ikke gjorde det.



Vi trenger å gjøre dette *målbart*: ett tall som sier hvor godt et gitt par (β_0, β_1) klarer denne jobben. Det tallet kalles **likelihood**.

Likelihood-funksjonen (4.5)

Steg 1 — ett individ om gangen.

Hvor sannsynlig er det vi *faktisk observerte* for individ i , gitt modellen?

$y_i = 1$: sannsynlighet $p(x_i)$

$y_i = 0$: sannsynlighet $1 - p(x_i)$

Steg 2 — alle sammen.

Observasjonene er uavhengige, så vi *multipliserer*:

$$\ell(\beta_0, \beta_1) = \prod_{i: y_i=1} p(x_i) \prod_{i': y_{i'}=0} (1 - p(x_{i'}))$$

Én kompakt skrivemåte

$$\ell(\beta) = \prod_{i=1}^n p(x_i)^{y_i} (1 - p(x_i))^{1-y_i}$$

- $y_i = 1$: gir $p^1(1 - p)^0 = p$ ✓
- $y_i = 0$: gir $p^0(1 - p)^1 = 1 - p$ ✓

Eksponentene fungerer som brytere.

ℓ er en funksjon av β , ikke av data. Dataene er faste — vi har jo sett dem. Det er β vi skrur på.

$\hat{\beta}_0, \hat{\beta}_1$ er de verdiene som **maksimerer** ℓ .

Miniøvelse: hvilken modell er best?

Tre kunder:

balance	y
1000	0
1500	0
2000	1

	$\hat{p}(1000)$	$\hat{p}(1500)$	$\hat{p}(2000)$	ℓ
A: $\beta_0 = -10,65, \beta_1 = 0,0055$	0,006	0,083	0,587	0,535
B: $\beta_0 = -5, \beta_1 = 0,004$	0,269	0,731	0,953	0,187

Utrekning for A: $\ell = (1 - 0,006) \times (1 - 0,083) \times 0,587 = 0,535$

Hva skjedde?

Modell B gir ganske høy sannsynlighet for mislighold til *alle tre* — også de to som ikke misligholdt. Den blir straffet for det. Modell A treffer bedre, og får høyere ℓ .

Datamaskinen gjør akkurat dette, bare for millioner av kandidat- β -er samtidig.

Fra produkt til sum: log-likelihood

Et produkt av 10 000 tall mellom 0 og 1 blir astronomisk lite — datamaskinen runder det til null. Og produkter er vonde å derivere.

Løsning: ta logaritmen. log er strengt voksende, så *samme β maksimerer begge.*

$$\log \ell(\beta) = \sum_{i=1}^n \left[y_i \log p(x_i) + (1 - y_i) \log(1 - p(x_i)) \right]$$

Sett inn $p = \frac{e^z}{1+e^z}$ og $1 - p = \frac{1}{1+e^z}$, med $z_i = \beta_0 + \beta_1 x_i$:

$$\begin{aligned} \log p(x_i) &= z_i - \log(1 + e^{z_i}) \\ \log(1 - p(x_i)) &= -\log(1 + e^{z_i}) \end{aligned}$$

Alt kollapser til

$$\log \ell(\beta_0, \beta_1) = \sum_{i=1}^n \left[y_i (\beta_0 + \beta_1 x_i) - \log(1 + e^{\beta_0 + \beta_1 x_i}) \right]$$

Førsteordensbetingelsene — og en gammel kjenning

Deriver $\log \ell$ og sett lik null. Nøkkelen er at $\frac{d}{dz} \frac{e^z}{1 + e^z} = p(1 - p)$.

$$\frac{\partial \log \ell}{\partial \beta_0} = \sum_{i=1}^n (y_i - p(x_i)) = 0$$

$$\frac{\partial \log \ell}{\partial \beta_1} = \sum_{i=1}^n x_i (y_i - p(x_i)) = 0$$

Sammenlign med OLS

Fra kapittel 3, med residual $e_i = y_i - \hat{y}_i$:

$$\sum_i e_i = 0, \quad \sum_i x_i e_i = 0$$

Nøyaktig samme struktur! Her er «residualen» $y_i - \hat{p}(x_i)$: differansen mellom observert 0/1 og modellens sannsynlighet.

En fin konsekvens av den første betingelsen

$\sum_i y_i = \sum_i \hat{p}(x_i)$, altså $\bar{\hat{p}} = \bar{y}$: **gjennomsnittlig predikert sannsynlighet er nøyaktig lik andelen enere i data.**

På `Default`: begge er 0,0333. Det er også derfor konstantleddet sjelden er interessant i seg selv — jobben dens er å få dette gjennomsnittet på plass.


Men ligningene kan ikke løses for hånd

$$\sum_i \left(y_i - \frac{e^{\beta_0 + \beta_1 x_i}}{1 + e^{\beta_0 + \beta_1 x_i}} \right) = 0$$

β -ene sitter fast inne i en eksponentialfunksjon inne i en brøk inne i en sum. Det finnes **ingen** algebraisk løsning.

Løsningen: numerisk søk. Gjett, se hvilken vei det bærer oppover, ta et skritt, gjenta. (Newton–Raphson / IRLS.)

Det er dette `.fit()` gjør i Python — vanligvis på under ti iterasjoner.



Godt nytt

$\log \ell$ er **konkav**. Det finnes bare én topp — ingen lokale maksima å gå seg vill i. Algoritmen finner alltid fram.

Unntak: hvis en prediktor skiller klassene *perfekt*, vokser $\log \ell$ i det uendelige og $\hat{\beta}$ divergerer. Kalles «separasjon», og er en av grunnene til at diskriminantanalyse i 4.4 finnes.

Resultatet: ISLP Tabell 4.1

	Koeffisient	Std.feil	z -verdi	p -verdi
Konstantledd	-10,6513	0,3612	-29,5	< 0,0001
balance	0,0055	0,0002	24,9	< 0,0001

z -verdien spiller nøyaktig samme rolle som t -verdien i kapittel 3:

$$z = \frac{\hat{\beta}_1}{\text{SE}(\hat{\beta}_1)} = \frac{0,0055}{0,00022} = 24,9$$

Stor absoluttverdi $\Rightarrow$ vi forkaster $H_0 : \beta_1 = 0$.

Hva sier $H_0 : \beta_1 = 0$?

At $p(X) = \frac{e^{\beta_0}}{1 + e^{\beta_0}}$ — altså at sannsynligheten for mislighold er **den samme for alle**, uansett saldo.

Med $z = 24,9$ er det ikke troverdig.

$\hat{\beta}_1 > 0$: høyere saldo $\Rightarrow$ høyere risiko. Fortegnet er alt vi trenger for retningen; størrelsen krever mer omtanke (forrige del).

4.3.3–4.3.5

Prediksjon, klassifikasjon og flere prediktorer

Fra $\hat{\beta}$ til $\hat{p}$: to regneeksempler

Kunde med balance = \$1000

$$\begin{aligned} z &= -10,6513 + 0,0055 \times 1000 \\ &= -10,6513 + 5,5 = -5,1513 \end{aligned}$$

$$e^z = 0,00579$$

$$\hat{p} = \frac{0,00579}{1 + 0,00579} = \mathbf{0,0058}$$

Altså **0,58 %** sjanse for mislighold.

Kunde med balance = \$2000

$$\begin{aligned} z &= -10,6513 + 0,0055 \times 2000 \\ &= -10,6513 + 11,0 = 0,3487 \end{aligned}$$

$$e^z = 1,4172$$

$$\hat{p} = \frac{1,4172}{1 + 1,4172} = \mathbf{0,586}$$

Altså **58,6 %** sjanse for mislighold.

Legg merke til

Saldoen ble doblet. Sannsynligheten ble **hundredoblet**. Dette er S-kurven i praksis — og grunnen til at $\hat{\beta}_1$ ikke kan leses av som «prosentpoeng per dollar».

Fra $\hat{p}$ til klasse

Beslutningsregelen

$$\hat{C}(x) = \begin{cases} \text{Yes} & \text{hvis } \hat{p}(x) > c \\ \text{No} & \text{ellers} \end{cases}$$

Standardvalget er $c = 0,5$ — det tilsvarer Bayes-klassifikatoren, og velger simpelthen den mest sannsynlige klassen.

Med $c = 0,5$ blir grensen der $z = 0$:

$$\hat{\beta}_0 + \hat{\beta}_1 X = 0 \implies X = \frac{10,6513}{0,0055} \approx \$1937$$

Alle med saldo over \$1937 klassifiseres som mislighold.

Men 0,5 er et *valg*, ikke en naturlov

Bare 3,33 % misligholder. Med $c = 0,5$ vil modellen nesten aldri rope varsku — den treffer på over 97 % ved å si «nei» hele tiden.

En bank som vil fange opp risikokunder tidlig kan sette $c = 0,1$: flere falske alarmer, men langt færre oversette mislighold.

Terskelen bestemmes av **kostnaden ved de to feiltypene** — ikke av statistikken. Vi kommer tilbake til dette med forvekslingsmatrisen i 4.4.

Kvalitativ prediktor: er studenter mer risikable?

Lag en dummy akkurat som i 3.3.1: `student[Yes]` = 1 for studenter, 0 ellers.

	Koeff.	Std.feil	z	p
Konstantledd	-3,5041	0,0707	-49,55	< 0,0001
<code>student[Yes]</code>	0,4049	0,1150	3,52	0,0004

ISLP Tabell 4.2

Regn ut begge

$$\text{Student: } \frac{e^{-3,5041+0,4049}}{1 + e^{-3,5041+0,4049}} = 0,0431$$

$$\text{Ikke student: } \frac{e^{-3,5041}}{1 + e^{-3,5041}} = 0,0292$$

$\hat{\beta}_1 > 0$ og signifikant: **studenter misligholder oftere** — 4,3 % mot 2,9 %.

Hold fast på den konklusjonen i to slides.

Multippel logistisk regresjon

Nøyaktig samme utvidelse som fra enkel til multippel lineær regresjon:

$$\log\left(\frac{p(X)}{1-p(X)}\right) = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p \quad (4.6)$$

$$p(X) = \frac{e^{\beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p}}{1 + e^{\beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p}} \quad (4.7)$$

Estimeres med samme metode: maksimer $\ell(\beta_0, \dots, \beta_p)$.

	Koeff.	Std.feil	z	p
Konstantledd	-10,8690	0,4923	-22,08	< 0,0001
balance	0,0057	0,0002	24,74	< 0,0001
income	0,0030	0,0082	0,37	0,7115
student[Yes]	-0,6468	0,2362	-2,74	0,0062

ISLP Tabell 4.3. `income` målt i 1000 \$.


Se på fortegnet

Alene: `student` hadde koeffisient **+0,40**.


Sammen med `balance`: **-0,65**.

Samme data. Samme variabel. Motsatt fortegn.

Konfundering — og oppklaringen



Stiplet = samlet andel i gruppen (4,3 % mot 2,9 %)



Venstre: ved *enhver* gitt saldo misligholder studenter **sjeldnere** (heltrukne linjer) — men de stiplede totalratene sier motsatt.

Høyre: forklaringen. Studenter har systematisk *høyere* saldo (median \$980 mot \$759).

Konfundering

Å være student *i seg selv* senker risikoen. Men studenter har mer gjeld, og gjeld hever risikoen kraftig. Nettoeffekten uten kontroll for saldo blir positiv.

Praktisk konsekvens: har banken bare informasjon om studentstatus, bør den behandle studenter som mer risikable. Kjenner den saldoen også, bør den behandle dem som mindre risikable. Begge er riktige — de svarer på forskjellige spørsmål.

Prediksjon med tre prediktorer

To kunder med *nøyaktig samme* saldo (\$1500) og inntekt (\$40 000). Eneste forskjell: den ene er student.

Student

$$\begin{aligned} z &= -10,869 + 0,00574 \cdot 1500 \\ &\quad + 0,003 \cdot 40 - 0,6468 \cdot 1 \\ &= -10,869 + 8,610 + 0,120 - 0,647 \\ &= -2,786 \end{aligned}$$

$$\hat{p} = \frac{e^{-2,786}}{1 + e^{-2,786}} = \mathbf{0,058}$$

Ikke student

$$\begin{aligned} z &= -10,869 + 0,00574 \cdot 1500 \\ &\quad + 0,003 \cdot 40 - 0,6468 \cdot 0 \\ &= -10,869 + 8,610 + 0,120 - 0 \\ &= -2,139 \end{aligned}$$

$$\hat{p} = \frac{e^{-2,139}}{1 + e^{-2,139}} = \mathbf{0,105}$$

5,8 % mot 10,5 %: studenten er omtrent **halvparten** så risikabel.

Merk: `income` ganges med 40, ikke 40 000, fordi modellen er estimert med inntekt i tusen dollar. Med z -verdi 0,37 bidrar den uansett ingenting.

Mer enn to klasser: multinomisk logistisk regresjon

Husk akuttmottaket fra 4.2 — tre diagnoser, og lineær regresjon strandet. Nå kan vi løse det.

Velg én klasse som **referanse** (si klasse K), og modeller for $k = 1, \dots, K - 1$:

$$\Pr(Y = k \mid X = x) = \frac{e^{\beta_{k0} + \beta_{k1}x_1 + \dots}}{1 + \sum_{l=1}^{K-1} e^{\beta_{l0} + \beta_{l1}x_1 + \dots}} \quad (4.10)$$

$$\Pr(Y = K \mid X = x) = \frac{1}{1 + \sum_{l=1}^{K-1} e^{\beta_{l0} + \dots}} \quad (4.11)$$

Samme idé, én gang til

$$\log\left(\frac{\Pr(Y = k \mid x)}{\Pr(Y = K \mid x)}\right) = \beta_{k0} + \beta_{k1}x_1 + \dots \quad (4.12)$$

Log-odds mellom *ethvert* klassepar er fortsatt lineær i X .

Advarsel om tolkning: koeffisientene er alltid *relative til referanseklassen*. Bytter du referanse, endres tallene — men prediksjonene er identiske.

Softmax (4.13) er en ekvivalent skrivemåte som behandler alle K klassene symmetrisk. Den dukker opp igjen i kapittel 10 om nevralt nett.

I Python

```
import numpy as np
import statsmodels.api as sm
from ISLP import load_data, confusion_table
from ISLP.models import ModelSpec as MS, summarize

Default = load_data('Default')

design = MS(['balance', 'income', 'student'])
X = design.fit_transform(Default)
y = Default.default == 'Yes'

glm = sm.GLM(y, X, family=sm.families.Binomial())
res = glm.fit()
summarize(res)

# sannsynligheter, deretter klasser
p_hat = res.predict(X)
klasse = np.where(p_hat > 0.5, 'Yes', 'No')
confusion_table(klasse, Default.default)
```

Legg merke til

- `Binomial()` er det som skiller dette fra vanlig OLS
- `predict` gir sannsynligheter, ikke klasser
- terskelvalget er *ditt*, ikke modellens
- MS lager dummyer for student automatisk

Oppsummering

Kjeden vi gikk gjennom

1. Y er kvalitativ $\Rightarrow$ OLS duger ikke
2. Trenger $p \in (0, 1) \Rightarrow$ logistisk funksjon
3. log-odds er ubegrenset $\Rightarrow$ kan settes lik $\beta_0 + \beta_1 X$
4. Ingen lukket løsning $\Rightarrow$ maksimer $\log \ell$ numerisk
5. $\hat{p} + \text{terskel} \Rightarrow$ klassifikasjon

De tre tingene å huske

1. Logistisk regresjon er en **lineær modell for log-odds**, ikke for sannsynlighet.
2. $\hat{\beta}_1$ er **ikke** en endring i sannsynlighet. Effekten på p avhenger av hvor du står på kurven.
3. Modellen gir **sannsynligheter**. Klassifikasjonen skjer først når *du* velger en terskel.

Veien videre (4.4–4.5): logistisk regresjon modellerer $\Pr(Y | X)$ direkte. Et alternativ er å modellere fordelingen av X *innenfor* hver klasse og snu det med Bayes' teorem — det gir diskriminantanalyse og naive Bayes. Vi trenger også forvekslingsmatrisen for å måle *hvilke* feil en klassifikator gjør, ikke bare hvor mange.

Til neste gang

Regn for hånd

1. En kunde har odds 0,37 for mislighold. Hvor stor andel av slike kunder misligholder?
2. En annen har 16 % sannsynlighet. Hva er oddsen hennes?
3. Med Tabell 4.1: ved hvilken saldo er $\hat{p}$ nøyaktig 0,25?

Tenk gjennom

1. En modell sier «nei» til alle og treffer på 96,7 %. Er den god?
2. Hvorfor kan $\hat{\beta}$ for `student` snu fortegn når `balance` legges til — men aldri når vi bare bytter om 0 og 1 i kodingen av Y ?
3. Hvorfor er $\bar{\hat{p}} = \bar{y}$ en *egenskap ved metoden* og ikke en tilfeldighet?

ISLP kapittel 4, oppgave 6, 9 og 13. Labben: Smarket-datasettet.