

# SOK-1305 Statistisk læring for økonomer

## Kapittel 5: Resampling-metoder

**Del I:** Regresjon vs. klassifikasjon — hvordan måler vi feil?

**Del II:** Kryssvalidering og bootstrapping

## Agenda

### Del I: Å måle hvor god en modell er

1. To typer utfall: kvantitativt og kategorisk.

2. Regresjon og MSE.

3. Klassifikasjon, feilrate og treffsikkerhet.

4. *confusion matrix*.

5. Sensitivitet, spesifisitet og valg av terskel.

$Y$  er et tall  
 $Y$  er en kategori

} klassifikasjon

### Del II: Resampling (kapittel 5)

6. Hva er resampling og hvorfor trenger vi det?

7. Valideringssett-metoden (*the validation set approach*).

8. Leave-One-Out Cross-Validation (LOOCV).

9.  $k$ -fold kryssvalidering.

10. Bias-varians-avveilingen i kryssvalidering.

11. Bootstrapping: intuisjon, matematikk og økonomiske anvendelser.

# Del I

## Regresjon vs. klassifikasjon

*Før vi kan estimere test-feilen, må vi bli enige om hva “feil” betyr.*

## Alt avhenger av hva slags $Y$ vi har

hvilken response


Rammeverket er det samme:  $Y = f(X) + \epsilon$ . Vi bruker  $X$  til å si noe om  $Y$ . Men *typen*  $Y$  bestemmer hvilke verktøy vi bruker.

### Kvantitativ $Y$ (tall)

⇒ Regresjon (kapittel 3)

Lønn, boligpris, BNP-vekst, salg, avkastning

Vi predikerer et *tall*




### Kvalitativ $Y$ (kategori)

⇒ Klassifikasjon (kapittel 4)

Mislighold ja/nei, konkurs, arbeidsledig, hvilket parti, kredittrating


Vi predikerer en *merkelapp*






## Samme idé — to ulike spørsmål

Regresjon spør: *hvor langt bommet vi?* Klassifikasjon spør: *bommet vi — ja eller nei?*



Regresjon

Avstanden koster  
— vi kvadrerer den



Klassifikasjon

Enten riktig eller feil  
— avstand teller ikke

gj.snitt  
kvadrert feil

↓

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

— Når vi kvadrerer feil, straffer store feil mer!

$$RMSE = \sqrt{MSE}$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

samme skala  
som  $y$

Confusion Matrix

|         |   | observert |    |
|---------|---|-----------|----|
|         |   | 0         | 1  |
| predikt | 0 | TN        | FN |
|         | 1 | FP        | TP |

## Feilmålet i regresjon: MSE



*Mean Squared Error* — gjennomsnittlig kvadrert avvik mellom det vi observerte og det vi predikerte.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n \left( y_i - \hat{f}(x_i) \right)^2$$

- Store bommer straffes hardt (kvadrering): å bomme med 10 er *fire* ganger så ille som å bomme med 5.
- MSE er i *kvadrerte* enheter. Derfor rapporteres ofte  $\text{RMSE} = \sqrt{\text{MSE}}$ , som har samme enhet som  $y$ .
- Alltid ikke-negativ, og lik null bare ved perfekt tilpasning.

### Viktig Info: Trenings-MSE er ikke det vi bryr oss om

Trenings-MSE kan alltid presses mot null ved å gjøre modellen fleksibel nok. Det vi vil vite er **test-MSE**: feilen på observasjoner modellen *ikke* har sett. Hele kapittel 5 handler om å estimere nettopp den.



## Feilmålet i klassifikasjon: feilrate


Vi kan ikke kvadrere avstanden mellom “Ja” og “Nei”. I stedet teller vi hvor ofte vi tar feil.

$$\text{Feilrate} = \frac{1}{n} \sum_{i=1}^n I(y_i \neq \hat{y}_i),$$

$$\text{Treffsikkerhet} = 1 - \text{Feilrate}$$

Her er  $I(\cdot)$  en *indikator*: den er 1 når prediksjonen er feil, og 0 når den er riktig. Summen er altså rett og slett antall feil, delt på antall observasjoner.

- Dette kalles ofte **0/1-tap**: alle feil koster nøyaktig like mye.
- Enkelt og intuitivt — men den antakelsen er nesten alltid gal i økonomiske anvendelser.



### Viktig Info: Tenk over

Koster det banken det samme å avslå et lån til en god kunde som å innvilge et lån til en som misligholder?

## Problemet med treffsikkerhet alene

Når klassene er skjevfordelte, kan en helt ubrukelig modell se strålende ut.

De fleste bekles i tide!

### Eksempel: Default-datasettet

$n = 10\,000$  kunder. Av disse misligholder 333, altså **3,33 %**.

Anta at vi lager en “modell” som predikerer at *ingen* misligholder, uansett hva vi observerer:

$$\text{Treffsikkerhet} = \frac{9\,667}{10\,000} = \mathbf{96,67\%}$$

Accuracy

- Modellen er verdiløs — den fanger opp *null* av kundene banken faktisk vil identifisere.
- Til sammenligning gir logistisk regresjon med *balance*, *income* og *student* en treffsikkerhet på 97,32 %. Bare 0,65 prosentpoeng bedre enn å si “nei” til alt.
- Vi trenger å vite *hvilke* feil modellen gjør, ikke bare *hvor mange*.

## Confusion matrix

Bryt de  $n$  observasjonene ned i fire ruter: hva var sant, og hva gjettet vi?

|            |     | Faktisk klasse        |                       |
|------------|-----|-----------------------|-----------------------|
|            |     | Nei (negativ)         | Ja (positiv)          |
| Prediksjon | Nei | Sann negativ<br>(TN)  | Falsk negativ<br>(FN) |
|            | Ja  | Falsk positiv<br>(FP) | Sann positiv<br>(TP)  |

- Diagonalen (grønn) er de riktige svarene. Feilrate =  $(FP + FN)/n$ .
- Falsk positiv: vi ropte varsku uten grunn (banken avslår en god kunde).
- Falsk negativ: vi sov i timen (banken innvilger lån til en som misligholder).

## Fire tall å kunne

Samme matrise, fire ulike spørsmål. Legg merke til hva som står i *nevneren* — det er der forskjellen ligger.

|                        | Begrep                   | Formel               | Spørsmålet det svarer på                                              |
|------------------------|--------------------------|----------------------|-----------------------------------------------------------------------|
| Accuracy →             | Trefferikkerhet          | $\frac{TP + TN}{n}$  | Hvor ofte har modellen rett totalt sett?                              |
| True Positive Rate →   | Sensitivitet<br>(recall) | $\frac{TP}{TP + FN}$ | Av dem som <i>faktisk</i> er positive: hvor mange fanget vi opp?      |
| TN rate →              | Spesifisitet             | $\frac{TN}{TN + FP}$ | Av dem som <i>faktisk</i> er negative: hvor mange lot vi være i fred? |
| Pas. predicted value → | Presisjon                | $\frac{TP}{TP + FP}$ | Av dem vi <i>ropte varsku om</i> : hvor mange var reelle?             |

Evalueringss-  
metriker

### Viktig Info: Sensitivitet og spesifisitet trekker mot hverandre

Du kan alltid få sensitivitet på 100 % ved å si “Ja” til alle — men da blir spesifisiteten null. Kunsten er å finne balansen som passer problemet.

## Eksempel: Logistisk regresjon på Default med terskel 0,5

Modell: Pr(mislighold) som funksjon av balance, income og student. Alle 10 000 observasjoner.

hvilken  $\hat{p} \rightarrow 1$   
 $\rightarrow 0$

$$\text{Accuracy} = \frac{9627 + 105}{10.000} \approx 97,3\%$$

$$\text{Feilrate} = 1 - 97,3\% \approx 2,7\%$$

| Predikert | Faktisk |     | Sum    |
|-----------|---------|-----|--------|
|           | Nei     | Ja  |        |
| Nei       | 9 627   | 228 | 9 855  |
| Ja        | 40      | 105 | 145    |
| Sum       | 9 667   | 333 | 10 000 |

Vi fanger opp under  
 $1/3$  av de som  
 faktisk misligholder (1)

$$\text{Sensitivitet} = \frac{TP}{TP + FN} = \frac{105}{228 + 105} \approx 31\%$$

$$\text{spesifisitet (TN rate)} = \frac{9267}{9267 + 40} \approx 99,5\% \rightarrow \text{Vi "plager" nesten aldri en god kunde.}$$

$$\text{presisjonen} = \frac{105}{105 + 40} \approx 72,4\% \rightarrow \text{Når vi først roper "varsel", se her vi som regel rett (72\% av tiden)}$$

## Terskelen på 0,5 er ikke hellig

Logistisk regresjon gir oss  $\hat{p}(x)$ . Vi bestemmer hvor grensen skal gå:  $\hat{y} = \text{Ja}$  hvis  $\hat{p}(x) > t$ .

*Det vi akkurat  
regnet ut*

| Terskel $t$ | Feilrate | Sensitivitet | Spesifisitet | Presisjon |
|-------------|----------|--------------|--------------|-----------|
| 0,5         | 2,68 %   | 31,5 %       | 99,6 %       | 72,4 %    |
| 0,2         | 4,07 %   | 61,0 %       | 97,1 %       | 42,3 %    |

- Ved å senke terskelen til 0,2 nesten *dobler* vi andelen mislighold vi fanger opp: fra 31 % til 61 %.
- Prisen er en høyere samlet feilrate — fra 2,68 % til 4,07 %.

### Viktig Info: Poenget

Den “beste” terskelen kan ikke leses ut av dataene alene. Den avhenger av hva de to feiltypene *koster*. Det er et økonomisk spørsmål, ikke et statistisk.



MAE  
RMSE

conf. matrix

## Oppsummering Del I

- Kvantitativ  $Y \Rightarrow$  regresjon  $\Rightarrow$  MSE. Kategorisk  $Y \Rightarrow$  klassifikasjon  $\Rightarrow$  feilrate.
- Treffsikkerhet alene er villedende når klassene er skjeve. Bruk forvekslingsmatrisen.
- Sensitivitet og spesifisitet fanger opp de to feiltypene hver for seg. Terskelen styrer avveilingen mellom dem.

Hver godes  
 $\hat{f}(x)$

### Viktig Info: Men: alle tallene over er beregnet på treningsdata

Alle confusion matriser og feilrater vi nettopp så på, ble regnet ut på *de samme* 10 000 observasjonene som modellen ble tilpasset på. De er derfor for optimistiske.

Spørsmålet vi egentlig vil ha svar på er: **hvordan gjør modellen det på kunder banken ikke har sett før?**

*Det er nøyaktig dette kapittel 5 gir oss verktøyene til.*








## Del II

### Kapittel 5: Resampling-metoder

*Kryssvalidering og bootstrapping*



## Hovedkonseptet

Resampling handler om å trekke gjentatte utvalg fra de tilgjengelige dataene og tilpasse modellen på nytt for hvert utvalg.

### To hovedmål:

1. Modell-evaluering: Estimere test-feilen.
2. Modell-seleksjon: Velge riktig fleksibilitet.


Hvor god er modellen på nye data?  
Hvilken grad av polynom, hvilken modell,  
antall features

### Viktig Info: Økonomisk relevans

I økonomi har vi ofte begrenset med data. Resampling lar oss 'skvise' mer informasjon ut av datasettet uten å måtte samle inn nye data.

## Valideringssett (The Validation Set Approach)

Den enkleste formen: Del dataene i to.



### Begrensninger:

- Varians: Estimert test-feil kan variere mye avhengig av *hvilke* observasjoner som havner i hvilken boks.
- Overestimering av feil: Siden modellen trenes på færre data enn tilgjengelig, vil den ofte prestere dårligere enn den egentlig ville gjort på hele datasettet.

# Leave-One-Out Cross-Validation (LOOCV)

En ekstrem variant: Tren på  $n - 1$  observasjoner, test på den siste. Gjenta  $n$  ganger.

$$CV_{(n)} = \frac{1}{n} \sum_{i=1}^n MSE_i$$

Fordeler:

- Langt mindre bias enn valideringssettet.
- Ingen tilfeldighet (du får alltid samme resultat).

Ulemper:

- Beregningsmessig tungt ( $n$  regresjoner!).
- *Unntak:* For OLS finnes en snarvei:  $CV_{(n)} = \frac{1}{n} \sum \left( \frac{y_i - \hat{y}_i}{1 - h_i} \right)^2$ .


Vi må lage  $n$  modeller.

$$T_1 \approx T_2 \approx T_3 \approx \dots \approx T_n$$

$e_1, e_2, \dots, e_n$  — sterkt korrelert?

$$CV_{LoO} = \frac{1}{n} \sum e_i$$

①



→ trener  $\hat{f}(x)$ , tester på test-sett.

②



⋮  
③






## k-fold Cross-Validation

Gullstandarden i maskinl ring. Del data i  $k$  grupper (folder).

Prediksj n

Inferens

$\hat{f}(x)$



Vanligvis brukes  $k = 5$  eller  $k = 10$ . Det gir et godt kompromiss mellom beregningstid og presisjon.

Balance mellom  $\hat{\epsilon}$  &  $Var$  litt h gere bias, men ogs   
ofte litt lavere varians. + bedre p  beregningstid!  
Bias/variance tradeoff.

## Hvorfor ikke alltid LOOCV (altså $k$ lik $n$ )?

Det handler om variansen til selve feil-estimatet.

- **LOOCV** ( $k = n$ ): Lav bias (vi bruker nesten alle data), men **høy varians**. De  $n$  modellene vi trener er nesten identiske  $\implies$  deres MSE-er er høyt korrelerte. Gjennomsnittet av høyt korrelerte tall har høyere varians.
- $k = 5$  eller  $10$ : Litt høyere bias, men mye **lavere varians**.

*I praksis:  $k = 10$  er ofte det beste estimatet på den sanne test-feilen.*



## Bootstrapping: Hva er det?


To pull oneself up by one's <sup>own</sup> bootstraps. "Vi bruker de dataene vi har til å simulere nye utvalg.

Konseptet: Trekking med tilbakelegging (Replacement).

1. Vi har et datasett  $Z$  med  $n$  observasjoner.
2. Vi trekker  $n$  observasjoner tilfeldig fra  $Z$ , *men vi legger hver observasjon tilbake før vi trekker neste*.
3. Dette betyr at i et Bootstrap-datasett  $Z^*$ , kan noen observasjoner fra originalen dukke opp flere ganger, mens andre ikke er med i det hele tatt.

### Viktig Info: Hvorfor?

Dette lar oss estimere usikkerheten (standardfeilen) til *hvilken som helst* statistikk, selv om vi ikke har en matematisk formel for det.




## Hvorfor trekker vi bare 2/3 av dataene?

Siden vi trekker med tilbakelegging, vil noen observasjoner trekkes flere ganger, mens andre aldri blir med.

### Sannsynlighetsregning:

- Sannsynligheten for at observasjon *i ikke* blir trukket i ett enkelt trekk:  $1 - 1/n$ .
- Sannsynligheten for at den *ikke* blir med i det hele tatt etter  $n$  trekk:  $(1 - 1/n)^n$ .
- Når  $n$  blir stor, går dette mot  $1/e \approx 0.368$ .




### Viktig Info: 63.2%-regelen

Sannsynligheten for at en observasjon blir med minst én gang er:

$$1 - (1 - 1/n)^n \approx 1 - 0.368 = 0.632$$

Altså inneholder hvert bootstrap-utvalg ca. **2/3** av de originale observasjonene. De resterende 1/3 kalles ofte "Out-of-Bag" (OOB) data.

Originalt Utvalg ( $n = 5$ )



Resample  
→

Bootstrap Utvalg ( $Z^*$ )



(Obs 2 og 5 ble "Out-of-Bag")

↑ ↑

bootstrapped data

orig-data

## Proessen

Vi ønsker å estimere usikkerheten til en parameter  $\alpha$ .

1. Generer  $B$  forskjellige bootstrap-datasett:  $Z^{*1}, Z^{*2}, \dots, Z^{*B}$ .
2. For hvert datasett, beregn estimatet:  $\hat{\alpha}^{*1}, \hat{\alpha}^{*2}, \dots, \hat{\alpha}^{*B}$ . *gj. snitt, ventas.*
3. Beregn standardfeilen til disse  $B$  estimatene:

$$SE_B(\hat{\alpha}) = \sqrt{\frac{1}{B-1} \sum_{b=1}^B \left( \hat{\alpha}^{*b} - \frac{1}{B} \sum_{r=1}^B \hat{\alpha}^{*r} \right)^2}$$

*Dette er rett og slett det empiriske standardavviket til våre bootstrap-estimer.*

### Eksempel: Investeringsallokering

Anta at du skal investere i to aksjer ( $X$  og  $Y$ ). Du vil minimere variansen til porteføljen ved å velge andelen  $\alpha$  i aksje  $X$ .

$$\alpha = \frac{\sigma_Y^2 - \sigma_{XY}}{\sigma_X^2 + \sigma_Y^2 - 2\sigma_{XY}}$$

- I virkeligheten kjenner vi ikke  $\sigma_X, \sigma_Y, \sigma_{XY}$ . Vi må estimere dem.
- Hvordan vet vi hvor nøyaktig vår  $\hat{\alpha}$  er?
- **Løsning:** Bootstrap! Vi trekker nye datasett fra historiske avkastninger og ser hvor mye  $\hat{\alpha}$  hopper rundt.

Slutten av  
kyp. J.  
(se i boka!)

## Hvorfor Bootstrap?

- **Fleksibilitet:** Fungerer på komplekse statistikker (f.eks. median, ratioer, eller koeffisienter fra kompliserte modeller).
- **Ingen fordelingsantakelser:** Vi trenger ikke anta at dataene er normalfordelte.

Men vær forsiktig:

- **Avhengighet:** Standard bootstrap antar uavhengige observasjoner (i.i.d.). Fungerer dårlig på tidsserier uten modifikasjoner (f.eks. Block Bootstrap).
- **Små utvalg:** Hvis originalutvalget er dårlig, blir bootstrap-resultatet også dårlig (Garbage in, garbage out").



## Oppsummering Kapittel 5

- **Kryssvalidering** brukes for å sjekke modellens nøyaktighet og velge modell (tuning).
- **$k$ -fold** ( $k = 10$ ) er den foretrukne metoden i de fleste tilfeller.
- **Bootstrap** er et kraftfullt verktøy for å beregne usikkerhet og standardfeil til estimer.
- For en samfunnsøkonom: Dette er verktøyene som skiller en robust analyse fra en tilfeldig konklusjon.

nyttig i mer  
komplekse modeller.

*Neste gang: Kapittel 8 - Beslutningstrær.*

