

SOK-1305 Statistisk læring for økonomer

Kapittel 5: Resampling-metoder

Del I: Regresjon vs. klassifikasjon — hvordan måler vi feil?

Del II: Kryssvalidering og bootstrapping

Agenda

Del I: Å måle hvor god en modell er

1. To typer utfall: kvantitativt og kategorisk.
2. Regresjon og MSE.
3. Klassifikasjon, feilrate og treffsikkerhet.
4. *confusion matrix*.
5. Sensitivitet, spesifisitet og valg av terskel.

Del II: Resampling (kapittel 5)

6. Hva er resampling og hvorfor trenger vi det?
7. Valideringssett-metoden (*the validation set approach*).
8. Leave-One-Out Cross-Validation (LOOCV).
9. k -fold kryssvalidering.
10. Bias-varians-avveilingen i kryssvalidering.
11. Bootstrapping: intuisjon, matematikk og økonomiske anvendelser.

Del I

Regresjon vs. klassifikasjon

Før vi kan estimere test-feilen, må vi bli enige om hva “feil” betyr.

Alt avhenger av hva slags Y vi har

Rammeverket er det samme: $Y = f(X) + \epsilon$. Vi bruker X til å si noe om Y . Men *typen* Y bestemmer hvilke verktøy vi bruker.

Kvantitativ Y (tall)

⇒ **Regresjon** (kapittel 3)

Lønn, boligpris, BNP-vekst, salg, avkastning

Vi predikerer et *tall*

Kvalitativ Y (kategori)


⇒ **Klassifikasjon** (kapittel 4)

Mislighold ja/nei, konkurs, arbeidsledig, hvilket parti, kredittrating

Vi predikerer en *merkelapp*


Samme idé — to ulike spørsmål

Regresjon spør: *hvor langt* bommet vi? Klassifikasjon spør: *bommet vi* — ja eller nei?



Regresjon

Avstanden koster
— vi kvadrerer den



Klassifikasjon

Enten riktig eller feil
— avstand teller ikke

Feilmålet i regresjon: MSE

Mean Squared Error — gjennomsnittlig kvadrert avvik mellom det vi observerte og det vi predikerte.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n \left(y_i - \hat{f}(x_i) \right)^2$$

- Store bommer straffes hardt (kvadrering): å bomme med 10 er *fire* ganger så ille som å bomme med 5.
- MSE er i *kvadrerte* enheter. Derfor rapporteres ofte $\text{RMSE} = \sqrt{\text{MSE}}$, som har samme enhet som y .
- Alltid ikke-negativ, og lik null bare ved perfekt tilpasning.

Viktig Info: Trenings-MSE er ikke det vi bryr oss om

Trenings-MSE kan alltid presses mot null ved å gjøre modellen fleksibel nok. Det vi vil vite er **test-MSE**: feilen på observasjoner modellen *ikke* har sett. Hele kapittel 5 handler om å estimere nettopp den.

Feilmålet i klassifikasjon: feilrate

Vi kan ikke kvadrere avstanden mellom “Ja” og “Nei”. I stedet teller vi hvor ofte vi tar feil.

$$\text{Feilrate} = \frac{1}{n} \sum_{i=1}^n I(y_i \neq \hat{y}_i), \quad \text{Trefferikkerhet} = 1 - \text{Feilrate}$$

Her er $I(\cdot)$ en *indikator*: den er 1 når prediksjonen er feil, og 0 når den er riktig. Summen er altså rett og slett antall feil, delt på antall observasjoner.

- Dette kalles ofte **0/1-tap**: alle feil koster nøyaktig like mye.
- Enkelt og intuitivt — men den antakelsen er nesten alltid gal i økonomiske anvendelser.

Viktig Info: Tenk over

Koster det banken det samme å avslå et lån til en god kunde som å innvilge et lån til en som misligholder?

Problemet med treffsikkerhet alene

Når klassene er skjevfordelte, kan en helt ubrukelig modell se strålende ut.

Eksempel: Default-datasettet

$n = 10\,000$ kunder. Av disse misligholder 333, altså **3,33 %**.

Anta at vi lager en “modell” som predikerer at *ingen* misligholder, uansett hva vi observerer:

$$\text{Treffsikkerhet} = \frac{9\,667}{10\,000} = \mathbf{96,67\ \%}$$

- Modellen er verdiløs — den fanger opp *null* av kundene banken faktisk vil identifisere.
- Til sammenligning gir logistisk regresjon med `balance`, `income` og `student` en treffsikkerhet på 97,32 %. Bare 0,65 prosentpoeng bedre enn å si “nei” til alt.
- Vi trenger å vite *hvilke* feil modellen gjør, ikke bare *hvor mange*.

Confusion matrix

Bryt de n observasjonene ned i fire ruter: hva var sant, og hva gjettet vi?

		Faktisk klasse	
		Nei (negativ)	Ja (positiv)
Prediksjon	Nei	Sann negativ (TN)	Falsk negativ (FN)
	Ja	Falsk positiv (FP)	Sann positiv (TP)

- Diagonalen (grønn) er de riktige svarene. Feilrate = $(FP + FN)/n$.
- **Falsk positiv:** vi ropte varsku uten grunn (banken avslår en god kunde).
- **Falsk negativ:** vi sov i timen (banken innvilger lån til en som misligholder).

Fire tall å kunne

Samme matrise, fire ulike spørsmål. Legg merke til hva som står i *nevneren* — det er der forskjellen ligger.

Begrep	Formel	Spørsmålet det svarer på
Treffsikkerhet	$\frac{TP + TN}{n}$	Hvor ofte har modellen rett totalt sett?
Sensitivitet (<i>recall</i>)	$\frac{TP}{TP + FN}$	Av dem som <i>faktisk</i> er positive: hvor mange fanget vi opp?
Spesifisitet	$\frac{TN}{TN + FP}$	Av dem som <i>faktisk</i> er negative: hvor mange lot vi være i fred?
Presisjon	$\frac{TP}{TP + FP}$	Av dem vi <i>ropte varsku om</i> : hvor mange var reelle?

Viktig Info: Sensitivitet og spesifisitet trekker mot hverandre

Du kan alltid få sensitivitet på 100 % ved å si “Ja” til alle — men da blir spesifisiteten null. Kunsten er å finne balansen som passer problemet.

Eksempel: Logistisk regresjon på Default med terskel 0,5

Modell: $\Pr(\text{mislighold})$ som funksjon av `balance`, `income` og `student`. Alle 10 000 observasjoner.

Predikert	Faktisk		Sum
	Nei	Ja	
Nei	9 627	228	9 855
Ja	40	105	145
Sum	9 667	333	10 000

Terskelen på 0,5 er ikke hellig

Logistisk regresjon gir oss $\hat{p}(x)$. Vi bestemmer hvor grensen skal gå: $\hat{y} = \text{Ja}$ hvis $\hat{p}(x) > t$.

Terskel t	Feilrate	Sensitivitet	Spesifisitet	Presisjon
0,5	2,68 %	31,5 %	99,6 %	72,4 %
0,2	4,07 %	61,0 %	97,1 %	42,3 %

- Ved å senke terskelen til 0,2 nesten *dobler* vi andelen mislighold vi fanger opp: fra 31 % til 61 %.
- Prisen er en høyere samlet feilrate — fra 2,68 % til 4,07 %.

Viktig Info: Poenget

Den “beste” terskelen kan ikke leses ut av dataene alene. Den avhenger av hva de to feiltypene *koster*. Det er et økonomisk spørsmål, ikke et statistisk.

Oppsummering Del I

- Kvantitativ $Y \Rightarrow$ regresjon $\Rightarrow$ **MSE**. Kategorisk $Y \Rightarrow$ klassifikasjon $\Rightarrow$ **feilrate**.
- Treffsikkerhet alene er villedende når klassene er skjeve. Bruk **forvekslingsmatrisen**.
- Sensitivitet og spesifisitet fanger opp de to feiltypene hver for seg. Terskelen styrer avveiningen mellom dem.

Viktig Info: Men: alle tallene over er beregnet på treningsdata

Alle confusion matriser og feilrater vi nettopp så på, ble regnet ut på *de samme* 10 000 observasjonene som modellen ble tilpasset på. De er derfor for optimistiske.

Spørsmålet vi egentlig vil ha svar på er: **hvordan gjør modellen det på kunder banken ikke har sett før?**

Det er nøyaktig dette kapittel 5 gir oss verktøyene til.

Del II

Kapittel 5: Resampling-metoder

Kryssvalidering og bootstrapping

Hovedkonseptet

Resampling handler om å trekke gjentatte utvalg fra de tilgjengelige dataene og tilpasse modellen på nytt for hvert utvalg.

To hovedmål:

1. **Modell-evaluering:** Estimere test-feilen.
2. **Modell-seleksjon:** Velge riktig fleksibilitet.

Viktig Info: Økonomisk relevans

I økonomi har vi ofte begrenset med data. Resampling lar oss 'skvise' mer informasjon ut av datasettet uten å måtte samle inn nye data.

Valideringssett (The Validation Set Approach)

Den enkleste formen: Del dataene i to.

Trening (Training)

Validering

Begrensninger:

- **Varians:** Estimert test-feil kan variere mye avhengig av *hvilke* observasjoner som havner i hvilken boks.
- **Overestimering av feil:** Siden modellen trenes på færre data enn tilgjengelig, vil den ofte prestere dårligere enn den egentlig ville gjort på hele datasettet.

Leave-One-Out Cross-Validation (LOOCV)

En ekstrem variant: Tren på $n - 1$ observasjoner, test på den siste. Gjenta n ganger.

$$CV_{(n)} = \frac{1}{n} \sum_{i=1}^n MSE_i$$

Fordeler:

- Langt mindre bias enn valideringssettet.
- Ingen tilfeldighet (du får alltid samme resultat).

Ulemper:

- Beregningsmessig tungt (n regresjoner!).
- *Unntak:* For OLS finnes en snarvei: $CV_{(n)} = \frac{1}{n} \sum \left(\frac{y_i - \hat{y}_i}{1 - h_i} \right)^2$.

k-fold Cross-Validation

Gullstandarden i maskinl ring. Del data i k grupper (folder).



Gult = Test / Validering

Bl tt = Trening

Vanligvis brukes $k = 5$ eller $k = 10$. Det gir et godt kompromiss mellom beregningstid og presisjon.

Hvorfor ikke alltid LOOCV (altså k lik n)?

Det handler om variansen til selve feil-estimatet.

- **LOOCV** ($k = n$): Lav bias (vi bruker nesten alle data), men **høy varians**. De n modellene vi trener er nesten identiske $\implies$ deres MSE-er er høyt korrelerte. Gjennomsnittet av høyt korrelerte tall har høyere varians.
- $k = 5$ eller 10 : Litt høyere bias, men mye **lavere varians**.

I praksis: $k = 10$ er ofte det beste estimatet på den sanne test-feilen.

Bootstrapping: Hva er det?

To pull oneself up by one's bootstraps."Vi bruker de dataene vi har til å simulere nye utvalg.

Konseptet: Trekking med tilbakelegging (Replacement).

1. Vi har et datasett Z med n observasjoner.
2. Vi trekker n observasjoner tilfeldig fra Z , *men vi legger hver observasjon tilbake før vi trekker neste.*
3. Dette betyr at i et Bootstrap-datasett " Z^* ", kan noen observasjoner fra originalen dukke opp flere ganger, mens andre ikke er med i det hele tatt.

Viktig Info: Hvorfor?

Dette lar oss estimere usikkerheten (standardfeilen) til *hvilken som helst* statistikk, selv om vi ikke har en matematisk formel for det.

Hvorfor trekker vi bare 2/3 av dataene?

Siden vi trekker med tilbakelegging, vil noen observasjoner trekkes flere ganger, mens andre aldri blir med.

Sannsynlighetsregning:


- Sannsynligheten for at observasjon i *ikke* blir trukket i ett enkelt trekk: $1 - 1/n$.
- Sannsynligheten for at den *ikke* blir med i det hele tatt etter n trekk: $(1 - 1/n)^n$.
- Når n blir stor, går dette mot $1/e \approx 0.368$.

Viktig Info: 63.2%-regelen

Sannsynligheten for at en observasjon blir med minst én gang er:

$$1 - (1 - 1/n)^n \approx 1 - 0.368 = \mathbf{0.632}$$

Altså inneholder hvert bootstrap-utvalg ca. **2/3** av de originale observasjonene. De resterende 1/3 kalles ofte "*Out-of-Bag*" (*OOB*) data.



Proessen

Vi ønsker å estimere usikkerheten til en parameter α .

1. Generer B forskjellige bootstrap-datasett: $Z^{*1}, Z^{*2}, \dots, Z^{*B}$.
2. For hvert datasett, beregn estimatet: $\hat{\alpha}^{*1}, \hat{\alpha}^{*2}, \dots, \hat{\alpha}^{*B}$.
3. Beregn standardfeilen til disse B estimatene:

$$SE_B(\hat{\alpha}) = \sqrt{\frac{1}{B-1} \sum_{b=1}^B \left(\hat{\alpha}^{*b} - \frac{1}{B} \sum_{r=1}^B \hat{\alpha}^{*r} \right)^2}$$

Dette er rett og slett det empiriske standardavviket til våre bootstrap-estimer.

Eksempel: Investeringsallokering

Anta at du skal investere i to aksjer (X og Y). Du vil minimere variansen til porteføljen ved å velge andelen α i aksje X .

$$\alpha = \frac{\sigma_Y^2 - \sigma_{XY}}{\sigma_X^2 + \sigma_Y^2 - 2\sigma_{XY}}$$

- I virkeligheten kjenner vi ikke $\sigma_X, \sigma_Y, \sigma_{XY}$. Vi må estimere dem.
- Hvordan vet vi hvor nøyaktig vår $\hat{\alpha}$ er?
- **Løsning:** Bootstrap! Vi trekker nye datasett fra historiske avkastninger og ser hvor mye $\hat{\alpha}$ hopper rundt.

Hvorfor Bootstrap?

- **Fleksibilitet:** Fungerer på komplekse statistikker (f.eks. median, ratioer, eller koeffisienter fra kompliserte modeller).
- **Ingen fordelingsantakelser:** Vi trenger ikke anta at dataene er normalfordelte.

Men vær forsiktig:

- **Avhengighet:** Standard bootstrap antar uavhengige observasjoner (i.i.d.). Fungerer dårlig på tidsserier uten modifikasjoner (f.eks. Block Bootstrap).
- **Små utvalg:** Hvis originalutvalget er dårlig, blir bootstrap-resultatet også dårlig (Garbage in, garbage out").

Oppsummering Kapittel 5

- **Kryssvalidering** brukes for å sjekke modellens nøyaktighet og velge modell (tuning).
- **k -fold** ($k = 10$) er den foretrukne metoden i de fleste tilfeller.
- **Bootstrap** er et kraftfullt verktøy for å beregne usikkerhet og standardfeil til estimer.
- For en samfunnsøkonom: Dette er verktøyene som skiller en robust analyse fra en tilfeldig konklusjon.

Neste gang: Kapittel 8 - Beslutningstrær.

