

Forberedelser til muntlig eksamen - SOK-1305

Fagansvarlig: Markus J. Aase
Universitetslektor i matematikk og statistikk

8. september 2026

Dette dokumentet inneholder mulige spørsmål studenter i SOK-1305 *Statistisk læring for økonomer* **kan** få på muntlig eksamen. Spørsmålene er hentet fra pensum (ISLP kapittel 1–5, 8 og 9) og dekker tematikk vi har diskutert i forelesningene, i notebookene, i seminarene eller som dere har jobbet med i prosjektarbeidet. Alle kandidater **vil** få noen spørsmål fra listen nedenfor.

Alle får minst to spørsmål fra denne samlingen.

Mulige spørsmål

1. Hva menes med **statistisk læring**? Hva er det vi forsøker å estimere når vi skriver $Y = f(X) + \epsilon$?
2. Hva er forskjellen på **regresjon** og **klassifikasjon**? Gi et eksempel på hver fra økonomifaget.
3. Hva er forskjellen på **veiledet** (supervised) og **ikke-veiledet** (unsupervised) læring?
4. Vi har snakket om **prediksjon** og **inferens** som to ulike formål. Hva er forskjellen, og hvorfor spiller det en rolle for hvilken metode du velger?
5. I kurset har vi diskutert **reducible** og **irreducible error** ved å se på forventningsverdien av den kvadrerte forskjellen mellom Y og $\hat{Y}$. Hva handler dette om?
6. Hva er forskjellen på **parametriske** og **ikke-parametriske** metoder? Fordeler og ulemper ved begge.
7. Forklar avveiningen mellom **fleksibilitet** og **tolkbarhet**. Kan du gi et eksempel på en situasjon hvor du med vilje velger en mindre fleksibel modell?
8. Hvordan oppfører **treningsfeilen** og **testfeilen** seg når vi gjør modellen mer fleksibel? Hvorfor er testfeilkurven typisk U-formet?
9. Hva er **bias-variance trade-off**? Forklar hva bias og varians betyr med dine egne ord, og hvordan de henger sammen med testfeilen.

10. Hva er **overtilpasning** (overfitting)? Hva med **undertilpasning** (underfitting)? Hvordan oppdager du hver av dem i praksis?
11. Hvordan fungerer **K -nærmeste naboer** (KNN)? Hva skjer med modellen når $K = 1$, og hva skjer når K blir stor?
12. Hva gjør **minste kvadraters metode**? Hva er det vi minimerer, og kan du illustrere det geometrisk?
13. Hva er et **residual**? Hva er forskjellen på residualet e_i og feilleddet ϵ_i ?
14. Hva måler **R^2** , og hva måler **RSE**? Hvorfor øker R^2 alltid når vi legger til en ny forklaringsvariabel?
15. Hva tester **F -testen**? Hvorfor holder det ikke å bare se på de individuelle p -verdiene når vi har mange variabler?
16. Hvordan håndterer vi **kvalitative variabler** i en regresjon?
17. Hva er et **interaksjonsledd**, og hva betyr det for tolkningen?
18. En modell med horsepower og horsepower² kalles fortsatt en **lineær** modell. Hvorfor?
19. **Tolkningsoppgave.** Under er resultatet av en multipl regressjon av salg på reklamebudsjett i tre kanaler:

	Koeffisient	Standardfeil	t -verdi	p -verdi
Konstantledd	2.939	0.3119	9.42	< 0.0001
TV	0.046	0.0014	32.81	< 0.0001
radio	0.189	0.0086	21.89	< 0.0001
newspaper	-0.001	0.0059	-0.18	0.8599

Tolk koeffisienten til TV. Hva konkluderer du om **newspaper**? Dersom en enkel regresjon av salg på **newspaper** alene gir en klart positiv og signifikant koeffisient, hvordan kan begge deler stemme samtidig?

20. Hvorfor er det problematisk å bruke vanlig lineær regresjon på en **binær** respons? Hva med en respons med tre eller flere kategorier?
21. Hvordan estimeres koeffisientene i logistisk regresjon? Forklar ideen bak **sannsynlighetsmaksimering** (maximum likelihood), og hvordan det skiller seg fra minste kvadraters metode.
22. Hva er **logistisk regresjon**? Skriv opp den logistiske funksjonen, og forklar hvorfor den garanterer at predikert sannsynlighet ligger mellom 0 og 1.
23. Hvorfor kan vi ikke bruke treningsfeilen til å velge mellom modeller?

24. Hva er **valideringssett-metoden** (validation set approach)? Hva er de to største ulempene med den?
25. Hva er **LOOCV**? Hvilke fordeler har den over valideringssett-metoden, og hva er ulempen?
26. Hva er **k -fold kryssvalidering**? Beskriv fremgangsmåten steg for steg. Hvorfor bruker man som regel $k = 5$ eller $k = 10$?
27. Hva er **bootstrap**? Beskriv hvordan utvalgene trekkes, og hva som er poenget med å trekke *med tilbakelegging*. Hva er *Out of bag* data?
28. Hvorfor er det viktig at testsettet ikke brukes underveis når du velger modell eller justerer parametre?
29. Hvordan lages et **regresjonstre**? Forklar **rekursiv binær splitting**, og hvorfor algoritmen kalles “grådig”.
30. Hvordan gir et tre en prediksjon for en ny observasjon? Hva er en **terminalnode**?
31. Hvorfor må vi **beskjære** (prune) treet? Forklar **cost complexity pruning** og hva parameteren α styrer. Hvordan velger vi α ?
32. Hva er et **klassifikasjonstre**, og hvordan skiller det seg fra et regresjonstre?
33. Hva er **Gini-indeksen** og **entropi**? Hvorfor bruker vi disse framfor klassifikasjonsfeilraten når vi bygger treet?
34. Hva er fordelene med beslutningstrær? Hva er den store ulempen?
35. Hva er **bagging**? Hvorfor reduserer det variansen, og hvorfor overtilpasser vi ikke selv om vi bruker veldig mange trær?
36. Hva er **out-of-bag**-feil? Hvorfor slipper vi å gjøre kryssvalidering når vi har OOB?
37. Hva er **random forests**, og hva er den ene endringen som skiller dem fra bagging? Hvorfor hjelper det å dekorrelere trærne, og hva er et typisk valg av m ?
38. Hvordan måler vi **variabelviktighet** i en random forest? Hva mister vi i tolkbarhet sammenlignet med ett enkelt tre?
39. Hva er **boosting**?
40. Når ville du valgt ett enkelt beslutningstre framfor en random forest?
41. Hva er et **hyperplan**? Hvordan ser det ut når $p = 2$, og når $p = 3$?
42. Hvordan håndterer SVM problemer med mer enn to klasser? Forklar **en-mot-en** og **en-mot-alle**.

43. Kan du gi noen eksempler på hvor statistisk læring kan brukes innenfor økonomi og samfunnsøkonomi?

Lykke til. Kan dere alle spørsmålene her, har dere en god oversikt over pensum. Likevel, **vil** dere få spørsmål som ikke står her, men som kommer fra pensum. Husk at det også er viktig at dere har god oversikt over prosjektarbeidet deres, da dere kan bli utfordret på hvorfor dere har brukt de metodene dere har – selv om prosjektet leveres og vurderes for seg.

Muntlig eksamen er individuell og varer i inntil 30 minutter. Den utgjør 60 % av karaktergrunnlaget i kurset, mens prosjektinnleveringen utgjør de resterende 40 %. Eksamen er en dialog med sensor, hvor dere blant annet får spørsmål fra listen over og spørsmål knyttet til prosjektet deres.